Analisi Numerica

Fabio Bonsignore

4 giugno 2026

Disclaimer 1: i nomi dei risultati sono per lo più di finzione. Riferimenti a persone o cose sono puramente casuali.
Disclaimer 2: tutte le istanze di "Taylor senza resto" sono applicazioni del teorema di Lagrange, ma seguo la notazione del prof.
Disclaimer 3: le sottosezioni il cui nome inizia con "Caso", sono descrizioni preliminari per lo svolgimento di laboratori assegnati dal prof. Non contengono dati teorici nuovi.

Contents

1 Zeri Di Funzione **4**

1.1 Problema del punto fisso 4
1.2 Dal punto fisso alla ricerca degli zeri 7
1.3 Metodi quasi-Newton 8
1.3.1 Convergenza dei metodi quasi-Newton 9
1.3.2 Metodo alle Differenze 12
1.3.3 Metodo di Broyden 14
1.4 Test di arresto per la ricerca degli zeri 16
1.5 Caso della temperatura 18

2 Massimi e Minimi liberi **19**

2.1 Convessità 19
2.2 Metodi di Discesa 20
2.2.1 Steepest Descent 21
2.2.2 Discesa quasi-Newton 23
2.3 Metodi di scelta del passo 24
2.3.1 Condizioni di Wolfe 24
2.3.2 Backtracking 27
2.4 Metodo di Newton 29
2.4.1 Metodo di Newton con correzione della matrice hessiana 32
2.5 Ricerca degli zeri tramite minimi 33
2.6 Caso dei solidi di rotazione 35

3 Massimi e Minimi vincolati **37**

3.1 Introduzione all'ottimizzazione vincolata 37
3.2 Metodo del gradiente con proiezione 39
3.3 Condizioni di Karush-Kuhn-Tucker 41
3.4 Metodo di Uzawa 46
3.5 Caso del filo con ostacolo 50

4 Problemi di Cauchy **52**
4.1 Metodi a un passo 52
4.2 Calcolo dell'ordine di un metodo 54
4.3 A-stabilità 55
4.4 Metodi Runge-Kutta 57
4.5 Come implementare i metodi impliciti 58
4.6 Caso del sistema predatore-preda 59

1 Zeri Di Funzione

1.1 Problema del punto fisso

Definizione 1.1.1. *Se $F : \mathbb{R}^d \to \mathbb{R}^d$ è una funzione, allora un punto fisso $x \in \mathbb{R}^d$ è un vettore che soddisfa $F(x) = x$.*

Definizione 1.1.2. *Sia $D \subseteq \mathbb{R}^d$ un chiuso, allora $G : D \to \mathbb{R}^d$ è una contrazione di parametro $\alpha \in [0, 1)$ se:*
(i) $G(D) \subseteq D$.
(ii) $\|G(x) - G(y)\| \leqslant \alpha\|x - y\| \ \forall x, y \in D$.

Richiamo 1. *Chiameremo regolare una funzione $F \in \mathscr{C}^1(\mathbb{R}^d)$.*

Richiamo 2. *Una funzione $F : \mathbb{R}^n \to \mathbb{R}^m$ si dice lipschitziana di costante L se soddisfa: $\|F(x) - F(y)\| \leqslant L\|x - y\| \ \forall x, y \in \mathbb{R}^n$.*
Se una funzione è lipschitziana, è automaticamente uniformemente continua (e dunque continua). Similmente, se la derivata di una funzione è lipschitziana, è automaticamente regolare.

Teorema 1.1.1 (Teorema Delle Contrazioni)**.** *Sia $G : D \to D$ una contrazione di parametro α. Allora, esiste un unico punto fisso, inoltre le iterate generate dall'algoritmo:* $\begin{cases} x_0 \in D \\ x_{k+1} = G(x_k) \end{cases}$
convergono al punto fisso $\bar{x}$ con le stime:
(i) $\|x_k - \bar{x}\| \leqslant \frac{\alpha^k}{1-\alpha}\|x_1 - x_0\|$.
(ii) $\|x_k - \bar{x}\| \leqslant \frac{\alpha}{1-\alpha}\|x_k - x_{k-1}\|$.

Proof. (Unicità) Siano $\bar{x}, \bar{y} \in D$ punti fissi distinti, allora $\|\bar{x} - \bar{y}\| = \|G(\bar{x}) - G(\bar{y})\| \leqslant \alpha\|\bar{x} - \bar{y}\| < \|\bar{x} - \bar{y}\|$, generando un assurdo.
(Esistenza) Osserviamo che $\|x_n - x_{n-1}\| = \|G(x_{n-1}) - G(x_{n-2})\| \leqslant \alpha\|x_{n-1} - x_{n-2}\|$. Vogliamo mostrare che la successione $\{x_k\}_{k=1}^{\infty}$ è di Cauchy. Siano $k, l \in \mathbb{N}$, allora $\|x_{k+l} - x_k\| = \|x_{k+l} - x_{k+l-1} + x_{k+l-1} - \ldots +$

$x_{k+1}-x_k\| \leqslant \sum_{j=0}^{l-1} \|x_{k+j+1}-x_{k+j}\| \leqslant \sum_{j=0}^{l-1} \alpha^j \|x_{k+1}-x_k\| \leqslant \frac{1}{1-\alpha}\|x_{k+1}-x_k\| \leqslant \frac{\alpha}{1-\alpha}\|x_k-x_{k-1}\| \leqslant \frac{\alpha^k}{1-\alpha}\|x_1-x_0\| \to 0$ per $k \to \infty$ uniformemente rispetto a l, ovvero la successione è di Cauchy. Sappiamo che D è chiuso, quindi la successione ammette limite. Inoltre, G è una contrazione, perciò è α-lipschitziana e dunque continua: $G(\bar{x}) = G(\lim_{k\to\infty} x_k) = \lim_{k\to\infty} G(x_k) = \lim_{k\to\infty} x_{k+1} = \bar{x}$. □

La seconda stima è la migliore per valutare nella pratica l'errore ma non fornisce dati sulla velocità di convergenza. Nell'implementazione, si aggiunge un test di arresto che si basa sulla seconda stima. Per evitare di usare troppe iterazioni nella soluzione numerica del problema, cerchiamo una minorazione dell'errore. La otteniamo come segue: $\|x_{k+1} - x_k\| \leqslant \|x_{k+1} - \bar{x}\| + \|\bar{x} - x_k\| = \|G(x_k) - G(\bar{x})\| + \|\bar{x} - x_k\| \leqslant (1+\alpha)\|x_k - \bar{x}\| \iff \frac{\|x_{k+1}-x_k\|}{1+\alpha} \leqslant \|x_k - \bar{x}\|$.
L'esempio del problema del punto fisso con le contrazioni rappresenta un problema risolto, limitato sia dall'alto che dal basso, e con stime degli errori.

Lemma 1.1.1 (Costante di Lipschitz per funzioni $\mathscr{C}^1$)**.** *Siano $G : D \to \mathbb{R}^d$ una funzione regolare, $D \subseteq \mathbb{R}^d$ un sottoinsieme convesso e sia $\alpha = \sup_{x\in D} \|G'(x)\| < \infty$. Allora, $\|G(x) - G(y)\| \leqslant \alpha\|x - y\|$ $\forall x, y \in D$ ed α è la più piccola costante che verifica questa disuguaglianza.*

Proof. Siano $x, y \in D$, usiamo lo sviluppo di Taylor senza resto: $\|G(x) - G(y)\| = \|G'(z)(y - x)\| \leqslant \alpha\|y - x\|$.
Sia per assurdo G lipschitziana di costante $\tilde{\alpha} \in [0, \alpha)$. Allora, $\alpha = \sup_{x\in D} \|G'(x)\| = \sup_{x\in D} \sup_{v\in\mathbb{R}^d, \|v\|=1} \|G'(x)v\| = \sup_{x\in D} \sup_{v\in\mathbb{R}^d, \|v\|=1} \lim_{h\to 0} \frac{\|G(x+hv)-G(x)\|}{|h|\|v\|} \leqslant \sup_{x\in D} \sup_{v\in\mathbb{R}^d, \|v\|=1} \lim_{h\to 0} \frac{\tilde{\alpha}\|hv\|}{|h|\|v\|} \leqslant \tilde{\alpha} < \alpha$, generando un assurdo. □

Definizione 1.1.3. *Sia* $\{x_k\} \subseteq \mathbb{R}^d$ *convergente a* $\bar{x}$. *Si dice che la successione converge con ordine* $r \geqslant 1$ *se esiste* $C > 0$ *tale che* $\|x_{k+1} - \bar{x}\| \leqslant C\|x_k - \bar{x}\|^r$, *definitivamente in* k.
Se $r = 1$ *si parla di convergenza lineare e si richiede* $C < 1$.
Se $\limsup_{k\to\infty} \frac{\|x_{k+1}-\bar{x}\|}{\|x_k-\bar{x}\|} = 0$ *si parla di convergenza superlineare.*
Se $r = 2$ *si parla di convergenza quadratica.*

Proposizione 1.1.1 (Ordine di convergenza per le iterate di punto fisso)**.** *Sia* $G : D \to \mathbb{R}^d$ *una funzione regolare,* $\bar{x} \in D$ *un punto fisso per* G *e* $D \subseteq \mathbb{R}^d$ *un sottoinsieme. (i) Se* $\|G'(\bar{x})\| < 1$, *allora esiste* $B(\bar{x}, \delta)$ *tale che* $G_{|B(\bar{x},\delta)}$ *è una contrazione (dunque se* $x_0 \in B(\bar{x}, \delta)$, *si ha convergenza). Inoltre,* $\limsup_{k\to\infty} \frac{\|x_{k+1}-\bar{x}\|}{\|x_k-\bar{x}\|} \leqslant \|G'(\bar{x})\|$.
(ii) Se $\|G'(\bar{x})\| \geqslant 1$, *allora non esiste alcun intorno di* $\bar{x}$ *su cui* G *è una contrazione.*

Proof. (i) Sappiamo che $\|G'(x)\|$ è continua, quindi per il teorema di permanenza del segno esistono $r \in [0, 1)$ e $\delta > 0$ tale che $\forall x \in B(\bar{x}, \delta)$ vale $\|G'(x)\| \leqslant r < 1$. Dunque, per il Lemma 1.1.1: $G_{|\overline{B(\bar{x},\delta)}}$ è lipschitziana con $\alpha = \sup_{x\in B(\bar{x},\delta)} \|G'(x)\| < 1$. Inoltre, se $x \in \overline{B(\bar{x}, \delta)}$, allora $\|G(x)-\bar{x}\| = \|G(x)-G(\bar{x})\| \leqslant \alpha\|x-\bar{x}\| \leqslant \alpha\delta < \delta$, dunque G è una contrazione. Dal Teorema 1.1.1, segue che si ha convergenza nella palla. Inoltre: $\frac{\|x_{k+1}-\bar{x}\|}{\|x_k-\bar{x}\|} = \frac{\|G(x_k)-G(\bar{x})\|}{\|x_k-\bar{x}\|} \overset{\text{Taylor}}{=} \frac{\|G(\bar{x})+G'(\bar{x})(x_k-\bar{x})+o(\|x_k-\bar{x}\|)-G(\bar{x})\|}{\|x_k-\bar{x}\|} = \frac{\|G'(\bar{x})(x_k-\bar{x})+o(\|x_k-\bar{x}\|)\|}{\|x_k-\bar{x}\|} \leqslant \frac{\|G'(\bar{x})(x_k-\bar{x})\|+\|o(\|\bar{x}-x_k\|)\|}{\|x_k-\bar{x}\|} \leqslant \|G'(\bar{x})\| + \frac{\|o(\|\bar{x}-x_k\|)\|}{\|x_k-\bar{x}\|}$.
(ii) Sia U intorno di $\bar{x}$, allora sappiamo che $\sup_{x\in U} \|G'(x)\| \geqslant \|G'(\bar{x})\| \geqslant 1$, dunque la costante di Lipschitz è maggiore o uguale a 1, ovvero $G_{|U}$ non è una contrazione. □

1.2 Dal punto fisso alla ricerca degli zeri

Richiamo 3. *Il gruppo lineare di ordine d su* $\mathbb{R}$ *è l'insieme delle matrici invertibili a coefficienti reali di ordine d e si indica con* $GL(d,\mathbb{R}) = \{A \in \mathbb{R}^{d\times d} \mid \det(A) \neq 0\}$.

Sia $F : D \to \mathbb{R}^d$, con $D \subseteq \mathbb{R}^d$; vogliamo trovare un punto $\bar{x} \in D$ tale per cui $F(\bar{x}) = 0$. Supponiamo che esista un campo di matrici invertibili $A : D \to GL(d,\mathbb{R})$. In tal caso, il problema della ricerca degli zeri può essere riformulato in modo equivalente come segue:

$$F(\bar{x}) = 0 \iff -A(\bar{x})F(\bar{x}) = 0 \iff \bar{x} - A(\bar{x})F(\bar{x}) = \bar{x}$$

Definendo la funzione

$$G(x) = x - A(x)F(x)$$

il problema originale diventa a tutti gli effetti un problema di punto fisso del tipo $G(\bar{x}) = \bar{x}$.

Proviamo a verificare sotto quali condizioni siano soddisfatte le ipotesi del teorema di convergenza locale, ovvero $\|G'(\bar{x})\| < 1$. Calcoliamo lo Jacobiano di G valutato in $\bar{x}$. Applicando la regola di derivazione del prodotto e ricordando che $F(\bar{x}) = 0$, il termine contenente la derivata di A si annulla:

$$\|G'(\bar{x})\| = \|I_d - A'(\bar{x})F(\bar{x}) - A(\bar{x})F'(\bar{x})\| \overset{F(\bar{x})=0}{=} \|I_d - A(\bar{x})F'(\bar{x})\| < 1$$

Il problema si sposta quindi sulla scelta di una matrice $A(x)$ ottimale che minimizzi la norma dello Jacobiano.

La scelta migliore risulta essere $A(x) = (F'(x))^{-1}$ (ipotizzando che lo Jacobiano di F sia non singolare). Con questa scelta si ottiene infatti $\|G'(\bar{x})\| = \|I_d - I_d\| = 0$, garantendo un ordine di convergenza superiore al primo (almeno quadratico).

1.3 Metodi quasi-Newton

Definizione 1.3.1. *Siano $B_k \in GL(d, \mathbb{R})$ e $B_k \approx F'(x_k)$. Un metodo quasi-Newton è un metodo di ricerca degli zeri che segue il seguente algoritmo:* $\begin{cases} x_0 \in D \\ x_{k+1} = x_k - B_k^{-1} F(x_k) \end{cases}$

A livello implementativo, non sarebbe ottimale usare questa forma perché richiederebbe il calcolo dell'inversa di una matrice, dunque lo modifichiamo scrivendo: $B_k \Delta x_k = -F(x_k)$.

Definizione 1.3.2. *Il metodo di Newton usa come matrice di iterazione $B_k = F'(x_k)$.*

Sebbene sia potenzialmente il miglior metodo, si riscontrano due problemi: il calcolo di F' non è sempre possibile e, se lo fosse, potrebbe essere una matrice piena.

Definizione 1.3.3. *Il metodo delle corde usa come matrice di iterazione $B_k = F'(x_0)$.*

Il vantaggio del metodo delle corde è il suo costo computazionale basso, in quanto è possibile calcolare la decomposizione LU della matrice $F'(x_0)$ per velocizzare le iterazioni successive.

Definizione 1.3.4. *Il metodo di Newton-Jacobi usa come matrice di iterazione $B_k = diag(F'(x_k))$.*

Il vantaggio di questo metodo è il suo costo computazionale nettamente inferiore agli altri, ma richiede condizioni molto forti per garantire intorni di convergenza.

1.3.1 Convergenza dei metodi quasi-Newton

Lemma 1.3.1 (Lemma di invertibilità)**.** *Siano $A \in GL(d,\mathbb{R})$ e $B \in \mathbb{R}^{d\times d}$ tali che $\|A-B\| < \frac{1}{\|A^{-1}\|}$. Allora, $B \in GL(d,\mathbb{R})$ e $\|B^{-1}\| \leqslant \frac{\|A^{-1}\|}{1-\|A^{-1}\|\|A-B\|}$.*

Proof. Consideriamo il caso $A = I_d$ e $\|I-B\| < 1$. In analogia con il caso uno dimensionale, possiamo pensare che $\frac{1}{b} = \sum_{j=0}^{\infty}(1-b)^j$. Consideriamo dunque la successione delle somme parziali $S_n = \sum_{j=0}^{n}(I-B)^j$ e mostriamo che è una successione di Cauchy: $\|S_{n+l} - S_n\| = \|\sum_{j=n+1}^{n+l}(I-B)^j\| \leqslant \sum_{j=n+1}^{n+l}\|I-B\|^j = \|I-B\|^{n+1}\sum_{j=0}^{l-1}\|I-B\|^j \leqslant \|I-B\|^{n+1}\sum_{j=0}^{\infty}\|I-B\|^j = \frac{\|I-B\|^{n+1}}{1-\|I-B\|}$. Osserviamo che il numeratore tende a 0 per $n\to\infty$, dunque la serie converge a una matrice $S \in \mathbb{R}^{d\times d}$. Notiamo che: $S_{n+1} = \sum_{j=0}^{n+1}(I-B)^j = I + \sum_{j=1}^{n+1}(I-B)^j = I + (I-B)\sum_{j=1}^{n+1}(I-B)^{j-1} = I + (I-B)\sum_{j=0}^{n}(I-B)^j = I + (I-B)S_n$. Prendendo il limite per $n\to\infty$ di entrambi i membri, si ha $S = I + (I-B)S \iff BS = I$, ovvero $B \in \mathrm{GL}(d,\mathbb{R})$. Calcoliamo la norma dell'inversa di B: $B^{-1} = S = \lim_{n\to\infty}\sum_{j=0}^{n}(I-B)^j \Longrightarrow \|B^{-1}\| = \lim_{n\to\infty}\|S_n\| \leqslant \lim_{n\to\infty}\sum_{j=0}^{n}\|I-B\|^j \leqslant \frac{1}{1-\|I-B\|}$. Torniamo al caso generale, dimostriamo che $A^{-1}B \in GL(d,\mathbb{R})$: $\|I - A^{-1}B\| = \|A^{-1}(A-B)\| \leqslant \|A^{-1}\|\|A-B\| \overset{\text{ipotesi}}{<} 1$, dunque applichiamo il punto precedente e otteniamo il risultato. Da questo, segue che $B \in \mathrm{GL}(d,\mathbb{R})$. Valutiamo la norma dell'inversa: $\|B^{-1}\| = \|B^{-1}AA^{-1}\| = \|(A^{-1}B)^{-1}A^{-1}\| \leqslant \|A^{-1}\|\|(A^{-1}B)^{-1}\| \leqslant \frac{\|A^{-1}\|}{1-\|I-A^{-1}B\|} \leqslant \frac{\|A^{-1}\|}{1-\|A^{-1}\|\|A-B\|}$. □

Lemma 1.3.2 (Lemma di comportamento intorno a uno zero)**.** *Siano $F : D \to \mathbb{R}^d$ una funzione con derivata F' lipschitziana di costante L, $\bar{x}$ uno zero di F, $D \subseteq \mathbb{R}^d$ un sottoinsieme e supponiamo $F'(\bar{x}) \in GL(d, \mathbb{R})$. Allora, $\exists \delta > 0$ tale per cui $\forall x \in B(\bar{x}, \delta)$:*
(i) $\|F'(x)\| \leqslant 2\|F'(\bar{x})\|$.
(ii) $\|F'(x)^{-1}\| \leqslant 2\|F'(\bar{x})^{-1}\|$.
(iii) $\frac{1}{2}\|F'(\bar{x})^{-1}\|^{-1}\|x - \bar{x}\| \leqslant \|F(x)\| \leqslant 2\|F'(\bar{x})\|\|x - \bar{x}\|$.

Proof. (i) $\|F'(x)\| = \|F'(x) - F'(\bar{x}) + F'(\bar{x})\| \leqslant \|F'(x) - F'(\bar{x})\| + \|F'(\bar{x})\| \leqslant L\|x - \bar{x}\| + \|F'(\bar{x})\| \leqslant L\delta + \|F'(\bar{x})\|$, scegliamo $\delta \leqslant \frac{\|F'(\bar{x})\|}{L}$.
(ii) Vogliamo usare il Lemma 1.3.1 con $A = F'(\bar{x})$ e $B = F'(x)$, dunque valuto: $\|F'(x) - F'(\bar{x})\| \leqslant L\|x - \bar{x}\| \leqslant L\delta$, scegliamo $\delta \leqslant \frac{1}{2L\|F'(\bar{x})^{-1}\|}$, dove il 2 al denominatore è necessario per avere la disuguaglianza stretta richiesta dal lemma. Dunque, $F'(x) \in \mathrm{GL}(d, \mathbb{R})$ è invertibile e la maggiorazione segue dal Lemma 1.3.1 e dalla maggiorazione precedente: $\|F'(x)^{-1}\| \leqslant \frac{\|F'(x)^{-1}\|}{1 - \|F'(\bar{x})^{-1}\|\|F'(x) - F'(\bar{x})\|} \leqslant \frac{\|F'(\bar{x})^{-1}\|}{1 - \frac{1}{2}} = 2\|F'(\bar{x})^{-1}\|$.
(iii) Scegliamo $\delta = \min\{\frac{1}{2L\|F'(\bar{x})^{-1}\|}, \frac{\|F'(\bar{x})\|}{L}\}$ in modo da rendere validi i risultati dei punti precedenti, facciamo delle manipolazioni algebriche: $F(x) = F(x) - F(\bar{x}) = F(\bar{x}) + F'(z)(x - \bar{x}) - F(\bar{x}) = F'(z)(x - \bar{x})$, con $z = \bar{x} + \theta(x - \bar{x}) \in B(\bar{x}, \delta)$ $\theta \in (0, 1)$ (Taylor senza resto). Quindi, $\|F(x)\| = \|F'(z)(x - \bar{x})\| \leqslant \|F'(z)\|\|x - \bar{x}\| \leqslant 2\|F'(\bar{x})\|\|x - \bar{x}\|$. Per ottenere l'implicazione opposta, scriviamo $x - \bar{x} = (F'(z))^{-1}F(x) \implies \|x - \bar{x}\| \leqslant \|(F'(z))^{-1}\| \cdot \|F(x)\| \leqslant 2\|(F'(\bar{x}))^{-1}\| \cdot \|F(x)\| \implies \|F(x)\| \geqslant \frac{\|x - \bar{x}}{2\|(F'(\bar{x}))^{-1}\|}$. □

Lemma 1.3.3 (Lemma di comportamento al passo)**.** *Sia $F : D \to \mathbb{R}^d$ una funzione con derivata F' lipschitziana di costante L, $\bar{x} \in D$ uno zero di F e supponiamo $F'(\bar{x}) \in GL(d, \mathbb{R})$. Detto $\delta > 0$ il raggio la cui esistenza è garantita dal Lemma* 1.3.2*, allora $\forall x_k \in B(\bar{x}, \delta)$ l'iterata generata da un metodo quasi-Newton $x_{k+1} = x_k - B_k^{-1}F(x_k)$ soddisfa:*

$$\|x_{k+1} - \bar{x}\| \leqslant \rho_k\|x_k - \bar{x}\| + C\|x_k - \bar{x}\|^2$$

Dove $\rho_k = \|I - B_k^{-1}F'(x_k)\| < 1$ *e* $C = C(F) > 0$.

Proof. $\|x_{k+1} - \bar{x}\| = \|x_k - B_k^{-1}F(x_k) - \bar{x}\| = \|(x_k - \bar{x}) - B_k^{-1}(F(x_k) - F(\bar{x}))\| = \|(x_k - \bar{x}) - B_k^{-1}\int_0^1 \frac{d}{ds}F(\bar{x} + s(x_k - \bar{x}))\ ds\| = \|(x_k - \bar{x}) - B_k^{-1}\int_0^1 F'(\bar{x} + s(x_k - \bar{x}))(x_k - \bar{x})\ ds\| = \|(I - B_k^{-1}F'(x_k))(x_k - \bar{x}) - B_k^{-1}\int_0^1 (F'(\bar{x} + s(x_k - \bar{x})) - F'(x_k))(x_k - \bar{x})\ ds\| \leqslant \|I - B_k^{-1}F'(x_k)\|\|x_k - \bar{x}\| + \|B_k^{-1}\|\|\int_0^1 (F'(\bar{x} + s(x_k - \bar{x})) - F'(x_k))(x_k - \bar{x})\ ds\| \leqslant \rho_k\|x_k - \bar{x}\| + \|B_k^{-1}\|\int_0^1 \|F'(\bar{x} + s(x_k - \bar{x})) - F'(x_k)\|\|x_k - \bar{x}\|\ ds \leqslant \rho_k\|x_k - \bar{x}\| + \|B_k^{-1}\|\int_0^1 L\|\bar{x} + s(x_k - \bar{x}) - x_k\|\|x_k - \bar{x}\|\ ds \leqslant \rho_k\|x_k - \bar{x}\| + \|B_k^{-1}\|\int_0^1 L(1 - s)\|\bar{x} - x_k\|\|x_k - \bar{x}\|\ ds = \rho_k\|x_k - \bar{x}\| + \frac{L}{2}\|B_k^{-1}\|\|x_k - \bar{x}\|^2$
$\|B_k^{-1}\| = \|B_k^{-1}F'(x_k)F'(x_k)^{-1}\| \leqslant \|B_k^{-1}F'(x_k)\|\|F'(x_k)^{-1}\| \leqslant (\|I\| + \|I - B_k^{-1}F'(x_k)\|)\|F'(x_k)^{-1}\| \leqslant (1 + \rho_k)2\|F'(\bar{x})^{-1}\| \leqslant 4\|F'(\bar{x})^{-1}\|$. □

Proposizione 1.3.1 (Convergenza locale del metodo di Newton)**.** *Sia* $F : D \to \mathbb{R}^d$ *una funzione con derivata* F' *lipschitziana di costante* L, $\bar{x} \in D$ *uno zero di* F *e supponiamo* $F'(\bar{x}) \in GL(d, \mathbb{R})$*. Allora, detto* $\bar{\delta}$ *il raggio la cui esistenza è garantita dal Lemma* 1.3.2, $\exists \delta > 0$ *con* $\bar{\delta} \leqslant \delta$ *tale che* $\forall x_0 \in B(\bar{x}, \bar{\delta})$*, il metodo di Newton converge a* $\bar{x}$ *con la stima:* $\|x_{k+1} - \bar{x}\| \leqslant C\|x_k - \bar{x}\|^2$.

Proof. Sia $x_k \in B(\bar{x}, \bar{\delta})$, possiamo applicare il Lemma 1.3.3. Per definizione del metodo, si ha $\rho_k = 0$, ovvero: $\|x_{k+1} - \bar{x}\| \leqslant C\|x_k - \bar{x}\|^2 \leqslant C\|x_k - \bar{x}\|\|x_k - \bar{x}\| \leqslant C\bar{\delta}\|x_k - \bar{x}\|$. Scegliendo $\bar{\delta} \leqslant \frac{1}{2C}$, si ha: $\|x_{k+1} - \bar{x}\| \leqslant \frac{1}{2}\|\bar{x} - x_k\|$. □

Proposizione 1.3.2 (Convergenza locale del metodo delle corde)**.** *Sia* $F : D \to \mathbb{R}^d$ *una funzione con derivata* F' *lipschitziana di costante* L, $\bar{x} \in D$ *uno zero di* F *e supponiamo* $F'(\bar{x}) \in GL(d, \mathbb{R})$*. Allora, detto* $\bar{\delta}$ *il raggio la cui esistenza è garantita dal Lemma* 1.3.2, $\exists \delta > 0$ *con* $\bar{\delta} \leqslant \delta$ *tale che* $\forall x_0 \in B(\bar{x}, \bar{\delta})$*, il metodo delle corde converge a* $\bar{x}$ *con la stima:* $\|x_{k+1} - \bar{x}\| \leqslant (\hat{C}\|x_0 - \bar{x}\|)\|x_k - \bar{x}\|$.

Proof. Sia $x_k \in B(\bar{x}, \bar{\delta})$, allora per il Lemma 1.3.3: $\|x_{k+1} - \bar{x}\| \leqslant \|I - F'(x_0)^{-1}F'(x_k)\|\|x_k - \bar{x}\| + C\|x_k - \bar{x}\|^2 \leqslant \|F'(x_0)^{-1}\|\|F'(x_0) - F'(x_k)\|\|x_k - \bar{x}\| + C\|x_k - \bar{x}\|^2 \leqslant \|F'(x_0)^{-1}\|L\|x_0 - x_k\|\|x_k - \bar{x}\| + C\|x_k - \bar{x}\|^2 \leqslant 2L\|F'(\bar{x})^{-1}\|(\|x_0 - \bar{x}\| + \|x_k - \bar{x}\|)\|x_k - \bar{x}\| + C\|x_k - \bar{x}\|^2 \leqslant (4L\|F'(\bar{x})^{-1}\|\bar{\delta} + C\bar{\delta})\|x_k - \bar{x}\| \leqslant (4L\|F'(\bar{x})^{-1}\|\bar{\delta} + C\bar{\delta})\|x_k - \bar{x}\|$ per un'opportuna scelta di $\bar{\delta}$, dunque si ha convergenza.
Riprendendo la maggiorazione da qualche passaggio prima, sappiamo che: $2L\|F'(\bar{x})^{-1}\|(\|x_0 - \bar{x}\| + \|x_k - \bar{x}\|) \leqslant 4L\|F'(\bar{x})^{-1}\|\|x_0 - \bar{x}\|$ in quanto abbiamo verificato che c'è convergenza. Perciò: $\|x_{k+1} - \bar{x}\| \leqslant (4L\|F'(\bar{x})^{-1}\|\|x_0 - \bar{x}\| + C\|x_k - \bar{x}\|)\|x_k - \bar{x}\| \leqslant (4L\|F'(\bar{x})^{-1}\|\|x_0 - \bar{x}\| + C\|x_0 - \bar{x}\|)\|x_k - \bar{x}\| = (C + 4L\|F'(\bar{x})^{-1}\|)\|x_0 - \bar{x}\|\|x_k - \bar{x}\| = \hat{C}\|x_0 - \bar{x}\|\|x_k - \bar{x}\|$. □

Proposizione 1.3.3 (Convergenza locale del metodo di Newton-Jacobi)**.** *Sia $F : D \to \mathbb{R}^d$ una funzione con derivata F' lipschitziana di costante L, $\bar{x} \in D$ uno zero di F, supponiamo che $F'(\bar{x}) \in GL(d, \mathbb{R})$ sia strettamente a diagonale dominante per righe. Allora, detto $\bar{\delta}$ il raggio la cui esistenza è garantita dal Lemma* 1.3.2*, $\exists \delta > 0$ con $\bar{\delta} \leqslant \delta$ tale che $\forall x_0 \in B(\bar{x}, \bar{\delta})$, il metodo di Newton-Jacobi converge a $\bar{x}$ linearmente.*

1.3.2 Metodo alle Differenze

Definizione 1.3.5. *Sia $h \in (0, 1)$, il metodo alle differenze usa come matrice di iterazione $(B_k)_{ij} = \frac{F_i(x_k + h\hat{e}_j) - F_i(x_k)}{h}$. Viene implementato come: $(B_k)_j = \frac{F(x_k + h\hat{e}_j) - F(x_k)}{h}$.*

Proposizione 1.3.4. *Sia $F : D \to \mathbb{R}^d$ una funzione con derivata F' lipschitziana di costante L, $\bar{x} \in D$ uno zero di F e supponiamo $F'(\bar{x}) \in GL(d, \mathbb{R})$. Allora, detto $\bar{\delta}$ il raggio la cui esistenza è garantita dal Lemma* 1.3.2*, $\exists \delta > 0$ con $\bar{\delta} \leqslant \delta$ tale che $\forall x_0 \in B(\bar{x}, \bar{\delta})$, il metodo alle differenze converge linearmente e ρ_k è proporzionale ad h.*

Proof. $|(B_k)_j - (F'(x_k))_j| = |\frac{F(x_k+h\hat{e}_j)-F(x_k)}{h} - (F'(x_k))_j| =$
$= |\frac{F(x_k)+(F'(x_k+\theta h\hat{e}_j)\cdot\hat{e}_j)h-F(x_k)}{h} - (F'(x_k))_j| = |F'(x_k+\theta h\hat{e}_j)_j - F'(x_k)_j| \leqslant$
$L\|x_k + \theta h\hat{e}_j - x_k\| = L\theta h \leqslant Lh \Longrightarrow \|B_k - F'(x_k)\| \leqslant dLh.$
Applichiamo il Lemma 1.3.1 su $A = F'(x_k)$ e $B = B_k$ e scegliamo $h < \frac{1}{4dL\|F'(\bar{x})^{-1}\|}$, in modo che: $\|F'(x_k) - B_k\| \leqslant dLh \leqslant \frac{1}{4\|F'(\bar{x})^{-1}\|} \leqslant$ $\frac{1}{2\|F'(x_k)^{-1}\|} < \frac{1}{\|F'(x_k)^{-1}\|}$. Dunque $B_k \in \mathrm{GL}(d,\mathbb{R})$ e $\|B_k^{-1}\| \leqslant \frac{\|F'(x_k)^{-1}\|}{1-\|F'(x_k)^{-1}\|\|B_k-F'(x_k)\|} \leqslant$ $\frac{\|F'(x_k)^{-1}\|}{1-\frac{1}{2}} \leqslant 2\|F'(x_k)^{-1}\|$.
Calcoliamo ρ_k: $\rho_k = \|I - B_k^{-1}F'(x_k)\| \leqslant \|B_k\|^{-1}dLh \leqslant 2\|F'(x_k)^{-1}\|dLh \leqslant$ $4\|F'(\bar{x})^{-1}\|dLh < 1.$ □

A causa degli errori di arrotondamento introdotti dall'aritmetica floating-point del calcolatore, non è possibile valutare esattamente il valore di una funzione in un dato punto. Indichiamo con $\tilde{F}_i(x)$ il valore effettivamente calcolato dalla macchina, per il quale vale la stima:

$$|F_i(x) - \tilde{F}_i(x)| < \varepsilon \quad \forall x \in \mathbb{R}^d$$

con $\varepsilon \ll 1$. Di conseguenza, l'errore totale nell'approssimazione dello Jacobiano tramite differenze finite può essere maggiorato aggiungendo e sottraendo le valutazioni esatte della funzione e applicando la disuguaglianza triangolare:
$|(B_k)_{ij} - (F'(x_k))_{ij}| = |\frac{\tilde{F}_i(x_k+h\hat{e}_j)-\tilde{F}_i(x_k)}{h} - (F'(x_k))_{ij}| \leqslant \frac{|\tilde{F}_i(x_k+h\hat{e}_j)-F_i(x_k+h\hat{e}_j)|}{h} +$
$\frac{|F_i(x_k)-\tilde{F}_i(x_k)|}{h} + |\frac{F_i(x_k+h\hat{e}_j)-F_i(x_k)}{h} - (F'(x_k))_{ij}| \leqslant \frac{\varepsilon}{h} + \frac{\varepsilon}{h} + Lh.$
Sebbene possa sembrare controintuitivo dal punto di vista puramente analitico, questo calcolo dimostra chiaramente perché, nell'implementazione numerica reale, scegliere un passo h infinitamente piccolo non sia la strategia ottimale (poiché il termine legato a ε tenderebbe a esplodere a causa dell'errore di cancellazione numerica).

1.3.3 Metodo di Broyden

Richiamo 4. *Le matrici di rango* 1 *possono essere scritte come prodotto di un vettore colonna e un vettore riga. In questo modo, il prodotto tra una matrice di rango* 1 *e un vettore colonna è un multiplo del vettore colonna della matrice.*

L'idea alla base dei metodi quasi-Newton è di generalizzare il metodo delle secanti al caso multidimensionale. Cerchiamo quindi una matrice B_k che approssimi lo Jacobiano $F'(x_k)$ e che soddisfi:

$$B_k(x_k - x_{k-1}) = F(x_k) - F(x_{k-1})$$

Quest'ultima espressione è ben definita in più variabili, ma da sola non fornisce una costruzione univoca per la matrice B_k. Per determinare univocamente l'aggiornamento, si impone che l'azione della matrice rimanga inalterata lungo tutti i vettori ortogonali all'incremento stesso. Si ottiene così il seguente sistema di condizioni:

$$\begin{cases} B_k(x_k - x_{k-1}) = F(x_k) - F(x_{k-1}) \\ B_k w = B_{k-1} w \quad \forall w \in \mathbb{R}^d \text{ t.c. } w^T(x_k - x_{k-1}) = 0 \end{cases}$$

Definizione 1.3.6 (Metodo di Broyden)**.** *Posto* $\Delta x_{k-1} = x_k - x_{k-1}$ *e* $\Delta F_{k-1} = F(x_k) - F(x_{k-1})$*, il metodo di Broyden aggiorna l'approssimazione dello Jacobiano utilizzando la formula:*

$$B_k = B_{k-1} + \frac{(\Delta F_{k-1} - B_{k-1}\Delta x_{k-1})(\Delta x_{k-1})^T}{\|\Delta x_{k-1}\|_2^2}$$

partendo da una matrice iniziale $B_0 \in \mathbb{R}^{d \times d}$*.*

Dalla definizione, è possibile verificare tramite calcoli espliciti che la matrice B_k così costruita soddisfa entrambe le condizioni del sistema

posto in precedenza. Nella pratica, la matrice iniziale B_0 viene tipicamente scelta coincidente con lo Jacobiano esatto valutato nel punto iniziale (come nel metodo di Newton, $B_0 = F'(x_0)$), oppure approssimata calcolandone le colonne tramite differenze finite.

Proposizione 1.3.5 (Convergenza locale per il metodo di Broyden)**.** *Sia $F : D \to \mathbb{R}^d$ una funzione con derivata F' lipschitziziana di costante L, $\bar{x} \in D$ uno zero di F, supponiamo che $F'(\bar{x}) \in GL(d, \mathbb{R})$ e $B_0 = F'(x_0)$. Allora, detto $\bar{\delta}$ il raggio la cui esistenza è garantita dal Lemma* 1.3.2*, $\exists \delta > 0$ con $\bar{\delta} \leqslant \delta$ tale che $\forall x_0 \in B(\bar{x}, \bar{\delta})$, il metodo di Broyden converge con ordine superlineare.*

Lemma 1.3.4 (Formula di Sherman-Morrison-Woodbury)**.** *Siano $A, B \in GL(d, \mathbb{R})$ con $B = A + vw^t$ e $v, w \in \mathbb{R}^d$. Allora, $B^{-1} = A^{-1} - \frac{A^{-1}vw^tA^{-1}}{1+w^tA^{-1}v}$.*

Proof. Siano $v, w \neq \bar{0}$, siano $x, y \in \mathbb{R}^d$ tali per cui $y = Bx$ (e quindi $x = B^{-1}y$). Allora, $w^tA^{-1}y = w^tA^{-1}(Ax + vw^tx) = w^tx + w^tA^{-1}v(w^tx) = (1 + w^tA^{-1}v)(w^tx)$. Questa relazione deve valere $\forall y \in \mathbb{R}^d$, quindi scegliendo $y = Aw$ otteniamo che $(1 + w^tA^{-1}v)(w^tx) \neq 0$ e in particolare deve esserlo il primo fattore, dunque posso dividere e ottengo $w^tx = \frac{w^tA^{-1}y}{1+w^tA^{-1}v}$. Riscrivo $Ax = y - v(w^tx) = y - v\frac{w^tA^{-1}y}{1+w^tA^{-1}v} \implies x = A^{-1}y - \frac{w^tA^{-1}y}{1+w^tA^{-1}v}A^{-1}v = A^{-1}y - \frac{A^{-1}vw^tA^{-1}}{1+w^tA^{-1}v}y = (A^{-1} - \frac{A^{-1}vw^tA^{-1}}{1+w^tA^{-1}v})y$, ma a questo punto ricordando che $x = B^{-1}y$ si ottiene la tesi. □

Questo lemma permette di facilitare il calcolo delle matrici B_k^{-1} successive richieste dal metodo di Broyden.

Osservazione 1.3.1. *Una formulazione alternativa (e computazionalmente conveniente) del metodo di Broyden lavora direttamente con le inverse $H_k = B_k^{-1}$. L'algoritmo può essere implementato come segue:*

(i) Inizializzazione dell'inversa: $H_0 = B_0^{-1}$

(ii) Primo passo iterativo: $x_1 = x_0 - H_0F(x_0)$

(iii) Procedura iterativa (per $k \geqslant 1$):

$$\begin{cases} \Delta x_{k-1} = x_k - x_{k-1} \\ \Delta F_{k-1} = F(x_k) - F(x_{k-1}) \\ H_k = H_{k-1} + \frac{(\Delta x_{k-1} - H_{k-1}\Delta F_{k-1})\Delta x_{k-1}^T H_{k-1}}{\Delta x_{k-1}^T H_{k-1} \Delta F_{k-1}} \\ \Delta x_k = -H_k F(x_k) \\ x_{k+1} = x_k + \Delta x_k \\ \textit{Verifica del criterio di arresto} \end{cases}$$

Dal punto di vista analitico le due formulazioni sono del tutto equivalenti; tuttavia, a causa dell'algebra di macchina, le traiettorie generate tendono a differire e a non coincidere esattamente in alcuni punti. In particolare, in presenza di matrici malcondizionate, questa seconda implementazione (aggiornamento diretto dell'inversa) è più soggetta a instabilità numerica e all'accumulo di errori. Un'ulteriore criticità teorica risiede nella possibilità che le matrici successive perdano la proprietà di invertibilità. Nonostante questi potenziali inconvenienti, nella pratica euristica le matrici H_k così calcolate si rivelano ottime approssimazioni dell'inversa dello Jacobiano locale.

1.4 Test di arresto per la ricerca degli zeri

Definizione 1.4.1. *Fissata una tolleranza $TOL > 0$, il test del residuo decreta l'arresto dell'algoritmo quando è verificata la condizione:*

$$\|F(x_k)\| \leqslant TOL$$

Definizione 1.4.2. *Fissata una tolleranza $TOL > 0$, il test sullo scarto (o dell'incremento) decreta l'arresto dell'algoritmo quando è verificata la condizione:*

$$\|x_k - x_{k-1}\| \leqslant TOL$$

Richiamando il terzo punto del Lemma 1.3.2 applicato al punto x_k, possiamo affermare che il test del residuo funziona bene ed è un indicatore affidabile.
Per quanto riguarda il test sullo scarto, sappiamo che tutti e tre i metodi analizzati convergono almeno linearmente, con una costante di convergenza $C < 1$. Applicando la disuguaglianza triangolare e l'ipotesi di convergenza locale ($\|x_{k+1} - \bar{x}\| \leqslant C\|x_k - \bar{x}\|$), possiamo stimare l'errore reale $\|x_k - \bar{x}\|$:

$$\|x_k - \bar{x}\| \leqslant \|x_{k+1} - x_k\| + \|x_{k+1} - \bar{x}\| \leqslant \|x_{k+1} - x_k\| + C\|x_k - \bar{x}\|$$

Riordinando i termini portando $C\|x_k - \bar{x}\|$ a sinistra, otteniamo una stima dall'alto per l'errore:

$$\|x_k - \bar{x}\| \leqslant \frac{\|x_{k+1} - x_k\|}{1 - C}$$

Al contempo, possiamo ricavare una limitazione dal basso procedendo in modo analogo:

$$\|x_{k+1} - x_k\| \leqslant \|x_{k+1} - \bar{x}\| + \|x_k - \bar{x}\| \leqslant C\|x_k - \bar{x}\| + \|x_k - \bar{x}\| = (1 + C)\|x_k - \bar{x}\|$$

Combinando le due disuguaglianze ottenute, si ricava la seguente relazione fondamentale:

$$\frac{1}{1 + C}\|x_{k+1} - x_k\| \leqslant \|x_k - \bar{x}\| \leqslant \frac{1}{1 - C}\|x_{k+1} - x_k\|$$

La differenza principale tra i due criteri risiede nel fatto che il test sullo scarto si basa intrinsecamente sulle ipotesi di convergenza del metodo iterativo, mentre il test del residuo ne prescinde (ad esempio, se si valutassero punti generati casualmente, il test del residuo rimarrebbe l'unico indicatore affidabile). Se invece il metodo iterativo impiegato possiede un ordine di convergenza quadratico, la costante

di convergenza lineare tende a zero ($C = C_k \to 0$ per $k \to \infty$). In questo scenario, le costanti moltiplicative nell'equazione tendono a 1, dimostrando che lo scarto $\|x_{k+1} - x_k\|$ approssima in modo quasi esatto l'errore effettivo $\|x_k - \bar{x}\|$, rendendo del tutto evidente perché il secondo test funzioni estremamente bene.

1.5 Caso della temperatura

Il problema del laboratorio viene implementato con il modello descritto dal seguente sistema: $\begin{cases} (K(u)u')' + f = 0 \\ u(0) = u(1) = 0 \end{cases}$. Spezzo l'intervallo unitario in $0 = x_0 \leqslant ... \leqslant x_j \leqslant ... \leqslant x_d = 1$ separati da una distanza h. Vogliamo discretizzarlo, uno dei metodi più usati è il metodo delle differenze finite è uno dei più usati, l'idea è di prendere $U \in \mathbb{R}^d$ con $U_j = u(x_j)$. Chiaramente, si deve avere $U_1 = U_d = 0$ per le condizioni al bordo. Introduciamo $g(x) = K(u)u'$, quindi la nostra equazione diventa $g'(x) + f(x) = 0$. Valuto in ogni punto $0 = f(x_j) + g'(x_j) \approx f(x_j) + \frac{g(\frac{x_j+x_{j+1}}{2}) - g(\frac{x_j+x_{j-1}}{2})}{h} \approx f(x_j) + \frac{1}{h}(K(u(\frac{x_j+x_{j+1}}{2}))\frac{u(x_{j+1})-u(x_j)}{h} - K(u(\frac{x_j+x_{j-1}}{2}))\frac{u(x_j)-u(x_j}{h}$ A questo punto, $u(x_j) = U_j$ e per i punti medi prendo i punti medi tra gli U_j. Quindi, $0 = f(x_j) + \frac{1}{h}(K(\frac{U_j+U_{j+1}}{2})\frac{U_{j+1}-U_j}{h} + K(\frac{U_j+U_{j-1}}{2})\frac{U_{j-1}-U_j}{h}) = F_j(U)$ e deve valere per $j \in \{2, ..., d-1\}$ mentre $F_1(U) = U_1$ e $F_d(U) = U_d$, quindi mi ritrovo con un problema di ricerca degli zeri $\begin{cases} U \in \mathbb{R}^d \\ F(U) = 0 \end{cases}$ Se vogliamo calcolare F', allora la posso ottenere come $[F'(U)]_{ij} = \frac{\partial}{\partial U_j} F_i'(U)$. Nei casi $i = \{1, d\}$, per definizione si ha $[F'(U)]_{ij} = \delta_{ij}$. Negli altri casi, si ha $[F'(U)]_{ij} = \frac{1}{h}(\frac{1}{2}K'(\frac{U_i+U_{i+1}}{2})\frac{\delta_{ij}+\delta_{i+1,j}}{2}\frac{U_{i+1}-U_i}{h} + K(\frac{U_i+U_{i+1}}{2})\frac{\delta_{i+1,j}-\delta_{ij}}{h} + \frac{1}{2}K'(\frac{U_i+U_{i-1}}{2})\frac{\delta_{ij}+\delta_{i-1,j}}{2}\frac{U_{i-1}-U_i}{h} + K(\frac{U_i+U_{i-1}}{2})\frac{\delta_{i-1,j}-\delta_{ij}}{h})$. Fissato i, posso semplificare i calcoli grazie alle funzioni δ e considerare solo $j \in \{i-1, i, i+1\}$ e quindi la matrice F' è tridiagonale.

2 Massimi e Minimi liberi

2.1 Convessità

Definizione 2.1.1. *Una funzione $f : D \to \mathbb{R}$ è convessa in U se $\forall x, y \in U, \theta \in (0,1)$ si ha:*

$$f(x + \theta(y - x)) = f((1-\theta)x + \theta y) \leqslant \theta f(x) + (1-\theta)f(y)$$

Lemma 2.1.1. *Sia $f : U \to \mathbb{R}$ una funzione regolare e sia $U \subseteq \mathbb{R}^d$ convesso. Allora, la convessità di f è equivalente a $f(y) \geqslant f(x) + f'(x)^t(y-x)$ $\forall x, y \in U$.*
Inoltre, se $f \in \mathscr{C}^2(U)$, la convessità è equivalente a $(y-x)^t f''(x)(y-x) \geqslant 0$ $\forall x, y \in U$.

Proof. (i)
($\Longrightarrow$) $f'(x)^t(y-x) = \lim_{\theta \to 0^+} \frac{f(x+\theta(y-x))-f(x)}{\theta} \leqslant \lim_{\theta \to 0^+} \frac{(1-\theta)f(x)+\theta f(y)-f(x)}{\theta} = -f(x) + f(y) \Longrightarrow f(y) \geqslant f(x) + f'(x)^t(y-x)$.
($\Longleftarrow$) $\forall \hat{x}, \hat{y} \in U, \theta \in (0,1)$ definisco $y = \hat{y}$ e $x = \hat{x} + \theta(\hat{y} - \hat{x})$. Allora, $f(\hat{y}) \geqslant f(\hat{x}+\theta(\hat{y}-\hat{x})) + f'(\hat{x}+\theta(\hat{y}-\hat{x}))^t(\hat{y}-\hat{x})(1-\theta)$. Adesso prendiamo $y = \hat{x}, x = \hat{x} + \theta(\hat{y} - \hat{x})$, quindi $f(\hat{x}) \geqslant f(\hat{x} + \theta(\hat{y} - \hat{x})) + f'(\hat{x} + \theta(\hat{y} - \hat{x}))^t(\hat{y} - \hat{x})(-\theta)$. Moltiplichiamo la prima per θ e la seconda per $1-\theta$, otteniamo: $(1-\theta)f(\hat{x}) + \theta f(\hat{y}) \geqslant f(\hat{x} + \theta(\hat{y} - \hat{x})) = f((1-\theta)\hat{x} + \theta\hat{y})$.
(ii)
($\Longrightarrow$) $f(y) - f(x) - f'(x)^t(y-x) \geqslant 0$ $\forall x, y \in U$. Sia $z = x + \theta(y-x)$ con $\theta \in (0,1)$. $f(z) - f(x) - f'(x)^t(z-x) \geqslant 0 \overset{\text{Taylor in } x}{\Longleftrightarrow} f(x) + f'(x)^t(z-x) + \frac{1}{2}(z-x)^t f''(x)(z-x) + o(\|z-x\|^2) - f(x) - f'(x)^t(z-x) \geqslant 0 \iff \frac{1}{2}\theta^2(y-x)^t f''(x)(y-x) + o(\theta^2\|y-x\|^2) \geqslant 0$.
($\Longleftarrow$) $\forall x, y \in U$, sia $z = x + t(y-x)$ con $t \in (0,1)$ si ha: $f(y) - f(x) - f'(x)^t(y-x) \overset{\text{Taylor in } x}{=} f(x) + f'(x)^t(y-x) + \frac{1}{2}(y-x)^t f''(z)(y-x)(y-x) - f(x) - f'(x)^t(y-x) = \frac{1}{2}(y-x)^t f''(z)(y-x)$. Essendo l'hessiana semidefinita positiva, concludiamo che $\frac{1}{2}(y-x)^t f''(z)(y-x) \geqslant 0$ □

Osservazione 2.1.1. *Nelle stesse ipotesi, f è strettamente convessa è equivalente alla stessa disuguaglianza ma stretta e, se $f \in \mathscr{C}^2(U)$, allora è strettamente convessa se vale la disuguaglianza stretta (ma non vale il viceversa).*

Lemma 2.1.2. *Sia $f : U \to \mathbb{R}$ con U convesso, allora:*
(i) Se f è convessa, tutti i punti di minimo locali sono globali.
(ii) Se f è strettamente convessa, il punto di minimo è unico quando esiste.

Proof. (i) Sia per assurdo $x \in U$ minimo locale ma non globale, quindi $\exists y \in U$ con $f(y) < f(x)$. Allora, $f(x + \theta(y - x)) \leqslant (1 - \theta)f(x) + \theta f(y),\ \theta \in (0, 1) \implies f(x + \theta(y - x)) < (1 - \theta)f(x) + f(x) = f(x)$. Scegliendo θ sufficientemente piccolo, $x + \theta(y - x)$ ricade nell'intorno in cui x è minimo, generando un assurdo.
(ii) Siano per assurdo $x \neq y$ minimi globali, allora $f(x) = f(y) \implies f(\frac{1}{2}x + \frac{1}{2}y) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = f(x) = f(y)$, il che è assurdo. □

La condizione di convessità per una funzione è sufficiente per risolvere il problema tramite l'implementazione di un metodo di ricerca degli zeri su F'.

2.2 Metodi di Discesa

Definizione 2.2.1. *Siano $\{x_k\}_{k\in\mathbb{N}}$ con $F(x_{k+1}) < F(x_k)\ \forall k \in \mathbb{N}$. I metodi di line-search seguono il seguente algoritmo:*

$$\begin{cases} x_0 \in D \\ x_{k+1} = x_k + \alpha_k p_k \end{cases}$$

Dove $p_k \in \mathbb{R}^d$ è la direzione di discesa ($p_k^t F'(x_k) < 0$) e $\alpha_k > 0$ è il passo.

Per quanto riguarda la scelta della lunghezza del passo, le strategie più comuni prevedono l'utilizzo di un passo costante $\alpha_k = \alpha_0 > 0$, oppure l'approccio della ricerca esatta del minimo (exact line search). Quest'ultimo determina il parametro α_k imponendo il seguente criterio:

$$\begin{cases} \alpha_k > 0 \\ F(x_k + \alpha_k p_k) = \min\limits_{\alpha > 0} F(x_k + \alpha p_k) \end{cases}$$

Tuttavia, calcolare esattamente questo minimo globale monodimensionale risulta impraticabile nella maggior parte delle applicazioni reali.

La condizione affinché p_k sia una direzione di discesa può essere formulata algebricamente come $-p_k^t F'(x_k) > 0$. Geometricamente, questo equivale a richiedere che l'angolo θ_k compreso tra la direzione p_k e la direzione di massima discesa $-F'(x_k)$ appartenga all'intervallo $[0, \frac{\pi}{2})$.

Per garantire la convergenza dell'algoritmo, l'obiettivo è assicurare una discesa uniforme. Questo si ottiene imponendo che l'angolo sia strettamente limitato lontano dall'ortogonalità:

$$0 \leqslant \theta_k \leqslant \hat{\theta} < \frac{\pi}{2}$$

Questa limitazione è fondamentale per evitare che l'angolo possa tendere asintoticamente all'estremo $\frac{\pi}{2}$.

2.2.1 Steepest Descent

Definizione 2.2.2. *Il metodo di steepest descent usa come direzione di discesa* $p_k = -F'(x_k)$.

Osserviamo che $p_k^t F'(x_k) = -F'(x_k)^t F'(x_k) = -\|F'(x_k)\|^2 < 0$, dunque è effettivamente un metodo di discesa.

Proposizione 2.2.1 (Convergenza di steepest descent con passo costante)**.** *Sia $F : D \to \mathbb{R}$ una funzione limitata dal basso con derivata F' lipschitziana di costante L e sia $D \subseteq \mathbb{R}^d$ convesso. Supponendo che $0 < \alpha_0 < \frac{1}{L}$, si ha: $\|F'(x_k)\| \to 0$.*

Proof. Sia $\beta_k = -\alpha_0 F'(x_k)$ e sia $x_{k+1} = x_k + \beta_k$ generata seguendo il metodo. Allora: $F(x_{k+1}) = F(x_k + \beta_k) \overset{\text{Taylor}}{=} F(x_k) + F'(z_k)^t \beta_k$, con $z_k = x_k + \theta\beta_k$ per $\theta \in (0,1)$. Continuando la catena di uguaglianze, $F(x_{k+1}) = F(x_k) + F'(x_k)^t\beta_k + (F'(z_k) - F'(x_k))^t\beta_k \leqslant F(x_k) - \alpha_0\|F'(x_k)\|^2 + \|F'(z_k) - F'(x_k)\| \cdot \|\beta_k\| \leqslant F(x_k) - \alpha_0\|F'(x_k)\|^2 + L\theta\|\beta_k\|\|\beta_k\| = F(x_k) + \alpha_0(L\theta\alpha_0 - 1)\|F'(x_k)\|^2 \leqslant F(x_k) + \alpha_0(L\alpha_0 - 1)\|F'(x_k)\|^2$. Per ipotesi, $L\alpha_0 - 1 < 0$, quindi $F(x_{k+1}) \leqslant F(x_k)$. Iterando la maggiorazione, si ottiene $F(x_{k+1}) \leqslant F(x_0) - \alpha_0(1 - L\alpha_0)\sum_{j=0}^{k}\|F'(x_j)\|^2$. Sappiamo che $F(x) \geqslant C$, dunque: $\alpha_0(1 - L\alpha_0)\sum_{j=0}^{k}\|F'(x_j)\|^2 \leqslant F(x_0) - C$. Notiamo che la maggiorazione è indipendente da k, dunque varrà anche per la serie $\sum_{j=0}^{\infty}\|F'(x_j)\|^2 \leqslant \frac{F(x_0)-C}{\alpha_0(1-L\alpha_0)} < \infty$, che risulta convergente. Concludiamo che il termine generale della serie deve tendere a zero. □

Definizione 2.2.3. *Definiamo l'insieme dei punti stazionari.* $S = \{x \in D \mid F'(x) = 0\}$

Corollario 2.2.1.1 (Convergenza ai punti stazionari)**.** *Sia $F : D \to \mathbb{R}$ una funzione regolare e sia $\{x_k\}_{k\in\mathbb{N}} \subset D$ una successione di discesa tale che $\|F'(x_k)\| \to 0$. Sia inoltre $\mathscr{F}_{x_0} = \{x \in D : F(x) \leqslant F(x_0)\}$ chiuso e limitato in $\mathbb{R}^d$. Allora, $x_k \to S$, ovvero $\forall\varepsilon > 0\ \exists\bar{k} \in \mathbb{N}$ tale che $\forall k \geqslant \bar{k}\ \exists y \in S$ con $\|x_k - y\| < \varepsilon$.*

Proof. Sia per assurdo x_k non convergente, allora $\exists\varepsilon > 0$ e una sottosuccessione $\{x_{k_j}\}_{j\in\mathbb{N}}$ tale che $\|x_{k_j} - y\| > \varepsilon\ \forall y \in S$. Sappiamo che

$\mathscr{F}_{x_0}$ è compatto, dunque $\exists\{x_{k_{j_i}}\}_{i\in\mathbb{N}} \to \bar{x}$ e $\lim_{i\to\infty} F'(x_{k_{j_i}}) = F'(\bar{x})$, ma al contempo deve andare a zero, dunque $\bar{x} \in S$. Di conseguenza, definitivamente la sottosuccessione cade in $B(\bar{x}, \varepsilon)$, generando un assurdo. □

È possibile escludere a priori la convergenza della successione verso un punto di massimo locale, poiché, trattandosi di un metodo di discesa, il valore della funzione obiettivo decresce ad ogni iterazione:

$$F(x_{k+1}) < F(x_k)$$

Da un punto di vista euristico, i punti di sella rappresentano posizioni di equilibrio instabile. Di conseguenza, una qualsiasi perturbazione genera una componente lungo una direzione di discesa, allontanando al passo successivo dalla sella.

Sotto opportune ipotesi, la convergenza del metodo risulta essere globale. Infine, qualora la funzione obiettivo risulti convessa, si ha la garanzia teorica che il limite della successione converga verso un punto di minimo globale. Tale punto di minimo è garantito essere rigorosamente unico se la funzione possiede la proprietà di convessità stretta.

2.2.2 Discesa quasi-Newton

Definizione 2.2.4. *Il metodo di discesa quasi-Newton usa come direzione di discesa $p_k = -B_k^{-1}F'(x_k)$, dove $B_k \approx F''(x_k)$.*

Osserviamo che $p_k^t F'(x_k) = -F'(x_k)^t B_k^{-t} F'(x_k)$. Dunque, se B_k è definita positiva, allora p_k è di discesa. Inoltre, per come è definita, B_k è definita positiva se F è strettamente convessa.

2.3 Metodi di scelta del passo

2.3.1 Condizioni di Wolfe

Definiamo la funzione $\varphi : \mathbb{R}_+ \to \mathbb{R}$ tale che $\varphi(\alpha) = F(x_k + \alpha p_k)$. Calcoliamone la derivata: $\varphi'(\alpha) = F'(x_k + \alpha p_k)^t p_k$ e $\varphi'(0) < 0$.

Definizione 2.3.1. *Scelti $0 < c_1 < c_2 < 1$, le condizioni di Wolfe per la scelta di α_k sono verificate se:*
(W1) $\varphi(\alpha_k) \leqslant \varphi(0) + c_1 \alpha_k \varphi'(0)$.
(W2) $\varphi'(\alpha_k) \geqslant c_2 \varphi'(0)$.

È importante osservare che esiste sempre un intorno destro dell'origine in cui la condizione (W1) risulta soddisfatta. Tuttavia, tale regola da sola non è sufficiente a garantire un progresso adeguato dell'algoritmo, poiché ammetterebbe passi arbitrariamente piccoli che renderebbero la convergenza eccessivamente lenta.

La condizione (W2) interviene proprio per evitare passi troppo ridotti, imponendo che la derivata direzionale $\varphi'(\alpha_k)$ subisca un incremento significativo (divenendo meno negativa) rispetto al suo valore iniziale. A conferma di questo scopo, la condizione (W2) non è mai verificata in un intorno destro di 0.

Lemma 2.3.1 (Esistenza di un intervallo che soddisfa le condizioni di Wolfe)**.** *Sia $F : D \to \mathbb{R}$ una funzione regolare limitata dal basso. Allora, data $\{x_k\}_{k\in\mathbb{N}} \subseteq D$ e $p_k \in \mathbb{R}^d$ di discesa, esiste un intervallo aperto I a misura positiva tale per cui le condizioni di Wolfe sono soddisfatte per ogni $\alpha \in I$.*

Proof. La retta di (W1) e φ devono avere intersezione, perché la (W1) ha pendenza negativa e va a meno infinito e φ è limitata, dunque $\exists \hat{\alpha} > 0$ tale che $\varphi(\hat{\alpha}) = \varphi(0) + c_1 \hat{\alpha} \varphi'(0)$ e lo scelgo come la prima intersezione positiva tra la curva e la retta. Per Lagrange, esiste $\bar{\alpha} \in (0, \hat{\alpha})$ tale che $\varphi'(\bar{\alpha}) = \frac{\varphi(\hat{\alpha}) - \varphi(0)}{\hat{\alpha}} = \frac{\varphi(0) + c_1 \hat{\alpha} \varphi'(0) - \varphi(0)}{\hat{\alpha}} = c_1 \varphi'(0)$. Sappiamo che $c_1 < c_2$

e $\varphi'(0) < 0$, dunque $c_1\varphi'(0) > c_2\varphi'(0)$. Ma allora $\varphi(\bar{\alpha}) < \varphi(0) + c_1\bar{\alpha}\varphi'(0)$ e $\varphi'(\bar{\alpha}) > c_2\varphi'(0)$ soddisfa le disuguaglianze strettamente, dunque per permanenza del segno $\exists I \ni \bar{\alpha}$ intorno in cui sono soddisfatte le condizioni di Wolfe. □

Proposizione 2.3.1. *Sia $F : D \to \mathbb{R}$ una funzione limitata dal basso con derivata F' lipschitziana di parametro L. Siano $\{x_k\}_{k\in\mathbb{N}} \subseteq D$ generate con un metodo di line search con p_k di discesa e passo α_k scelto con exact line search o Wolfe. Allora, vale:*

$$\sum_{k=0}^{\infty} \|F'(x_k)\|^2(\cos(\theta_k))^2 < \infty$$

Dove θ_k è l'angolo tra p_k e $-F'(x_k)$ e $\cos(\theta_k) = -\frac{F'(x_k)^t p_k}{\|F'(x_k)\|\|p_k\|}$.

Proof. Per (W2) di Wolfe $\varphi'(\alpha_k) > c_2\varphi'(0)$, ossia $F'(x_k + \alpha_k p_k)^t p_k \geqslant c_2 F'(x_k)^t p_k \implies (c_2 - 1)F'(x_k)^t p_k \leqslant (F'(x_k + \alpha_k p_k) - F'(x_k))^t p_k \leqslant L\|x_k + \alpha_k p_k - x_k\| \cdot \|p_k\| = L\alpha_k\|p_k\|^2 \implies \alpha_k \geqslant \frac{1-c_2}{L\|p_k\|^2}(-F'(x_k)^t p_k) > 0 \implies \alpha_k F'(x_k)^t p_k \leqslant -\frac{1-c_2}{L\|p_k\|^2}(F'(x_k)^t p_k)^2 = -\frac{1-c_2}{L}\frac{(-F'(x_k)^t p_k)^2}{\|p_k\|^2\|F'(x_k)\|^2} \cdot \|F'(x_k)\|^2 = -\frac{1-c_2}{L}(\cos(\theta_k))^2\|F'(x_k)\|^2$.
Per (W1) di Wolfe $F(x_{k+1}) = F(x_k + \alpha_k p_k) \leqslant F(x_k) + c_1\alpha_k F'(x_k)^t p_k \implies F(x_{k+1}) \leqslant F(x_k) - \frac{c_1(1-c_2)}{L}(\cos(\theta_k))^2\|F'(x_k)\|^2 \leqslant ... \leqslant$
$\leqslant F(x_0) - \frac{c_1(1-c_2)}{L}\sum_{j=0}^{k}(\cos(\theta_j))^2\|F'(x_i)\|^2$. Poiché F è limitata dal basso, si ha $\sum_{j=0}^{k}(\cos(\theta_j))^2\|F'(x_j)\|^2 \leqslant \frac{L}{c_1(1-c_2)}(F(x_0) - M)\ \forall k \in \mathbb{N}$.
Se genero le iterate usando exact line search, posso affermare che $F(x_{k+1}) \leqslant F(x_{k+1}^{wolfe})$, dunque la tesi segue dal risultato ottenuto poco sopra. □

Corollario 2.3.1.1. *Sia $F : D \to \mathbb{R}$ una funzione limitata dal basso con derivata F' Lipschitziana di parametro L. Siano $\{x_k\}_{k\in\mathbb{N}} \subseteq D$*

generate con un metodo di line search con p_k di uniforme discesa e passo α_k scelto con exact line search o Wolfe. Allora, vale che $F'(x_k) \to 0$.

Proof. Dato che p_k è di uniforme discesa, si ha che $0 \leqslant \theta_k \leqslant \hat{\theta} < \frac{\pi}{2}\ \forall k \in \mathbb{N}$. Quindi, $\cos(\theta_k) \geqslant \cos(\hat{\theta}) > 0\ \forall k \in \mathbb{N} \Longrightarrow \infty > \sum_{k=0}^{\infty} (\cos(\theta_k))^2 \|F'(x_k)\|^2 \geqslant (\cos(\hat{\theta}))^2 \sum_{k=0}^{\infty} \|F'(x_k)\|^2$. Poiché la serie converge, il termine generale tende a zero. □

Corollario 2.3.1.2. *Sia $F : D \to \mathbb{R}$ una funzione limitata dal basso con derivata F' lipschitziana di parametro L. Siano $\{x_k\}_{k\in\mathbb{N}} \subseteq D$ generate con un metodo di line search con p_k di uniforme discesa e passo α_k scelto con exact line search o Wolfe. Se $\mathscr{F}_{x_0}$ è compatto, si ha: $x_k \to S$.*

Osservazione 2.3.1. *Se $A \in \mathbb{R}^{d\times d}$ è simmetrica e definita positiva, allora ammette una radice quadrata.*

Proof. Per il teorema spettrale, sappiamo che $A = O^t D O$ è diagonalizzabile. Definiamo $\sqrt{A} = O^t \sqrt{D} O$, allora $\sqrt{A}\sqrt{A} = O^t \sqrt{D}\sqrt{D} O = O^t D O = A$. □

Lemma 2.3.2. *Sia $F : D \to \mathbb{R}$ una funzione differenziabile e consideriamo un metodo iterativo la cui direzione di ricerca sia definita dal sistema lineare $B_k p_k = -F'(x_k)$. Se la matrice $B_k \in \mathbb{R}^{d\times d}$ è simmetrica e definita positiva, allora p_k è una direzione di discesa. Se inoltre esiste una costante $C > 0$ tale per cui il numero di condizionamento in norma (spettrale) si mantenga uniformemente limitato per ogni iterazione k, ovvero $\|B_k\|\|B_k^{-1}\| \leqslant C$, allora le direzioni p_k sono di uniforme discesa.*

Proof. Per quanto riguarda la discesa: $\cos(\theta_k) = -\frac{F'(x_k)^t p_k}{\|F'(x_k)\| \cdot \|p_k\|} = \frac{p_k^t B_k p_k}{\|F'(x_k)\| \cdot \|p_k\|} > 0$.
Per quanto riguarda l'uniforme discesa:
$\cos(\theta_k) = \frac{p_k^t B_k p_k}{\|F'(x_k)\| \cdot \|p_k\|} = \frac{(\sqrt{B_k} p_k)^t (\sqrt{B_k} p_k)}{\|\sqrt{B_k}\sqrt{B_k} p_k\| \cdot \|B_k^{-\frac{1}{2}} \sqrt{B_k} p_k\|} \overset{w=\sqrt{B_k} p_k}{=} \frac{w^t w}{\|\sqrt{B_k} w\| \cdot \|B_k^{-\frac{1}{2}} w\|} =$
$\frac{\|w\|^2}{(w^t B_k w)^{\frac{1}{2}} (w^t B_k^{-1} w)^{\frac{1}{2}}} \geqslant \frac{1}{(\|B_k\| \cdot \|B_k^{-1}\|)^{\frac{1}{2}}} \geqslant \frac{1}{\sqrt{C}} > 0.$ □

2.3.2 Backtracking

ia $x_k \in D$ un'iterata prodotta da un metodo di discesa, $p_k \in \mathbb{R}^d$ la relativa direzione di discesa e $\varphi(\alpha)$ la restrizione monodimensionale della funzione obiettivo. La strategia di backtracking (o ricerca all'indietro) richiede l'introduzione di due parametri fondamentali:

- Un passo iniziale $\alpha_0 > 0$, che rappresenta una stima ottimistica della lunghezza del passo (spesso scelto pari a 1, in particolar modo nei metodi di Newton e quasi-Newton).

- Un fattore di contrazione $\beta \in (0, 1)$, che determina il tasso di riduzione geometrica del passo qualora questo non risulti accettabile.

Il criterio di accettazione per il passo si basa unicamente sulla condizione di decrescita sufficiente di Wolfe (W1). È garantito che la procedura termini in un numero finito di iterazioni, poiché la condizione (W1) è sempre soddisfatta in un intorno destro dell'origine.

L'algoritmo procede operativamente come segue: si inizializza il passo di prova ponendo $\alpha = \alpha_0$. Se il valore attuale di α soddisfa la condizione (W1), la procedura si arresta e il passo viene accettato. In caso contrario, il passo viene ridotto moltiplicandolo per il fattore di contrazione, aggiornandolo tramite la seguente assegnazione:

$$\alpha = \beta\alpha$$

e si ripete la verifica.

La peculiarità di questa tecnica risiede nel fatto che non è necessario imporre esplicitamente la condizione (W2). Il meccanismo stesso di ricerca all'indietro, partendo da un valore ampio e riducendolo progressivamente solo finché la (W1) non viene soddisfatta, assicura intrinsecamente che il passo finale accettato non risulti eccessivamente piccolo, preservando così l'efficienza della convergenza.

Proposizione 2.3.2. *Sia $F : D \to \mathbb{R}$ una funzione con derivata F' lipschitziana di costante L e sia F limitata dal basso. Sia $\{x_k\} \subset D$ una successione di iterate generata da un metodo di line search con direzioni di discesa $p_k = -B_k^{-1}F'(x_k)$ e passo α_k scelto con backtracking. Se $\|B_k\| \leqslant M \ \forall k \in \mathbb{N}$, allora risulta: $\sum_{k=0}^{\infty} \cos(\theta_k)^2 \|F'(x_k)\|^2 < \infty$.*

Proof. Dividiamo in due casi: se α_0 non soddisfa (W1) o se lo soddisfa. Nel primo caso, chiamo α' il più piccolo punto di intersezione positivo tra la retta e la funzione. Sappiamo che $\beta^{-1}\alpha_k$ non soddisfa (W1), altrimenti avremmo scelto quello, dunque $\beta^{-1}\alpha_k > \alpha'$. Uso Lagrange su φ in $[0, \alpha']$ e chiamo $\bar{\alpha}$ il punto ottenuto, dunque $\varphi'(\bar{\alpha}) = \frac{\varphi(\alpha')-\varphi(0)}{\alpha'} = \frac{\varphi(0)+c_1\alpha'\varphi'(0)-\varphi(0)}{\alpha'} = c_1\varphi'(0) \iff \varphi'(\bar{\alpha}) - \varphi'(0) = (c_1 - 1)\varphi'(0)$, so che $\varphi'(\bar{\alpha}) - \varphi'(0) = [F'(x_k + \bar{\alpha}p_k) - F'(x_k)]^t p_k \leqslant L\|x_k + \bar{\alpha}p_k - x_k\| \cdot \|p_k\| = L\bar{\alpha}\|p_k\|^2 \iff \bar{\alpha} \geqslant \frac{c_1-1}{L}\frac{\varphi'(0)}{\|p_k\|^2} > 0$. Dunque, $\beta^{-1}\alpha_k \geqslant \alpha' \geqslant \bar{\alpha} \geqslant \frac{c_1-1}{L}\frac{\varphi'(0)}{\|p_k\|^2} \iff \alpha_k \geqslant \beta\frac{c_1-1}{L}\frac{\varphi'(0)}{\|p_k\|^2}$. A questo punto, $\alpha_k F'(x_k)^t p_k \leqslant \frac{\beta(c_1-1)}{L}\frac{(F'(x_k)^t p_k)^2}{\|p_k\|^2} = \frac{\beta(c_1-1)}{L}\frac{(-F'(x_k)^t p_k)^2}{\|p_k\|^2\|F'(x_k)\|^2}\|F'(x_k)\|^2 = -\frac{\beta(1-c_1)}{L}\cos(\theta_k)^2\|F'(x_k)\|^2$.
Se invece $\alpha_k = \alpha_0 > 0$ soddisfa (W1), $\alpha_k F'(x_k)^t p_k = \alpha_0 F'(x_k)^t p_k = -\alpha_0 \frac{-F'(x_k)^t p_k}{\|F'(x_k)\|\cdot\|p_k\|}\|f'(x_k)\| \cdot \|p_k\|$. Ricordando che $p_k = -B_k^{-1}F'(x_k)$, scriviamo $\|F'(x_k)\| \leqslant \|B_k\|\|p_k\| \leqslant M\|p_k\| \iff \|p_k\| \geqslant \frac{1}{M}\|F'(x_k)\|$ e usiamo nell'espressione precedente $\alpha_k f'(x_k)^t p_k \leqslant -\alpha_0 \cos(\theta_k)\|F'(x_k)\| \cdot \frac{\|F'(x_k)\|}{M} \leqslant -\frac{\alpha_0}{M}\cos(\theta_k)^2\|F'(x_k)\|^2$.

Unendo i casi, $\alpha_k F'(x_k)^t p_k \leqslant -\min\{\frac{\beta(1-c_1)}{L}, \frac{\alpha_0}{M}\}\cos(\theta_k)^2\|F'(x_k)\|^2$. Usiamo la (W1), $F(x_{k+1}) = F(x_k + \alpha_k p_k) \leqslant F(x_k) + c_1\alpha_k F'(x_k)^t p_k \leqslant F(x_k) - c_1 m\cos(\theta_k)^2\|F'(x_k)\|^2 \leqslant F(x_0) - c_1 m\sum_{j=0}^{k}\cos(\theta_j)^2\|F'(x_j)\|^2 \iff \sum_{j=0}^{k}\cos(\theta_j)^2\|F'(x_j)\|^2 \leqslant \frac{F(x_0)-R}{c_1 m}$ e vale per ogni $k \in \mathbb{N}$. □

Osservazione 2.3.2. *Scegliendo la matrice identità per B_k, oppure adottando un metodo di discesa di tipo quasi-Newton sotto opportune ipotesi di regolarità, le condizioni sulla limitatezza della norma risultano verificate.*

Corollario 2.3.2.1. *Nelle ipotesi della Proposizione* 2.3.2*, se le p_k sono di uniforme discesa, allora $\|F'(x_k)\| \to 0$.*

Corollario 2.3.2.2. *Nelle ipotesi del Corollario* 2.3.2.1*, se $\mathscr{F}_{x_0}$ è compatto, allora $x_k \to S$.*

2.4 Metodo di Newton

Definizione 2.4.1. *Il metodo di Newton usa come direzione di discesa $p_k = -[F''(x_k)]^{-1}F'(x_k)$.*

Nel corso di un laboratorio, abbiamo osservato che la direzione di Newton non coincide con la direzione di steepest descent. Dunque, non è garantito che sia un metodo di discesa se l'hessiana non è definita positiva.

Esempio 2.4.1. *Consideriamo $F(x,y) = \frac{1}{2}(\varepsilon x^2 + y^2)$, con $0 < \varepsilon \ll 1$. Lo steepest descent ci potrebbe mettere molto tempo a convergere. Notiamo che l'hessiana è definita positiva e, facendo i calcoli, Newton trova la direzione migliore possibile e punta direttamente al minimo globale, mentre lo steepest descent farà uno "zig-zag" infinito a causa dell'eccentricità delle curve di livello.*

Lemma 2.4.1. *Sia $F \in \mathscr{C}^2(D)$ e sia $\bar{x} \in D$ un punto di minimo in cui $F''(\bar{x})$ è definita positiva. Si consideri la successione di iterate $\{x_k\}_{k=1}^{\infty} \subset D$ generate con il metodo di Newton. Se $x_k \to \bar{x}$ e $c_1 \in (0, \frac{1}{2})$, allora il passo $\alpha_k = 1$ soddisfa definitivamente le condizioni di Wolfe.*

Proof. Sappiamo che $F''(\bar{x})$ è definita positiva, dunque vale la condizione di Rayleigh: $\exists \eta > 0$ tale che $v^t F''(\bar{x}) v \geqslant \eta \|v\|^2 \ \forall v \in \mathbb{R}^d$. Quindi, per permanenza del segno, deve esistere un intorno B di $\bar{x}$ tale che $v^t F''(x) v \geqslant \frac{\eta}{2}\|v\|^2 \ \forall x \in B$.
(W1) $F(x_k+p_k) = F(x_k)+F'(x_k)^t p_k+\frac{1}{2}p_k^t F''(x_k)p_k+o(\|p_k\|^2) \leqslant F(x_k)+c_1 F'(x_k)^t p_k \iff (1-c_1)F'(x_k)^t p_k + \frac{1}{2}p_k^t F''(x_k)^t p_k + o(\|p_k\|^2) \leqslant 0 \iff (c_1 - \frac{1}{2})p_k^t F''(x_k)p_k + o(\|p_k\|^2) \leqslant 0$. Ricordiamo che $x_k \to \bar{x}$ per ipotesi, perciò definitivamente $x_k \in B$ e quindi $(c_1 - \frac{1}{2})p_k^t F''(x_k)p_k + o(\|p_k\|^2) \leqslant (c_1 - \frac{1}{2})\frac{\eta}{2}\|p_k\|^2 + o(\|p_k\|^2) \overset{c_1 \in (0,\frac{1}{2})}{\leqslant} 0$.
(W2) $F'(x_k+p_k)^t p_k \geqslant c_2 F'(x_k)^t p_k \iff (F'(x_k)+F''(x_k)p_k+o(\|p_k\|))^t p_k \geqslant c_2 F'(x_k)^t p_k \iff (1-c_2)F'(x_k)^t p_k + p_k^t F''(x_k)p_k + o(\|p_k\|^2) \geqslant 0 \iff (1-c_2)F'(x_k)^t p_k+p_k^t F''(x_k)p_k+o(\|p_k\|^2) \geqslant 0 \iff (1-c_2)(-F''(x_k)p_k)^t + p_k^t F''(x_k)p_k + o(\|p_k\|^2) \geqslant 0 \iff c_2 p_k^t F''(x_k)p_k + o(\|p_k\|^2) \geqslant 0$. Come prima, ricordiamo che $x_k \to \bar{x}$ per ipotesi, perciò definitivamente $x_k \in B$ e quindi $c_2 p_k^t F''(x_k)p_k + o(\|p_k\|^2) \geqslant \frac{c_2}{2}\eta\|p_k\|^2 + o(\|p_k\|^2) \geqslant 0$. □

Proposizione 2.4.1. *Sia $F \in \mathscr{C}^2(D)$ una funzione con derivata seconda F'' lipschitziana di costante L e sia $\bar{x} \in D$ un punto di minimo in cui $F''(\bar{x}) \in GL(d, \mathbb{R})$ è definita positiva. Si consideri la successione di iterate $\{x_k\}_{k=1}^{\infty} \subset D$ generate con il metodo di Newton. Se $x_k \to \bar{x}$, $c_1 \in (0, \frac{1}{2})$ e il passo α_k è calcolato con backtracking scegliendo $c_1 \in (0, \frac{1}{2})$ e passo iniziale pari a 1 (oppure mediante un metodo basato sulle condizioni di Wolfe che abbia come valore iniziale $\alpha_k = 1$), allora la successione ha convergenza quadratica.*

Proof.

$$\begin{cases} x_0 \in D \\ x_{k+1} = x_k - \alpha_k F''(x_k)^{-1} F'(x_k) \end{cases}$$

Dal Lemma 2.4.1, sappiamo che $\forall k \geqslant \bar{k}$, la scelta di $\alpha_k = 1$ funziona e quindi il backtracking lo sceglierà definitivamente. Quindi, definitivamente il metodo diventa

$$\begin{cases} x_0 \in D \\ x_{k+1} = x_k - F''(x_k)^{-1} F'(x_k) \end{cases}$$

che coincide con il metodo di Newton per la ricerca di zeri applicata alla funzione F'. Dato che sono verificare le ipotesi della Proposizione 1.3.1, concludiamo che la convergenza è quadratica. □

Osservazione 2.4.1. *Sebbene lo steepest descent garantisca una direzione di discesa ad ogni passo, Newton offre una convergenza sensibilmente più rapida (quadratica in un intorno del minimo, assumendo F strettamente convessa e l'hessiana lipschitziana). Il prezzo da pagare è un costo computazionale per iterazione decisamente superiore, dovuto al calcolo e all'inversione della matrice hessiana, e una minor robustezza globale (poiché la direzione di Newton è di discesa solo se l'hessiana è definita positiva).*

Osservazione 2.4.2. *Dalla Proposizione* 2.4.1*, possiamo subito stabilire che $\alpha_0 = 1$ è la scelta migliore sempre. Tale valore non è in generale adeguato per lo steepest descent o nelle fasi iniziali di Newton lontano dal minimo. In tali contesti, si ricorre spesso a strategie euristiche per inizializzare il passo α_k:*
(i) $\alpha_k = \alpha_{k-1} \frac{F'(x_{k-1})^t p_{k-1}}{F'(x_k)^t p_k}$, basata sul mantenimento della variazione del gradiente direzionale.
(ii) $\alpha_k = \frac{F(x_k) - F(x_{k-1})}{2F'(x_k)^t p_k}$, basata sull'approssimazione quadratica del decremento di funzione.

2.4.1 Metodo di Newton con correzione della matrice hessiana

L'idea dietro i seguenti metodi è di cercare una matrice E_k che modifichi la direzione di discesa come $B_k = F''(x_k) + E_k$, con l'obiettivo di ottenere risultati migliori rispetto al metodo di Newton. Poniamo le seguenti richieste:
(i) B_k è definita positiva.
(ii) Se $F''(x_k)$ è definita positiva, allora $E_k = 0$.
(iii) E_k deve essere "piccola".
(iv) $\|B_k\|\|B_k^{-1}\| \leqslant C \ \forall k \in \mathbb{N}$.

Osservazione 2.4.3. *Sia $\tau \in \mathbb{R}$, $A \in \mathbb{R}^{d\times d}$ e $\lambda \in \mathbb{R}$ un autovalore di A con autovettore v, allora $(A + \tau I)v = Av + \tau v = \lambda v + \tau v = (\lambda + \tau)v$.*

Definizione 2.4.2. *Il primo metodo di modifica (di Levenberg-Marquardt) usa $B_k = F''(x_k) + \tau_k I$, dove $\tau_k = \max\{0, \rho - \lambda_{min}(F''(x_k))\}$ è scelto in modo che il più piccolo autovalore sia positivo e $\rho \sim 10^{-3}$.*

Definizione 2.4.3. *Il secondo metodo di modifica usa $B_k = F''(x_k) + \tau_k I$ e la scelta di τ_k si basa sul seguente algoritmo:*

(i) Se $\min_{i\in\{1,\dots,d\}} [F''(x_k)]_{ii} > 0$, allora si inizializza $\tau_k = 0$.

(i.1) Altrimenti, si pone $\tau_k = \rho - \min_{i\in\{1,\dots,d\}} [F''(x_k)]_{ii}$.

(ii) Si tenta di calcolare la fattorizzazione di Cholesky della matrice B_k.

(ii.1) Se la decomposizione ha successo (il che garantisce che B_k sia definita positiva), l'algoritmo termina e si adotta l'attuale matrice B_k.

(ii.2) Altrimenti, si aggiorna il parametro ponendo $\tau_k = \max\{\rho, 2\tau_k\}$ e si ritorna al passo (ii).

Definizione 2.4.4. *Il terzo metodo di modifica (di Nocedal) usa* $B_k = F''(x_k) + \tau_k I$ *e trova una Cholesky modificata.*

Osservazione 2.4.4. *Il primo metodo è molto costoso, ma impiega meno passaggi a garantire che gli autovalori diventino positivi.*
Il secondo metodo è meno costoso perché la decomposizione poi viene usata per trovare p_k*, ma potrebbe impiegare più tempo.*
Il terzo metodo è il più pratico ma non verrà trattato in questo corso.

2.5 Ricerca degli zeri tramite minimi

Sia $F : D \to \mathbb{R}^d$, definiamo la funzione $f : D \to \mathbb{R}$ come $f(x) = \|F(x)\|$. In questo modo, il problema della ricerca degli zeri di F può essere riformulato come un problema di minimizzazione per la funzione f. Questa scelta è motivata dal vantaggio di poter sfruttare le proprietà di convergenza globale tipiche dei metodi di ottimizzazione. Scegliendo come direzione di ricerca il passo di Newton $p_k = -[F'(x_k)]^{-1}F(x_k)$, occorre verificare che questa sia effettivamente una direzione di discesa. Calcolando il gradiente di $f(x)$ si ottiene:

$$f'(x) = \frac{d}{dx}(F(x)^t F(x))^{\frac{1}{2}} = \frac{2F'(x)^t F(x)}{2(F(x)^t F(x))^{\frac{1}{2}}} = \frac{F'(x)^t F(x)}{\|F(x)\|}$$

Di conseguenza, il prodotto scalare tra il gradiente e la direzione p_k risulta:

$$f'(x_k)^t p_k = -\frac{F(x_k)^t F'(x_k)}{\|F(x_k)\|}[F'(x_k)]^{-1}F(x_k) = -\frac{F(x_k)^t F(x_k)}{\|F(x_k)\|} = -\|F(x_k)\| < 0$$

Essendo la quantità strettamente negativa (assumendo $F(x_k) \neq 0$), la direzione trovata è di discesa. Per la scelta della lunghezza del passo, si utilizza la tecnica di backtracking con passo iniziale $\alpha_0 = 1$ e parametri $\beta \in (0,1)$, $c_1 \in (0,1)$. La (W1) diventa:

$$\|F(x_k + \alpha_k p_k)\| \leqslant \|F(x_k)\| - c_1\alpha_k\|F(x_k)\| = (1 - c_1\alpha_k)\|F(x_k)\|$$

Definizione 2.5.1. *L'algoritmo di Armijo per la ricerca degli zeri di una funzione (o metodo di Newton globalizzato tramite line search di Armijo) procede secondo le seguenti fasi:*

(0) Si scelgono il passo di prova iniziale $\alpha_0 = 1$*, i parametri* $\beta \in (0,1)$ *e* $c_1 \in (0,1)$*, un punto di partenza* $x_0 \in D$ *e una tolleranza* $TOL > 0$*. Si pone* $k = 0$*.*

(i) Si determina la direzione di Newton ponendo:

$$p_k = -[F'(x_k)]^{-1} F(x_k)$$

(ii) Si pone $\alpha_k = \alpha_0$*.*

(ii.1) Se risulta soddisfatta la disuguaglianza:

$$\|F(x_k + \alpha_k p_k)\| \leqslant (1 - c_1 \alpha_k) \|F(x_k)\|$$

si accetta il passo e si procede alla fase (iii).

(ii.2) Altrimenti, si aggiorna $\alpha_k = \beta \alpha_k$ *e si reitera il controllo al passo (ii.1).*

(iii) Si calcola l'iterata:

$$x_{k+1} = x_k + \alpha_k p_k$$

(iv) Si calcola la norma del residuo.

(iv.1) Se $\|F(x_{k+1})\| \leqslant TOL$*, l'algoritmo termina.*

(iv.2) Altrimenti, si torna a (i).

Teorema 2.5.1. *Nelle ipotesi della Proposizione* 1.3.1*, l'algoritmo di Armijo ha convergenza quadratica se il passo iniziale è* $\alpha_k = 1$*.*

Proof. Assumendo l'ipotesi di convergenza, si può applicare definitivamente il Lemma 1.3.2. Sviluppando i termini, si ottiene la seguente catena di disuguaglianze: $\|F(x_{k+1})\| \leqslant 2\|F'(\bar{x})\| \cdot \|x_{k+1} - \bar{x}\| \leqslant 2\|F'(\bar{x})\| \cdot C\|x_k - \bar{x}\| \cdot \|x_k - \bar{x}\| \leqslant 2\|F'(\bar{x})\| \cdot C \cdot 2\|[F'(\bar{x})]^{-1}\| \cdot \|x_k - \bar{x}\| \cdot \|F(x_k)\| \leqslant [4C\|F'(\bar{x})\| \cdot \|[F'(\bar{x})]^{-1}\|] \cdot \|F(x_k)\| \cdot \|x_k - \bar{x}\|$. Il termine tra parentesi quadre è una costante, mentre l'errore $\|x_k - \bar{x}\|$ tende a zero perché la successione converge. Quindi, definitivamente questo prodotto sarà strettamente minore di $1 - c_1$. Sostituendo questa maggiorazione nella catena di disuguaglianze:

$$\|F(x_{k+1})\| < (1 - c_1)\|F(x_k)\|$$

Comportandosi in modo identico al metodo di Newton, l'algoritmo garantisce la convergenza quadratica. □

2.6 Caso dei solidi di rotazione

Consideriamo l'intervallo $[-1, 1]$ nel piano xy e una funzione $0 < u \in \mathscr{C}^1(-1, 1)$ tale che $u(-1) = a$ e $u(1) = b$. Costruiamo la superficie di rotazione ottenuta dalla rotazione attorno all'asse x, ci chiediamo quale sia la superficie di estensione minima. Definiamo $V = \{u \in \mathscr{C}^1(-1, 1) \mid u(-1) = a > 0, u(1) = b > 0\}$ e consideriamo l'associazione $u \mapsto S(u)$ ="estensione della superficie ottenuta da u". Il problema è di minimizzare $\{S(u)\}_{u \in V}$. Parametrizzo usando $x \in [-1, 1]$ e $\theta \in [0, 2\pi)$, ovvero $s : [-1, 1] \times [0, 2\pi) \to \mathbb{R}^3 : \begin{pmatrix} x \\ u(x)\cos(\theta) \\ u(x)\sin(\theta) \end{pmatrix}$. Quindi, $S(u) = \int_0^{2\pi} \int_{-1}^{1} \|s_x \times s_\theta\| \, dx d\theta$, dove $s_x = \begin{pmatrix} 1 \\ u'(x)\cos(\theta) \\ u'(x)\sin(\theta) \end{pmatrix}$ e $s_\theta = \begin{pmatrix} 0 \\ -u(x)\sin(\theta) \\ u(x)\cos(\theta) \end{pmatrix}$ sono i vettori tangenti. Calcolandolo, si ha

$S(u) = 2\pi \int_{-1}^{1} u(x)\sqrt{1+u'(x)^2}dx$.
Partiziono l'intervallo in $d+2$ punti, usando $h = \frac{2}{d+1}$ e uso una spline di ordine 1, quindi considero $V_d = \{v \in \mathscr{C}^1([-1,1]) \mid v_{x_j,x_{j+1}} \in \mathbb{P}_1(x_j, x_{j+1})\}$ è isomorfo a $\mathbb{R}^d$ nel senso che le valutazioni nei d nodi interni sono un insieme di gradi di libertà per questo spazio. Restringendo il problema a V_d, diventa discreto e al crescere di d diventerà più vicino alla realtà. Chiamo $U_j = u_d(x_j)$, allora si ha $S(u_d) = 2\pi \int_{-1}^{1} u_d(x)\sqrt{1+u_d'(x)^2}\,dx = 2\pi \sum_{j=0}^{d} \int_{x_j}^{x_{j+1}} u_d(x)\sqrt{1+u_d'(x)^2}\,dx = 2\pi \sum_{j=0}^{d} \int_{x_j}^{x_{j+1}} u_d(x)\sqrt{1$
$2\pi \sum_{j=0}^{d} \sqrt{1+(\frac{U_{j+1}-U_j}{h})^2} \int_{x_j}^{x_{j+1}} u_d(x)\,dx = \pi \sum_{j=0}^{d} \sqrt{1+(\frac{U_{j+1}-U_j}{h})^2}(U_j+U_{j+1})h =$
$\pi \sum_{j=0}^{d} \sqrt{h^2+(U_{j+1}-U_j)^2}(U_j+U_{j+1}) = f(U)$.
Il problema è diventato $\begin{cases} U \in \mathbb{R}^d \\ f(U) = \min\limits_{V\in\mathbb{R}^d} f(V) \end{cases}$. Calcoliamo la derivata prima $f'(U)_i = \pi \sum_{j=0}^{d} (\sqrt{h^2+(U_{j+1}-U_j)^2}(\delta_{i,j+1}+\delta_{ij}) + \frac{(U_j+U_{j+1})(U_{j+1}-U_j)(\delta_{i,j+1}-\delta_{ij})}{\sqrt{h^2+(U_{j+1}-U_j)^2}})$.
Nell'implementazione, notiamo che non serve calcolare tutta la somma ma solo su $j \in \{i-1, i\}$.
L'algoritmo è dunque:
(0) Scelgo parametri $\alpha_0 > 0, c_1 \in (0,1), \beta \in (0,1), 0 < tol \ll 1, x_0 \in D$ e definisco la B_k.
(1) Trovo p_k risolvendo $B_k p_k = -f'(x_k)$.
(2) Trovo l'α_k, inizio impostando $\alpha_k = \alpha_0$.
(2a) Se $f(x_k + \alpha_k p_k) \leqslant f(x_k) + c_1 \alpha_k f'(x_k)^t p_k$, allora uso α_k.
(2b) In caso contrario, $\alpha_k = \beta\alpha_k$ e ritorno a (2a).
(3) Calcolo $x_{k+1} = x_k + \alpha_k p_k$.
(4) Se $\|f'(x_{k+1})\| >$ TOL, torno a 1, altrimenti esco.

3 Massimi e Minimi vincolati

3.1 Introduzione all'ottimizzazione vincolata

Definizione 3.1.1. *Sia $F : U \to \mathbb{R}$ con $U \subseteq \mathbb{R}^d$ chiuso. Il problema di ricerca di estremi vincolati è la risoluzione del sistema* $\begin{cases} \bar{x} \in U \\ F(\bar{x}) = \min\limits_{x \in U} F(x) \end{cases}$

Osservazione 3.1.1. *Siano $\{\varphi_i\}_{i \in \{1,\dots,n\}} \subset \mathscr{C}^0(\mathbb{R}^d)$ i vincoli, allora:*
(i) $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0 \ \forall i \in \{1, ..., n\}\} \subset \mathbb{R}^d$ è chiuso.
(ii) Se le φ_i sono convesse, allora U è convesso.
(iii) Se le φ_i sono regolari, non è detto che ∂U sia regolare.

Da qui in avanti, supponiamo U chiuso a meno che non sia specificato altrimenti.

Definizione 3.1.2. *Nel caso descritto nell'Osservazione* 3.1.1*, si parla di ottimizzazione nonlineare. Se i vincoli sono convessi, si parla di ottimizzazione convessa. Se i vincoli sono affini e $F(x) = \frac{1}{2}x^tAx + b^tx + c$ con $A \in \mathbb{R}^{d \times d}$ simmetrica e definita positiva, si parla di ottimizzazione quadratica. Se $A = 0$, si parla di ottimizzazione lineare.*

Lemma 3.1.1. *Sia U convesso e $F \in \mathscr{C}^1(U)$. Allora, f è convessa se e solo se $(F'(y) - F'(x))^t(y - x) \geqslant 0 \ \forall x, y \in U$.*

Proof. E' equivalente a dimostrare che $F(y) \geqslant F(x) + F'(x)^t(y - x) \iff (F'(y) - F'(x))^t(y - x) \geqslant 0$.
($\Longrightarrow$) Per convessità, $F(x) \geqslant F(y) + F'(y)^t(x - y)$ e $F(y) \geqslant F(x) + F'(x)^t(y - x) \Longrightarrow F(x) + F(y) \geqslant F(x) + F(y) + F'(x)^t(y - x) + F'(y)^t(x - y) \iff (F'(y) - F'(x))^t(y - x) \geqslant 0$.
($\Longleftarrow$) Prendendo lo sviluppo di Taylor con $z = x + \theta(y - x)$: $F(y) = F(x) + F'(z)^t(y - x)$. Allora, $F(y) = F(x) + \frac{1}{\theta}F'(z)^t(z - x) \geqslant F(x) + \frac{1}{\theta}F'(x)^t(z - x) = F(x) + F'(x)^t(y - x)$. □

Lemma 3.1.2. *Sia U convesso, $F \in \mathscr{C}^1(U)$ e $\bar{x} \in U$ punto di minimo locale per F. Allora, $F'(\bar{x})^t(y - \bar{x}) \geqslant 0 \ \forall y \in U$. Se F è convessa, vale il viceversa.*

Proof. Se $\bar{x}$ è minimo, allora $F'(\bar{x})^t(y - \bar{x}) = \lim_{\theta \to 0^+} \frac{F(\bar{x}+\theta(y-\bar{x}))-F(\bar{x})}{\theta} \geqslant 0$. Se F è convessa, $F(y) \geqslant F(\bar{x}) + F'(\bar{x})^t(y - \bar{x}) \ \forall y \in U$, dunque $F(y) \geqslant F(\bar{x})$. □

Definizione 3.1.3. *Una funzione $F : U \to \mathbb{R}$ si dice coerciva se $\lim_{\|x\| \to \infty} F(x) = \infty$.*

Osservazione 3.1.2. *Se U è compatto e F è continua su U, allora F ammette minimo in U.*
Se U è chiuso e F è continua su U e coerciva, allora ammette minimo in U.

Teorema 3.1.1 (Proiezione nei chiusi)**.** *Sia U chiuso, convesso e non vuoto.*
(i) $\forall w \in \mathbb{R}^d \ \exists! p_w \in U$ tale che $\|w - p_w\| \leqslant \|w - u\| \ \forall u \in U$.
(ii) p_w è caratterizzato dalla proprietà: $(w - p_w)^t(u - p_w) \leqslant 0 \ \forall u \in U$.
(iii) $\|p_w - p_u\| \leqslant \|u - w\| \ \forall u, w \in \mathbb{R}^d$.

Proof. Considero la funzione $F(u) = \|u-w\|^2$, dunque $F'(u) = 2(u-w)$ e $F''(u) = 2I$.
(i) Si tratta di risolvere il problema di minimo: $\begin{cases} p_w \in U \\ F(p_w) = \min_{u \in U} F(u) \end{cases}$ ma U è chiuso e F coerciva, dunque ammette minimo. Inoltre, F'' è definita positiva e dunque tale minimo è unico.
(ii) Se F è convessa, per Lemma 3.1.2 p_w è minimo se e solo se $F'(p_w)^t(u - p_w) \geqslant 0 \ \forall u \in U \iff 2(p_w - w)^t(u - p_w) \geqslant 0 \iff (w - p_w)^t(u - p_w) \leqslant 0$.
(iii) Siano $u, w \in \mathbb{R}^d$ e siano $p_u, p_w \in U$ le loro proiezioni. Usando (ii)

su entrambi, si ha:

$$(w - p_w)^t(p_u - p_w) \leqslant 0$$
$$(u - p_u)^t(p_w - p_u) \leqslant 0 \Longrightarrow (p_u - u)^t(p_u - p_w) \leqslant 0$$

Sommiamo le due disuguaglianze e otteniamo: $(w - u + p_u - p_w)^t(p_u - p_w) \leqslant 0 \iff (w-u)^t(p_u - p_w) + \|p_u - p_w\|^2 \leqslant 0 \iff \|p_w - p_u\|^2 \leqslant (w-u)^t(p_w - p_u) \iff \|p_w - p_u\|^2 \leqslant \|w-u\| \cdot \|p_w - p_u\| \iff \|p_w - p_u\| \leqslant \|w - u\|$. □

3.2 Metodo del gradiente con proiezione

Sia $F : U \to \mathbb{R}$ una funzione convessa con $U \subseteq \mathbb{R}^d$ convesso, dal Lemma 3.1.2 sappiamo che $F'(\bar{x})^t(y - \bar{x}) \geqslant 0 \ \forall y \in U$ se e solo se $\bar{x}$ è il minimo di F in U. Sia $\delta > 0$, allora: $-\delta F'(\bar{x})^t(y - \bar{x}) \leqslant 0 \ \forall y \in U \Longrightarrow (\bar{x} - \delta F'(\bar{x}) - \bar{x})^t(y - \bar{x}) \leqslant 0 \ \forall y \in U$. Dunque, per il Teorema 3.1.1 sappiamo che $p_U(\bar{x} - \delta F'(\bar{x})) = \bar{x}$.

Definizione 3.2.1. *Sia $\delta > 0$, il metodo del gradiente con proiezione usa il seguente algoritmo:* $\begin{cases} x_0 \in U \\ x_{k+1} = p(x_k - \delta F'(x_k)) = G(x_k) \end{cases}$

Osservazione 3.2.1. *Ponendo $U = \mathbb{R}^d$, il metodo equivale a steepest descent.*

Definizione 3.2.2. *Sia $\alpha > 0$. Una funzione $F \in \mathscr{C}^1(U)$ si dice α-ellittica se soddisfa: $(F'(y) - F'(x))^t(y - x) \geqslant \alpha\|y - x\|^2 \ \forall x, y \in U$.*

Osservazione 3.2.2. *Osserviamo che se F è α-ellittica la sua hessiana è definita positiva con un autovalore minimo maggiore o uguale ad α.*

Lemma 3.2.1. *Una funzione α-ellittica è coerciva.*

Proposizione 3.2.1. *Sia U convesso e non vuoto, sia $F : U \to \mathbb{R}$ una funzione α-ellittica con derivata F' lipschitziana di parametro L. Allora, se $\delta \in (0, \frac{2\alpha}{L^2})$, le iterate $\{x_k\}_{k=1}^{\infty}$ generate dal metodo del gradiente con proiezione convergono all'unico punto $\bar{x}$ di minimo per F in U $\forall x_0 \in U$.*

Proof. Per il Lemma 3.2.1, F è coerciva, dunque per l'Osservazione 3.1.2 ammette minimo e tale minimo è unico perché F è convessa. Facciamo in modo che G sia una contrazione: $\|G(x) - G(y)\|^2 = \|p(x - \delta F'(x)) - p(y - \delta F'(y))\|^2 \leqslant \|(x - \delta F'(x)) - (y - \delta F'(y))\|^2 = \|(x - y) - \delta(F'(x) - F'(y))\|^2 = \|x - y\|^2 + \delta^2\|F'(x) - F'(y)\|^2 - 2\delta(x - y)^t(F'(x) - F'(y)) \leqslant (1 + \delta^2 L^2)\|x - y\|^2 - 2\delta\alpha\|x - y\|^2 = (1 - 2\delta\alpha + \delta^2 L^2)\|x - y\|^2 \Longrightarrow 1 - 2\delta\alpha + \delta^2 L^2 < 1 \Longrightarrow \delta \in (0, \frac{2\alpha}{L^2})$. □

Dunque, si possono utilizzare gli strumenti della ricerca del punto fisso. Come test di arresto, si può usare il controllo sulla differenza delle iterate successive. Per trovare un δ adatto dinamicamente, si può usare il backtracking ad ogni passo:

(i) Si calcola il candidato $x_{k+1} = p(x_k - \delta F'(x_k))$.

  (i.1) Se $\|x_{k+1} - x_k\| \geqslant \|x_k - x_{k-1}\|$, allora il passo è troppo lungo e si aggiorna $\delta = \frac{\delta}{2}$. Poi si torna al passo (i).

(iii) Se $\|x_{k+1} - x_k\| < \text{TOL} \implies \text{STOP}$

Tuttavia, in generale, l'operazione di proiezione è difficile da calcolare e richiede di per sé una ricerca di minimo vincolato ad ogni singola iterazione.

Esempio 3.2.1 (Iper-rettangoli)**.** *Sia $U = \bigtimes_{i=1}^{d} [a_i, b_i] \subseteq \mathbb{R}^d$, con $a_i \in \mathbb{R} \cup \{-\infty\}$ e $b_i \in \mathbb{R} \cup \{+\infty\}$. Allora: $[p_U(x)]_i = \max\{a_i, \min\{b_i, x_i\}\}$.*

3.3 Condizioni di Karush-Kuhn-Tucker

Definizione 3.3.1. *Sia* $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0 \ i \in \{1, ..., m\}\}$, *con* $\varphi_i \in \mathscr{C}^0(\mathbb{R}^d)$.
(a) L'insieme degli indici attivi è $I(x) = \{i \in \{1, ..., m\} \mid \varphi_i(x) = 0\}$.
(b) I vincoli $\{\varphi_i\}_{i=1}^m$ *si dicono qualificati in* $x \in U$ *se* $\exists \tilde{w} \in \mathbb{R}^d$ *tale che* $\forall i \in \{1, ..., m\}$: $\begin{cases} \tilde{w}^t \varphi_i'(x) < 0, \ \varphi \text{ non affine} \\ \tilde{w}^t \varphi_i'(x) \leqslant 0, \ \varphi \text{ affine} \end{cases}$

Lemma 3.3.1 (Lemma di Farkas - Minkowski)**.** *Siano* $b \in \mathbb{R}^d$, $\{a_i\}_{i \in I} \subset \mathbb{R}^d$. *Allora,* $\{v \in \mathbb{R}^d \mid v^t a_i > 0 \ \forall i \in I\} \subseteq \{v \in \mathbb{R}^d \mid v^t b \geqslant 0\}$ *se e solo se* $\exists \{\lambda_i\}_{i \in I} \subset \mathbb{R}^+$ *tali che* $b = \sum_{i \in I} \lambda_i a_i$.

Proposizione 3.3.1. *Sia* $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0, i \in \{1, ..., m\})\}$, *dove* $\{\varphi_i\}_{i=1}^m \subset \mathscr{C}^0(U)$ *è un vettore di vincoli differenziabili e qualificati in* $\bar{x} \in U$. *Sia* $F \in \mathscr{C}^0(U)$ *differenziabile in* $\bar{x}$ *e sia* $\bar{x}$ *un minimo locale per* F. *Allora,* $\exists \{\lambda_i\}_{i \in I(\bar{x})} \subseteq \mathbb{R}^m_+$ *tale che* $F'(\bar{x}) + \sum_{i \in I(\bar{x})} \lambda_i \varphi_i'(\bar{x}) = 0$.

Proof. Definiamo:

$$S_1 = \{w \in \mathbb{R}^d \mid \begin{cases} \varphi_i'(\bar{x})^t w < 0, \ \varphi \text{ non affine} \\ \varphi_i'(\bar{x})^t w \leqslant 0, \ \varphi \text{ affine} \end{cases} \quad i \in I(\bar{x})\}$$

$$S_2 = \{w \in \mathbb{R}^d \mid F'(\bar{x})^t w \geqslant 0\}$$

$$S_3 = \{w \in \mathbb{R}^d \mid \varphi_i'(\bar{x})^t w \leqslant 0 \ \forall i \in I(\bar{x})\}$$

L'insieme S_1 contiene tutte le direzioni che garantiscano di finire nella regione ammissibile (i vincoli affini possono essere uguali a 0 perché la curvatura è nulla e dunque non rischiano di essere tangenti), l'insieme S_2 contiene tutte le direzioni di non-discesa (se sto già in $\bar{x}$ non devo scendere oltre) e S_3 contiene tutte le direzioni di S_1 e anche quelle

tangenti. Il primo passo è mostrare che $S_1 \subseteq S_2$. Sia $w \in S_1$, vogliamo mostrare che $\exists \varepsilon_0 > 0 \mid \bar{x} + \varepsilon w \in U \ \forall \varepsilon \in [0, \varepsilon_0)$. Se $i \notin I(\bar{x})$: $\varphi_i(\bar{x}) < 0$ e per permanenza del segno vale l'asserto. Se $i \in I(\bar{x})$: $\varphi_i(\bar{x}) = 0$. Facciamo lo sviluppo di Taylor centrato in $\bar{x}$: $\varphi_i(\bar{x} + \varepsilon w) = \varphi_i(\bar{x}) + \varepsilon \varphi_i'(\bar{x})^t w + o(\varepsilon) = \varepsilon \varphi_i'(\bar{x})^t w + o(\varepsilon)$. Dividiamo in due casi:

- φ_i non affine: $\varphi_i(\bar{x} + \varepsilon w) \leqslant 0$ per permanenza del segno.
- φ_i affine: Lo sviluppo di Taylor coincide con la funzione stessa e quindi $\varphi(\bar{x} + \varepsilon w) = \varepsilon \varphi_i'(\bar{x})^t w \leqslant 0$ per qualunque $\varepsilon \geqslant 0$.

Valutiamo ora la condizione di S_2 per un tale w: $f'(\bar{x})^t w = \lim_{\varepsilon \to 0^+} \frac{F(\bar{x}+\varepsilon w) - F(\bar{x})}{\varepsilon} \geqslant 0$ perché stiamo prendendo un intorno piccolo abbastanza per avere $\bar{x} + \varepsilon w \in U$ e siamo attorno a un minimo. Con questo, concludiamo che $S_1 \subseteq S_2$. Sappiamo che S_2 è chiuso e quindi $\overline{S_1} \subseteq S_2$. Vogliamo mostrare che $S_3 \subseteq \overline{S_1} \subseteq S_2$. Sia $w \in S_3$ il nostro obiettivo è dimostrare che esiste una successione $\{w_k\}_{k \in \mathbb{N}} \subset S_1$ che converge a w. Per l'ipotesi di qualificazione sui vincoli, sappiamo che esiste $\tilde{w} \in \mathbb{R}^d$ tale che: $\begin{cases} \varphi_i'(\bar{x})^t \tilde{w} < 0, \ \varphi \text{ non affine} \\ \varphi_i'(\bar{x})^t \tilde{w} \leqslant 0, \ \varphi \text{ affine} \end{cases}$ $i \in I(\bar{x})$. Definiamo la successione come $w_k = w + \frac{1}{k}\tilde{w}$. Vogliamo mostrare che $w_k \in S_1 \ \forall k > 0$: $\varphi_i'(\bar{x})^t w_k = \varphi_i'(\bar{x})^t (w + \frac{1}{k}\tilde{w}) = \varphi_i'(\bar{x})^t + \frac{1}{k}\varphi_i'(\bar{x})^t \tilde{w}$. Poiché $w \in S_3$, sappiamo che $\varphi_i'(\bar{x})^t w \leqslant 0$. Per il secondo termine, si ha che se il vincolo è non affine, allora è strettamente negativo e dunque la somma è strettamente negativa; se il vincolo è affine, allora è non-positivo e dunque la somma è non-positiva. Dunque, $w_k \in S_1 \ \forall k > 0$. Deduciamo quindi che $w \in \overline{S_1} \subseteq S_2$, ma allora $S_3 \subseteq S_2$.
Possiamo applicare il Lemma 3.2.2 con $F'(\bar{x})^t = b$, $-\varphi_i'(\bar{x})^t = a_i$ e $i \in I(\bar{x})$, ottenendo $F'(\bar{x})^t = \sum_{i \in I(\bar{x})} -\lambda_i \varphi_i'(\bar{x})^t$ con $\lambda_i \geqslant 0$, da cui segue la tesi. □

Definizione 3.3.2. *Se* $I(\bar{x}) = \{i \in \{1, ..., m\} \mid \varphi_i(\bar{x}) = 0\}$*, le condizioni di Karush-Kuhn-Tucker sono uno dei tre equivalenti sistemi:*

$$\begin{cases} f'(\bar{x}) + \sum\limits_{i \in I(\bar{x})} \lambda_i \varphi_i'(\bar{x}) = 0 \\ \lambda_i \geqslant 0, \ i \in I(\bar{x}) \end{cases}$$

$$\begin{cases} \lambda_i \geqslant 0, \ i \in \{1, ..., m\} \\ f'(\bar{x}) + \sum\limits_{i=1}^{m} \lambda_i \varphi_i'(\bar{x}) = 0 \\ \lambda_i = 0 \ i \notin I(\bar{x}) \end{cases}$$

$$\begin{cases} \lambda_i \geqslant 0, \ i \in \{1, ..., m\} \\ f'(\bar{x}) + \sum\limits_{i=1}^{m} \lambda_i \varphi_i'(\bar{x}) = 0 \\ \sum\limits_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) = 0 \end{cases}$$

La terza definizione è coerente. Infatti, se il vincolo non è attivo, allora $\varphi_i(\bar{x}) < 0$ e quindi la somma è nulla se e solo se per ogni vincolo non attivo si ha $\lambda_i = 0$.

Proposizione 3.3.2. *Siano* $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0\}$*, con* $\varphi_i \in \mathscr{C}^0(\mathbb{R}^d)$ *convessi, e sia* $F : U \to \mathbb{R}$ *continua e convessa. Se* F *e* $\{\varphi_i\}_{i \in I(\bar{x})}$ *sono differenziabili in* $\bar{x}$ *e ivi valgono le (KKT), allora* $\bar{x}$ *è minimo di* F *in* U*.*

Proof. Sia $y \in U$, allora per convessità di F si ha:$F(y) \geqslant F(\bar{x}) + F'(\bar{x})^t(y - \bar{x}) \overset{(KKT)1}{=} F(\bar{x}) - \sum\limits_{i \in I(\bar{x})} \lambda_i \varphi_i'(\bar{x})^t(y - x)$. Per convessità dei vincoli: $\varphi_i(y) \geqslant \varphi_i(\bar{x}) + \varphi_i'(\bar{x})^t(y - \bar{x}) =^{i \in I(\bar{x})} \varphi_i'(\bar{x})^t(y - \bar{x}) \iff -\varphi_i(y) \leqslant -\varphi_i'(\bar{x})^t(y - \bar{x})$. Applico questa disuguaglianza alla prima disequazione: $F(y) \geqslant F(\bar{x}) - \sum\limits_{i \in I(\bar{x})} \lambda_i \varphi_i(y) \geqslant F(\bar{x})$. □

Definizione 3.3.3. *Sia $F : V \times M \to \mathbb{R}$, diciamo che $(\bar{x}, \bar{\mu}) \in V \times M$ è un punto di sella per F se:* $\inf_{x \in V} F(x, \bar{\mu}) = F(\bar{x}, \bar{\mu}) = \sup_{\mu \in M} F(\bar{x}, \mu)$.

Lemma 3.3.2. *Sia $(\bar{x}, \bar{\mu})$ un punto di sella per $F : V \times M \to \mathbb{R}$. Allora:* $\inf_{x \in V} \sup_{\mu \in M} F(x, \mu) = F(\bar{x}, \bar{\mu}) = \sup_{\mu \in M} \inf_{x \in V} F(x, \mu)$.

Proof. Siano $(x, \mu) \in V \times M$, definiamo le funzioni $G(\mu) = \inf_{x \in V} F(x, \mu)$ e $H(x) = \sup_{\mu \in M} F(x, \mu)$. Per definizione, per ogni coppia si ha $G(\mu) \leqslant H(x)$, in particolare si ha $\sup_{\mu \in M} G(\mu) \leqslant \inf_{x \in V} H(x)$. Sostituendo: $\sup_{\mu \in M} \inf_{x \in V} F(x, \mu) \leqslant \inf_{x \in V} \sup_{\mu \in M} F(x, \mu)$.
Ora, usiamo la definizione di punto di sella: $\inf_{x \in V} F(x, \bar{\mu}) = F(\bar{x}, \bar{\mu}) = \sup_{\mu \in M} F(\bar{x}, \mu)$. Usando l'uguaglianza a destra, otteniamo per definizione $\inf_{x \in V} F(x, \bar{\mu}) \leqslant \sup_{\mu \in M} \inf_{x \in V} F(x, \mu)$. Agiamo similmente sull'uguaglianza a sinistra, ottenendo: $\inf_{x \in V} \sup_{\mu \in M} F(x, \mu) \leqslant \sup_{\mu \in M} F(\bar{x}, \mu)$. Unendole, otteniamo la tesi. □

Definizione 3.3.4. *Sia $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0\}$ e $F : \mathbb{R}^d \to \mathbb{R}$. La funzione lagrangiana associata al problema della ricerca di punti di minimo di F vincolati a U è $L : \mathbb{R}^d \times \mathbb{R}^m_+ \to \mathbb{R} \mid L(x, \mu) = F(x) + \sum_{i=1}^{m} \mu_i \varphi_i(x)$, dove $\mu \in \mathbb{R}^m_+$.*

Proposizione 3.3.3. *Sia $(\bar{x}, \lambda) \in \mathbb{R}^d \times \mathbb{R}^m_+$ un punto di sella per L. Allora, $\bar{x} \in U$ è punto di minimo (globale) per F in U.*

Proof. Sfruttiamo la seconda metà della definizione di punto di sella, ovvero: $L(\bar{x}, \lambda) = \sup_{\mu \in \mathbb{R}^m_+} L(\bar{x}, \mu)$, scriviamolo esplicitamente usando la

definizione di lagrangiana: $F(\bar{x}) + \sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \geqslant F(\bar{x}) + \sum_{i=1}^{m} \mu_i \varphi_i(\bar{x}) \ \forall \mu \in \mathbb{R}_+^m$, che semplificato diventa:

$$\sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \geqslant \sum_{i=1}^{m} \mu_i \varphi_i(\bar{x}) \ \forall \mu \in \mathbb{R}_+^m$$

Essendo valida per ogni μ, valutiamola in due valori specifici, ovvero $\mu = 0$ e $\mu = 2\lambda$:

$$\sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \geqslant 0$$

$$\sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \geqslant 2 \sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \Longrightarrow \sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \leqslant 0$$

Unendole, otteniamo che $\sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) = 0$. Sostituiamolo nella prima disequazione, diventando $\sum_{i=1}^{m} \mu_i \varphi_i(\bar{x}) \leqslant 0 \ \forall \mu \in \mathbb{R}_+^m$. Sostituendo $\mu = e_j$, si ottiene $\varphi_j(\bar{x}) \leqslant 0 \ \forall j \in \{1, ..., m\}$, ovvero $\bar{x} \in U$.
Ora, usiamo la prima metà della definizione di punto di sella:

$$F(\bar{x}) = F(\bar{x}) + \sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) \leqslant F(x) + \sum_{i=1}^{m} \lambda_i \varphi_i(x) \ \forall x \in \mathbb{R}^d$$

Sappiamo che i moltiplicatori di Lagrange sono non-negativi e che $\varphi_i(x) \leqslant 0 \ \forall x \in U$, dunque $\sum_{i=1}^{m} \lambda_i \varphi_i(x) \leqslant 0$. Applicandolo alla disuguaglianza, otteniamo:

$$F(\bar{x}) \leqslant F(x) + \sum_{i=1}^{m} \lambda_i \varphi_i(x) \leqslant F(x)$$

Concludiamo che $\bar{x}$ è un minimo globale. □

Proposizione 3.3.4. *Siano $F \in \mathscr{C}^0(\mathbb{R}^d)$, $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0 \ \forall i \in \{1, ..., m\}\}$, con $F, \{\varphi_i\}_{i=1}^m \subset \mathscr{C}^0(\mathbb{R}^d)$ convesse e differenziabili in $\bar{x} \in U$, punto di minimo per F in U. Supponiamo che i vincoli siano qualificati in $\bar{x}$. Allora, $\exists \lambda \in \mathbb{R}_+^m$ tale che $(\bar{x}, \lambda) \in \mathbb{R}^d \times \mathbb{R}_+^m$ è punto di sella per la lagrangiana associata L.*

Proof. Applicando la Proposizione 3.3.1, sappiamo che esiste un vettore $\{\lambda_i\}_{i=1}^m \subset \mathbb{R}_+$ tali che: $\begin{cases} F'(\bar{x}) + \sum_{i=1}^m \lambda_i \varphi_i'(\bar{x}) = 0 \\ \sum_{i=1}^m \lambda_i \varphi_i(\bar{x}) = 0 \end{cases}$

Valutiamo la lagrangiana in $(\bar{x}, \lambda)$: $L(\bar{x}, \lambda) = F(\bar{x}) + \sum_{i=1}^m \lambda_i \varphi_i(\bar{x}) \overset{\text{(KKT)2}}{=} F(\bar{x})$. Sia ora $\mu \in \mathbb{R}_+^m$ arbitrario, dato che $\bar{x} \in U$ si ha $\varphi_i(\bar{x}) \leqslant 0$, dunque $L(\bar{x}, \mu) \leqslant F(\bar{x}) = L(\bar{x}, \lambda) \ \forall \mu \in \mathbb{R}_+^m$. In altre parole, $L(\bar{x}, \lambda) = \sup_{\mu \in \mathbb{R}_+^m} L(\bar{x}, \mu)$.

Definiamo la funzione ausiliaria $g(x) = L(x, \lambda)$, allora $g'(\bar{x}) = F'(\bar{x}) + \sum_{i=1}^m \lambda_i \varphi_i'(\bar{x}) \overset{\text{(KKT)1}}{=} 0$, ovvero $\bar{x}$ è stazionario per g. Dato che $g(x)$ è una combinazione lineare di funzioni convesse con coefficienti non-negativi, concludiamo che il minimo è unico e quindi $g(\bar{x}) \leqslant g(x) \ \forall x \in \mathbb{R}^d$ o, in altre parole, $L(\bar{x}, \lambda) = \inf_{x \in \mathbb{R}^d} L(x, \lambda)$.

Unendo i due risultati, concludiamo che $(\bar{x}, \lambda)$ è di sella per $L(x, \mu)$. □

3.4 Metodo di Uzawa

Consideriamo la funzione Lagrangiana $L(x, \mu) = F(x) + \sum_{i=1}^m \mu_i \varphi_i(x)$. Sia $(\bar{x}, \bar{\mu}) \in \mathbb{R}^d \times \mathbb{R}_+^m$ un punto di sella. Definiamo la funzione $G(\mu)$ come:

$$G(\mu) = \inf_{x \in \mathbb{R}^d} L(x, \mu)$$

Sfruttando le proprietà del punto di sella, vale la relazione:

$$G(\bar{\mu}) = L(\bar{x}, \bar{\mu}) = \sup_{\mu \in \mathbb{R}^m_+} \inf_{x \in \mathbb{R}^d} L(x, \mu) = \sup_{\mu \in \mathbb{R}^m_+} G(\mu)$$

Per trovare il sup di $G(\mu)$, possiamo applicare il metodo del gradiente con proiezione alla funzione $-G$ (ovvero per minimizzare $-G$) sull'insieme $\mathbb{R}^m_+$. Il metodo astratto assume la seguente forma:

$$\begin{cases} \lambda_0 \in \mathbb{R}^m_+ \\ \lambda_{k+1} = p_{\mathbb{R}^m_+}(\lambda_k + \delta G'(\lambda_k)), k \in \mathbb{N} \end{cases}$$

dove la proiezione sul cono positivo avviene componente per componente:

$$(p_{\mathbb{R}^m_+}(v))_i = \max\{0, v_i\} \forall v \in \mathbb{R}^m.$$

Proposizione 3.4.1. *Se per $\mu \in \mathbb{R}^m_+$ esiste un punto $x_\mu \in \mathbb{R}^d$ che minimizza la Lagrangiana tale per cui $G(\mu) = L(x_\mu, \mu)$, allora $G'(\mu) = \varphi(x_\mu)$, dove φ è il vettore dei vincoli.*

Proof. Calcoliamolo esplicitamente: $[G'(\mu)]_j = \frac{\partial G}{\partial \mu_j}(\mu) = \nabla_x f(x_\mu)^t \frac{\partial x_\mu}{\partial \mu_j} + \frac{\partial}{\partial \mu_j}[\sum_{i=1}^m \mu_i \varphi_i(x_\mu)] = \nabla_x f(x_\mu)^t \frac{\partial x_\mu}{\partial \mu_j} + \sum_{i=1}^m (\frac{\partial \mu_i}{\partial \mu_j}\varphi_i(x_\mu) + \mu_i \nabla_x \varphi_i(x_\mu)^t \frac{\partial x_\mu}{\partial \mu_j}) = \nabla_x f(x_\mu)^t \frac{\partial x_\mu}{\partial \mu_j} + \varphi_j(x_\mu) + \sum_{i=1}^m \mu_i \nabla_x \varphi_i(x_\mu)^t \frac{\partial x_\mu}{\partial \mu_j} = \varphi_j(x_\mu) + [\nabla_x f(x_\mu) + \sum_{i=1}^m \mu_i \nabla_x \varphi_i(x_\mu)]^t \frac{\partial x_\mu}{\partial \mu_j} = \varphi_j(x_\mu) + \nabla_x L(x_\mu, \mu) = \varphi_j(x_\mu)$. Concludiamo che $G'(\mu) = \varphi(x_\mu)$. □

Usando il risultato della Proposizione 3.4.1, il metodo astratto diventa:

$$\begin{cases} \lambda_0 \in \mathbb{R}^m_+ \\ \delta \in \mathbb{R}_+ \\ \lambda_{k+1} = p_{\mathbb{R}^m_+}(\lambda_k + \delta \varphi(x_{\lambda_k})) \end{cases}$$

con $x_{\lambda_k} \in \mathbb{R}^d$ che minimizza $F(x) + \sum_{i=1}^{m} (\lambda_k)_i \varphi_i(x)$.

Definizione 3.4.1. *Siano scelti $\lambda_0 \in \mathbb{R}^m_+$ e $\delta > 0$. Il metodo di Uzawa genera la successione delle iterate secondo il seguente algoritmo:*

(i) Dato il moltiplicatore λ_k, si calcola $x_k \in \mathbb{R}^d$ minimizzando la funzione lagrangiana:

$$F(x_k) + \sum_{i=1}^{m} \lambda_i^k \varphi_i(x_k) = \min_{x \in \mathbb{R}^d} \left(F(x) + \sum_{i=1}^{m} \lambda_i^k \varphi_i(x) \right)$$

(ii) Si calcolano i nuovi moltiplicatori:

$$\lambda_{k+1}^i = \max\{0, \lambda_k^i + \delta \varphi_i(x_k)\}$$

Proposizione 3.4.2 (Convergenza del metodo di Uzawa)**.** *Siano $U = \{x \in \mathbb{R}^d \mid \varphi_i(x) \leqslant 0 \ i \in \{1, ..., m\}\}$, $F \in \mathscr{C}^1(\mathbb{R}^d)$ α-ellittica, $\{\varphi_i\}_{i=1}^m$ qualificati in $\bar{x}$, convessi e lipschitziani con costante L e sia $\delta \in (0, \frac{2\alpha}{L^2})$. Allora, le iterate generate dal metodo di Uzawa convergono all'unico minimo $\bar{x}$ di F in U $\forall \lambda_0 \in \mathbb{R}^m_+$.*

Proof. Essendo F α-ellittica, è coerciva e strettamente convessa e dunque ammette un unico punto di minimo. Per (KKT) sappiamo esistere $\lambda \in \mathbb{R}^m_+$ tale che $\begin{cases} F'(\bar{x}) + \sum_{i=1}^{m} \lambda_i \varphi_i'(\bar{x}) = 0 \\ \sum_{i=1}^{m} \lambda_i \varphi_i(\bar{x}) = 0 \end{cases}$

Osserviamo che $\lambda = p(\lambda + \delta\varphi(\bar{x})) \iff (\lambda + \delta\varphi(\bar{x}) - \lambda)^t(\mu - \lambda) \leqslant 0 \ \forall \mu \in \mathbb{R}^m_+ \iff \delta\varphi(\bar{x})^t(\mu - \lambda) \leqslant 0 \ \forall \mu \in \mathbb{R}^m_+ \iff \delta\varphi(\bar{x})^t\mu \leqslant 0 \ \forall \mu \in \mathbb{R}^m_+$ (per le (KKT) in quanto $\varphi(\bar{x})^t\lambda = 0$), ma quest'ultima è verificata e dunque lo è anche la prima.

Calcoliamo: $\|\lambda_{k+1} - \lambda\|^2 = \|p(\lambda_k + \delta\varphi(x_k)) - p(\lambda + \delta\varphi(\bar{x}))\|^2$

$\leqslant \|\lambda_k + \delta\varphi(x_k) - (\lambda + \delta\varphi(\bar{x}))\|^2$
$= \|\lambda_k - \lambda\|^2 + \delta^2\|\varphi(x_k) - \varphi(\bar{x})\|^2 + 2\delta(\varphi(x_k) - \varphi(\bar{x}))^t(\lambda_k - \lambda)$
$\leqslant \|\lambda_k - \lambda\|^2 + \delta^2 L^2\|x_k - \bar{x}\|^2 + 2\delta \sum_{i=1}^{m}(\varphi_i(x_k) - \varphi_i(\bar{x}))(\lambda_i^k - \lambda_i)$
$= \|\lambda_k - \lambda\|^2 + \delta^2 L^2\|x_k - \bar{x}\|^2 + 2\delta[\sum_{i=1}^{m}(\varphi_i(x_k) - \varphi_i(\bar{x}))\lambda_i^k + \sum_{i=1}^{m}(\varphi_i(\bar{x}) - \varphi_i(x_k))\lambda_i]$
$\overset{\text{convessità}}{\leqslant} \|\lambda_k-\lambda\|^2+\delta^2L^2\|x_k-\bar{x}\|^2+2\delta[\sum_{i=1}^{m}\varphi_i'(x_k)^t(x_k-\bar{x})\lambda_i^k+\sum_{i=1}^{m}\varphi_i'(\bar{x})^t(\bar{x}-x_k)\lambda_i]$
$= \|\lambda_k - \lambda\|^2 + \delta^2 L^2\|x_k - \bar{x}\|^2 + 2\delta[\sum_{i=1}^{m}\lambda_i^k\varphi_i'(x_k) - \sum_{i=1}^{m}\lambda_i\varphi_i'(\bar{x})]^t(x_k - \bar{x})$
$\overset{\text{KKT}}{=} \|\lambda_k - \lambda\|^2 + \delta^2 L^2\|x_k - \bar{x}\|^2 - 2\delta[F'(x_k) - F'(\bar{x})]^t(x_k - \bar{x})$
$\overset{\alpha\text{-ellittica}}{\leqslant} \|\lambda_k - \lambda\|^2 + \delta^2 L^2\|x_k - \bar{x}\|^2 - 2\delta\alpha\|x_k - \bar{x}\|^2$
$= \|\lambda_k - \lambda\|^2 + \delta(\delta L^2 - 2\alpha)\|x_k - \bar{x}\|^2$, dove l'applicazione delle (KKT) ci dice che $\sum_{i=1}^{m}\lambda_i\varphi_i'(\bar{x}) = -F'(\bar{x})$, ma x_k minimizza la Lagrangiana al passo k e quindi $\sum_{i=1}^{m}\lambda_i^k\varphi_i'(x_k) = -F'(x_k)$. Si ha dunque $\Delta < 0 \iff \delta \in (0, \frac{2\alpha}{L^2})$. In queste condizioni, si ha $C\sum_{k=0}^{N}\|x_k - \bar{x}\| \leqslant \|\lambda_0-\lambda\| - \|\lambda_{N+1}-\lambda\|^2 \leqslant \|\lambda_0-\lambda\|^2$, dunque la serie converge e il termine generale deve tendere a zero, ovvero le iterate di Uzawa convergono al minimo. □

Corollario 3.4.2.1. *Nelle ipotesi precedenti, se il λ che soddisfa (KKT) è unico, allora $\lambda_k \to \lambda$.*

Proof. Sappiamo che $\|\lambda_k - \lambda\| \leqslant C\ \forall k \in \mathbb{N}$ perché converge a un limite finito. Supponiamo per assurdo che esista $\varepsilon > 0$ e una sottosuccessione $\{\lambda_{k_j}\}_{j=1}^{\infty}$ tali che $\|\lambda_{k_j} - \lambda\| > \varepsilon\ \forall j \in \mathbb{N}$. So che $\|\lambda_{k_j}\| \leqslant \|\lambda_{k_j} - \lambda\| + \|\lambda\| \leqslant C + \|\lambda\|$. Essendo limitate, allora esiste $\{\lambda_{k_{j_l}}\}_{l=1}^{\infty}$ con $\lambda_{k_{j_l}} \to \tilde{\lambda}$. Bisogna

mostrare che $\tilde{\lambda} = \lambda$, ovvero che $\tilde{\lambda}$ soddisfa le (KKT).
(KKT1) $0 = F'(x^{k_{j_l}}) + \sum \lambda_i^{k_{j_l}} \varphi_i'(x^{k_{j_l}}) \to F'(\bar{x}) + \sum \tilde{\lambda}_i \varphi_i'(\bar{x})$.
(KKT2) Bisogna mostrare che $\varphi_i(\bar{x}) < 0 \implies \tilde{\lambda}_i = 0$. Sia i tale che $\varphi_i(\bar{x}) < 0$, allora $\lambda_i^{k+1} = \max\{0, \lambda_i^k + \delta\varphi_i(x_k)\}$. So che definitivamente $\varphi_i(x_k) \leqslant \frac{\varphi_i(\bar{x})}{2} < 0$, quindi $\lambda_i^k + \delta\varphi_i(x_k)$ decresce più che linearmente fino a raggiungere lo 0 in un numero finito di passi, ossia $\varphi_i(\bar{x}) < 0 \implies \tilde{\lambda}_i = \lim_{l\to\infty} \lambda^{k_{j_l}} = 0$. Per unicità, questo indica che $\tilde{\lambda} = \lambda$ ma questo porta a un assurdo perché abbiamo supposto $\|\lambda_{k_j} - \lambda\| > \varepsilon$. □

Il controllo sui lambda per ogni iterata ha la forma $\|\lambda_{k+1} - \lambda_k\| \geqslant \|\lambda_k - \lambda_{k-1}\| \implies \delta := \frac{\delta}{2}$, mentre il test di arresto è sulle iterate.

Osservazione 3.4.1. *Il metodo di Uzawa richiede una ricerca di minimo a ogni passaggio ma è resa più semplice dal punto iniziale x_{k-1} ad ogni iterata. Scegliere $\lambda_0 = \bar{0}$ significa cercare il minimo su tutto $\mathbb{R}^d$.*

3.5 Caso del filo con ostacolo

Consideriamo un filo elastico con estremi in $(0,0)$ e $(1,0)$, di avere una forza $g \in \mathscr{C}^0(0,1)$ che mette pressione dall'alto e un ostacolo $\psi \in \mathscr{C}^0(0,1)$, con $\psi(0), \psi(1) \leqslant 0$, sotto al filo. Il problema è di cercare $u \in V = \{u \in \mathscr{C}^1(0,1) \mid u(0) = u(1) = (0,0), u(x) \geqslant \psi(x)\ \forall x \in [0,1]\}$ che minimizzi l'energia $f : U \to \mathbb{R} \mid f(u) = \frac{k}{2}\int_0^1 1 + [u'(x)]^2\ dx - \int_0^1 g(x)u(x)\ dx$, moralmente $f(u) = \frac{k}{2}\int_0^1 1 + [u'(x)]^2\ dx - \int_0^1 g(x)u(x)\ dx$ perché 1 è una costante. Consideriamo, come già fatto in precedenza, una discretizzazione usando spline di grado 1 sullo spazio $S_d = \{u \in \mathscr{C}^0([0,1]) \mid u_{|[x_i,x_{i+1}]} \in \mathbb{P}_1(x, x_{i+1})\ i \in \{0,...,d\}, u(0) = u(1) = (0,0)\}$. Definiamo dunque $V_d = \{u \in S_d \mid \psi(x_i) \leqslant u(x_i)\ i \in \{0,...,d\}\}$. Definiamo $U_i = u(x_i)$, la soluzione la dobbiamo cercare in $\{U \in \mathbb{R}^d \mid U_i \geqslant \psi(x_i)\ i \in \{1,...,d\}\} = \bigtimes_{i=1}^{d} [\psi(x_i), \infty)$. La funzione diventa $f(U) =$

$\frac{k}{2}\sum_{j=0}^{d}\int_{x_j}^{x_{j+1}}[u_d'(x)]^2\,dx+\int_0^1 g(x)u_d(x) = \frac{k}{2}\sum_{j=0}^{d}\int_{x_j}^{x_{j+1}}(\frac{U_{j+1}-U_j}{h})^2\,dx+\sum_{j=1}^{d} hg(x_j)U_j =$
$\frac{k}{2h}\sum_{j=0}^{d}(U_{j+1}-U_j)^2 + h\sum_{j=1}^{d} g(x_j)U_j$. Notiamo che è una forma quadratica e, infatti, si può scrivere come $\frac{k}{2h}U^tAU + h\bar{g}^tU$, dove $A \in \mathbb{R}^{d\times d}$ è la matrice tridiagonale con 2 sulla diagonale e -1 sulle adiacenti e $(\bar{g})_i = g(x_i)$.

4 Problemi di Cauchy

4.1 Metodi a un passo

Definizione 4.1.1. *Sia* $f : [0,T] \times \mathbb{R}^d \to \mathbb{R}^d$ *e* $u_0 \in \mathbb{R}^d$. *La soluzione del problema di Cauchy consiste nella ricerca di una funzione* $u : [0,T] \to \mathbb{R}^d$ *tale che* $\begin{cases} \frac{du}{dt}(t) = f(t,u(t)) \ \forall t \in [0,T] \\ u(0) = u_0 \end{cases}$

Teorema 4.1.1 (Teorema di Picard)**.** *Sia* $u_0 \in \mathbb{R}^d$ *e* $f : [0,T] \times B(u_0,R) \to \mathbb{R}^d$, *con* $R > 0$, *continua e lipschitziana rispetto alla seconda variabile uniformemente rispetto alla prima.*
Allora, se $\max_{t\in[0,T],x\in B(u_0,R)} \|f(t,x)\|T \leqslant R$, *allora esiste ed è unica la soluzione* u *del problema di Cauchy.*

L'obiettivo è di tradurre l'equazione al continuo discretizzandola, ovvero cercando un vettore $\{u_k\}_{k=0}^N \subseteq \mathbb{R}^d$ tale che $u_k \approx u(t_k)\ \forall k \in \{0,...,N\}$, sapendo che $u_0 = u(0)$ è dato. Supponiamo da qui in avanti che $h = \frac{T}{N}$ sia l'ampiezza dell'intervallo.
Osserviamo che $u_{k+1} - u_k = u(t_{k+1}) - u(t_k) = \int_{t_k}^{t_{k+1}} u'(t)\,dt = \int_{t_k}^{t_{k+1}} f(t,u(t))\,dt$, trasformandolo in un problema di quadratura:
(i) Se uso il rettangolo con altezza $f(t_k,u(t_k))$, allora $u_{k+1} \approx u_k + hf(t_k,u(t_k)) \approx u_k + hf(t_k,u_k)$ (Metodo di Eulero in avanti).
(ii) Se uso il rettangolo con altezza $f(t_{k+1},u(t_{k+1}))$, allora $u_{k+1} \approx u_k + hf(t_{k+1},u(t_{k+1})) \approx u_k + hf(t_{k+1},u_{k+1})$ (Metodo di Eulero all'indietro).
(iii) Se uso i trapezi, allora $u_{k+1} \approx u_k + \frac{h}{2}(f(t_k,u_k) + f(t_{k+1},u_{k+1}))$ (Metodo dei trapezi).
(iv) Se uso il rettangolo con altezza $f(\frac{t_{k+1}+t_k}{2}, \frac{u_{k+1}+u_k}{2})$, allora $u_{k+1} \approx u_k + hf(t_k + \frac{h}{2}, \frac{u_k+u_{k+1}}{2})$ usando un'interpolazione per la u (Metodo del punto medio).

Definizione 4.1.2. *Il metodo di Heun è un metodo esplicito dato da* $u_{k+1} = u_k + \frac{h}{2}(f(t_k,u_k) + f(t_{k+1},u_k + hf(t_k,u_k)))$.

Definizione 4.1.3. *I metodi a un passo usano l'informazione del passo precedente per calcolare il dato successivo e hanno la forma:*

$$\begin{cases} u_{k+1} = u_k + h\Phi(t_k, u_k, u_{k+1}, h) \ \forall k \in \{0, ..., N-1\} \\ u_0 = u_0 \in \mathbb{R}^d \end{cases}$$

Definizione 4.1.4. *Un metodo a un passo si dice esplicito se* $\Phi = \Phi(t_k, u_k, h)$*. Altrimenti, è detto implicito.*

Osservazione 4.1.1. *Tutti i metodi precedenti sono metodi a un passo e solo Eulero in avanti e Heun sono espliciti.*

Definizione 4.1.5. *L'errore di troncamento è*

$$T_k = \frac{u(t_{k+1}) - u(t_k)}{h} - \Phi(t_k, u(t_k), u(t_{k+1}), h)$$

Definizione 4.1.6. *Un metodo a un passo si dice:*
(i) Consistente se, assumendo u sufficientemente regolare, vale $\lim_{h\to 0} \max_{0\leqslant k\leqslant N-1} \|T_k\| = 0$.
(ii) Accurato di ordine $p \in \mathbb{N}_0$ *se, assumendo u sufficientemente regolare,* $\exists C > 0$ *tale che* $\max_{0\leqslant k\leqslant N-1} \|T_k\| \leqslant Ch^p$.

Esempio 4.1.1. *I metodi di Eulero sono di ordine* 1*, gli altri metodi visti sono di ordine* 2*.*

Proposizione 4.1.1. *Sia* $\{u_k\}_{k=0}^N$ *generata con un metodo a un passo accurato di ordine p e con funzione* $\Phi(t_k, u_k, u_{k+1}, h)$ *lipschitziana di parametro L rispetto alla seconda e alla terza variabile uniformemente rispetto alle altre. Allora, se la soluzione esatta u è sufficientemente regolare, allora* $\exists C > 0$ *tale che* $\max_{0\leqslant k\leqslant N} \|u_k - u(t_k)\| \leqslant Ch^p \ \forall h < \frac{1}{L}$.

Proof. Scriviamo $u(t_{k+1}) = u(t_k) + hT_k + h\Phi(t_k, u(t_k), u(t_{k+1}), h)$ usando l'errore di troncamento. Calcoliamo: $E_{k+1} = \|u_{k+1} - u(t_{k+1})\| =$

$\|u_k+h\Phi(t_k,u_k,u_{k+1},h)-u(t_k)-h\Phi(t_k,u(t_k),u(t_{k+1}),h)-hT_k+h\Phi(t_k,u(t_k),u_{k+1},h)-h\Phi(t_k,u(t_k),u_{k+1},h)\| \leqslant E_k+h\|\Phi(t_k,u_k,u_{k+1},h)-\Phi(t_k,u(t_k),u_{k+1},h)\|+h\|\Phi(t_k,u(t_k),u_{k+1},h)-\Phi(t_k,u(t_k),u(t_{k+1}),h)\|+h\|T_k\| \leqslant E_k+hL\|u_k-u(t_k)\|+hL\|u_{k+1}-u(t_{k+1})\|+\tilde{C}h^{p+1} \leqslant E_k+hLE_k+hLE_{k+1}+\tilde{C}h^{p+1} \Longrightarrow (1-hL)E_{k+1} \leqslant (1+hL)E_k+\tilde{C}h^{p+1} \Longrightarrow E_{k+1} \leqslant (\frac{1+hL}{1-hL})E_k+\frac{\tilde{C}}{1-hL}h^{p+1} \leqslant (\frac{1+hL}{1-hL})^{k+1}E_0+\sum_{j=0}^{k}(\frac{1+hL}{1-hL})^j\frac{\tilde{C}}{1-hL}h^{p+1} \overset{E_0=0}{=} \sum_{j=0}^{k}(\frac{1+hL}{1-hL})^j\frac{\tilde{C}}{1-hL}h^{p+1}$. Passiamo all'errore al passo finale: $E_N \leqslant N(\frac{1+hL}{1-hL})^N\frac{\tilde{C}}{1-hL}h^{p+1} \overset{T=hN}{=} (\frac{1+\frac{TL}{N}}{1-\frac{TL}{N}})^N\frac{T\tilde{C}}{1-hL}h^p$. Osserviamo che il termine elevato a N è una successione limitata che converge a e^{2TL}, similmente la frazione $\frac{T\tilde{C}}{1-hL}$ è una costante e quindi $E_N \leqslant Ch^p$. □

Osservazione 4.1.2. *La richiesta di lipschitzianità è quasi sempre garantita se lo è f. Ad esempio, per Eulero in avanti $\Phi(t_k,u_k,u_{k+1},h) = f(t_k,u_k)$.*

4.2 Calcolo dell'ordine di un metodo

Di base si usano gli sviluppi di Taylor.

Esempio 4.2.1. *Calcoliamo l'ordine di Eulero in avanti: $T_k = \frac{u(t_{k+1})-u(t_k)}{h} - f(t_k,u(t_k)) = \frac{u(t_{k+1})-u(t_k)}{h} - u'(t_k) = \frac{u(t_k)+hu'(t_k)+\frac{h^2}{2}u''(t_k)+o(h^2)}{h} - u(t_k) + u'(t_k) = \frac{h}{2}u''(t_k)+o(h)$, dunque $T_k \leqslant \frac{u''(t_k)}{2}h$ se u è differenziabile due volte.*

Esempio 4.2.2. *Calcoliamo l'ordine del metodo dei trapezi: $T_k = \frac{u(t_{k+1})-u(t_k)}{h}-\frac{1}{2}(f(t_k,u(k))+f(t_{k+1},u(t_{k+1}))) = \frac{u(t_k)+hu'(t_k)+\frac{h^2}{2}u''(t_k)+\frac{h^3}{6}u'''(t_k)+o(h^3)-u(t_k)}{h}-\frac{1}{2}(u'(t_k)+u'(t_{k+1})) = \frac{hu'(t_k)+\frac{h^2}{2}u''(t_k)+\frac{h^3}{6}u'''(t_k)+o(h^3)}{h} - \frac{1}{2}(u'(t_k)+u'(t_k)+hu''(t_k)+\frac{h^2}{2}u'''(t_k)+o(h^2)) = h^2(\frac{1}{6}-\frac{1}{4})u'''(t_k)+o(h^2)$, dunque $\|T_k\| \leqslant \frac{\|u'''(t_k)\|}{12}h^2+|o(h^2)|$ se $u \in \mathscr{C}^3$.*

Esempio 4.2.3. *Calcoliamo l'ordine del metodo di Heun:* $T_k = \frac{u(t_{k+1})-u(t_k)}{h} - \frac{1}{2}(f(t_k, u(k)) + f(t_{k+1}, u(t_k) + hf(t_k, u(t_k)))) = \frac{u(t_k)+hu'(t_k)+\frac{h^2}{2}u''(t_k)+\frac{h^3}{6}u'''(t_k)+o(h^3)-u(t_k)}{h} - \frac{1}{2}(u'(t_k) + f(t_k + h, u(t_k) + hu'(t_k)))$. *Chiamiamo* $g(h) = f(t_k + h, u(t_k) + hu'(t_k)) \approx g(0) + hg'(0) + o(h^2) = f(t_k, u(t_k)) + h(\frac{\partial f}{\partial t}(t_k, u(t_k)) + \frac{\partial f}{\partial u}(t_k, u(t_k))f(t_k, u(t_k))) + o(h^2) = u'(t_k) + hu''(t_k) + o(h^2)$. *Allora:* $T_k = \frac{h^2}{6}u'''(t_k) + o(h^2)$, *dunque* $\|T_k\| \leqslant \frac{h^2}{6}|u'''(t_k)| + |o(h^2)|$.

4.3 A-stabilità

Osservazione 4.3.1. *Sia* $\lambda \geqslant 0$ *(si potrebbe prendere anche tale che* $\Re(\lambda)) > 0$*) e supponiamo di voler risolvere il problema*

$$\begin{cases} u'(t) = -\lambda u(t) \\ u(0) = u(0) \end{cases}$$

Conosciamo la soluzione esplicita del problema: $u : [0, \infty) \to \mathbb{R} \mid u(t) = u_0 e^{-\lambda t}$. *Osserviamo che* $\lim_{t\to\infty} u(t) = 0 \ \forall u_0 > 0$. *Vorremmo che il metodo numerico utilizzato rispetti questo comportamento asintotico. Sappiamo che* $f(t, u) = -\lambda u$. *Usiamo Eulero in avanti:* $u_{k+1} = u_k + hf(t_k, u_k) = u_k - h\lambda u_k = (1 - h\lambda)u_k = (1 - h\lambda)^{k+1}u_0$, *questa va a zero se e solo se* $|1 - h\lambda| < 1 \iff -1 < (1 - h\lambda) < 1 \iff -2 < -h\lambda < 0 \iff h \in (0, \frac{2}{\lambda})$ *perché* $h, \lambda > 0$.
Notiamo che questa condizione di stabilità risulta molto restrittiva: se λ *è grande, il passo di integrazione* h *deve essere scelto estremamente piccolo, rendendo il metodo computazionalmente inefficiente. Se invece tale condizione non viene rispettata (ovvero se* $h > \frac{2}{\lambda}$*), il metodo diventa instabile e la successione diverge anziché decadere a zero, portando a un blow-up numerico.*

Definizione 4.3.1. *L'intervallo di assoluta stabilità di un metodo numerico è il più grande intervallo* $I \subseteq \mathbb{R}^+$ *tale per cui il metodo preserva*

il corretto comportamento asintotico della soluzione esatta del problema di Cauchy per ogni $h\lambda \in I$.

Esempio 4.3.1. *Ripetiamo ciò che è stato fatto nell'Osservazione* 4.3.1 *ma con Eulero all'indietro:* $u_{k+1} = u_k + hf(t_{k+1}, u_{k+1}) = u_k - h\lambda u_{k+1} \iff u_{k+1} = \frac{1}{1+h\lambda}u_k = (\frac{1}{1+h\lambda})^{k+1}u_k$, *ma* $|\frac{1}{1+h\lambda}| = \frac{1}{1+h\lambda} < 1 \ \forall \lambda, h > 0$, *quindi* $I = (0, \infty)$.

Esempio 4.3.2. *Si può dimostrare che il metodo del punto medio e del trapezio hanno* $I = (0, \infty)$ *e il metodo di Heun ha* $I = (0, 2)$.

Osservazione 4.3.2. *Essendo pur vero che per* λ *molto grande bisogna prendere* h *(quantomeno nei metodi con* $I = (0, 2)$*) estremamente piccolo, al contempo se* λ *è grande allora l'interesse del problema è per piccoli tempi e quindi non crea problemi nel caso scalare. Consideriamo* $u : [0, \infty) \to \mathbb{R}^d$ *e il problema dell'Osservazione* 4.3.1

$$\begin{cases} u'(t) = -Au(t) \\ u(0) = u_0 \end{cases}$$

Dove A *è una matrice simmetrica e definita positiva. Consideriamo una base di autovettori* $\{v_i\}$ *per* A *e scriviamo* $u(t) = \sum_{i=1}^{d} c_i(t)v_i$ *e la derivata* $u'(t) = \sum_{i=1}^{d} c_i'(t)v_i = -Au(t) = -\sum_{i=1}^{d} c_i(t)Av_i = -\sum_{i=1}^{d} c_i(t)\lambda_i v_i$, *da cui* $c_i'(t) = -\lambda_i c_i(t) \implies c_i(t) = c_i(0)e^{-\lambda_i t}$. *A differenza del caso scalare, qui dipendentemente dai singoli* λ_i *potrebbe esserci interesse sia per lunghi tempi che per brevi tempi. Proviamo a considerare Eulero in avanti:* $u_{k+1} = u_k - hAu_k = (I - hA)u_k \iff \sum_{i=1}^{d} c_{i,k+1}(t)v_i = \sum_{i=1}^{d} c_{i,k}(t)(I - hA)v_i = \sum_{i=1}^{d} c_{i,k}(t)(1 - h\lambda_i)v_i$. *Quindi,* $c_{i,k+1} = (1 - h\lambda_i)c_{i,k} = (1 - h\lambda_i)^{k+1}c_{i,0}$.

Definizione 4.3.2. *Un problema stiff è un problema di Cauchy vettoriale in cui sono presenti sia λ_i piccoli che grandi.*

4.4 Metodi Runge-Kutta

I metodi a un passo che abbiamo considerato permettono al massimo di raggiungere l'ordine 2, l'idea è di usare una sorta di interpolazione per avere un'approssimazione che raggiunga un ordine più grande. Sia $R \in \mathbb{N}_0$ (il numero di stadi del metodo), scriviamo:

$$u_{k+1} = u_k + h \sum_{r=1}^{R} c_r K_r$$

dove $\{c_r\}_{r=1}^{R} \subseteq \mathbb{R}$ e $K_r \approx u'(t_k + hq_r)$ per $\{q_r\}_{r=1}^{R} \subseteq \mathbb{R}$. Osserviamo che $K_1 \approx u'(t_k) \approx f(t_k, u_k)$ e approssimiamo $u(t_k + hq_r) \approx u_k + h \sum_{s=1}^{R} b_{rs} K_s$, così:

$$K_r = f\left(t_k + hq_r, u_k + h \sum_{s=1}^{R} b_{rs} K_s\right), \quad \text{con } \{b_{rs}\}_{r\in\{2,\dots,R\}}^{s\in\{1,\dots,R\}}$$

Tutti questi parametri sono scelti a posteriori calcolando l'errore di troncamento e ponendo condizioni in modo da ottenere l'ordine voluto. Per far tornare il fatto che $h \sum_{r=1}^{R} c_r K_r$ approssimi l'integrale, sappiamo che $h \sum_{r=1}^{R} c_r = h$ e quindi $\sum_{r=1}^{R} c_r = 1$. Similmente, la condizione di coerenza sui nodi intermedi richiede che $h \sum_{s=1}^{R} b_{rs} = hq_r \implies \sum_{s=1}^{R} b_{rs} = q_r$.

Osservazione 4.4.1. *Il metodo di Heun è un caso particolare di metodo di Runge-Kutta.*

Osservazione 4.4.2. *(i) In generale sono metodi impliciti, ma se* $b_{rs} = 0\ \forall s \geqslant r$*, allora è esplicito.*
(ii) Se $b_{rs} = 0\ \forall s > r$*, allora il metodo è semi-implicito, nel senso che ad ogni calcolo di* K_r *mi ritrovo* K_r *al secondo membro ma non termini con* s *superiore.*

Definizione 4.4.1. *Il metodo di Runge-Kutta esplicito a* 3 *stadi usa* $c = (\frac{1}{6}, \frac{2}{3}, \frac{1}{6}), b_{21} = \frac{1}{2}, b_{31} = -1, b_{32} = 2, a_2 = \frac{1}{2}$ *e* $a_3 = 1$ *(le* a *si deducono dalle* b*). Da queste, derivano:* $u_{k+1} = u_k + \frac{1}{6}h(K_1 + 4K_2 + K_3)$*,* $K_1 = f(t_k, u_k)$*,* $K_2 = f(t_k + \frac{h}{2}, u_k + \frac{h}{2}hK_1)$ *e* $K_3 = f(t_k + h, u_k - hK_1 + 2hK_2)$*.*

Osservazione 4.4.3. *Il metodo ha ordine* 3 *e ricorda il metodo di Simpson.*

Definizione 4.4.2. *Il metodo di Runge-Kutta esplicito a* 4 *stadi usa* $u_{k+1} = u_k + \frac{1}{6}h(K_1 + 2K_2 + 2K_3 + K_4)$*, con* $K_1 = f(t_k, u_k)$*,* $K_2 = f(t_k + \frac{h}{2}, u_k + \frac{h}{2}K_1)$*,* $K_3 = f(t_k + \frac{h}{2}, u_k + \frac{h}{2}K_2)$ *e* $K_3 = f(t_k + h, u_k + hK_3)$*.*

Osservazione 4.4.4. *Questo metodo migliora il precedente, nel quale le valutazioni portano a una perdita di efficienza, mentre questo ha ordine* 4*.*

4.5 Come implementare i metodi impliciti

L'idea fondamentale è scrivere il metodo portando tutto a sinistra per evidenziare il problema di ricerca delle radici o del punto fisso:

$$u_{k+1} = u_k + h\Phi(t_k, u_k, u_{k+1}, h) \iff u_{k+1} - u_k - h\Phi(t_k, u_k, u_{k+1}, h) = 0$$

Un approccio standard per risolvere questa equazione implicita rispetto a u_{k+1} è implementare il metodo di iterazione di punto fisso applicato alla funzione $g(x) = u_k + h\Phi(t_k, u_k, x, h)$:

(i) Si pone $x_0 = u_k$.

(ii) Per $m \geqslant 0$, si calcola il nuovo iterato $x_{m+1} = u_k + h\Phi(t_k, u_k, x_m, h)$.

(iii) Se $\|x_{m+1} - x_m\| \leqslant \mathrm{TOL}$, l'algoritmo termina e si accetta $u_{k+1} = x_{m+1}$

Per garantire la convergenza di questo schema iterativo, richiediamo che g sia una contrazione. Verifichiamolo calcolando la sua costante di Lipschitz (dove L è la costante di Lipschitz di Φ rispetto al terzo argomento):

$$\|g(x) - g(y)\| = \|h\Phi(t_k, u_k, x, h) - h\Phi(t_k, u_k, y, h)\| = |h| \cdot \|\Phi(t_k, u_k, x, h) - \Phi(t_k, u_k, y, h)\|$$

Poiché il passo di integrazione è positivo ($h > 0$), la condizione affinché g sia una contrazione si riduce a $hL < 1$. Se tale condizione è rispettata, il teorema delle contrazioni assicura il corretto funzionamento del metodo.

Esempio 4.5.1. *Nel caso del punto medio, si ha* $x_{m+1} = u_k + hf(t_k, \frac{u_k + x_m}{2})$.

È opportuno scegliere la tolleranza in funzione del passo di integrazione h, in quanto la presenza di un errore di troncamento intrinseco del metodo numerico rende inutile imporre una tolleranza iterativa eccessivamente stringente.

4.6 Caso del sistema predatore-preda

Consideriamo due funzioni $u, v : [0, T] \to \mathbb{R}$, dove u rappresenta il numero di prede e v il numero di predatori e siano $u(0) = u_0 \geqslant 0$ e $v(0) = v_0 \geqslant 0$ i dati iniziali. Dati $a, b, c, d \geqslant 0$, il sistema evolve seguendo questa legge: $\begin{cases} u'(t) = (a - bv(t))u(t) \\ v'(t) = (cu(t) - d)v(t) \end{cases}$

La soluzione esatta prevede che $(u(t), v(t))$ formano orbite chiuse periodiche. Eulero in avanti tende ad allargarsi perché usa la derivata prima della soluzione, quindi segue la tangente al grafico. Eulero all'indietro tende a restringersi perché è come "partire dal punto successivo e fare Eulero in avanti in rewind, quindi ha il comportamento opposto". Invece, trapezi e punto medio funzionano meglio, sia perché hanno ordine maggiore sia perché sono una sorta di via di mezzo.