Fabio Bonsignore 20/02/25 *versione* 3.2

0. INTRODUZIONE

Tutto il materiale trattato in questo file ha per fonti le note e le lezioni del prof. Alessandro Russo, integrate con ricerche su vari forum, sul sito di MATLAB e simili.

1. ARITMETICA FLOATING POINT

Rappresentazione dei numeri nel calcolatore

Definizione 1.1. Un problema algoritmico può essere risolto con un processo dal numero finito di operazioni, un problema non algoritmico non ha un processo standard ma viene risolto fornendo un'approssimazione del risultato reale.

L'obiettivo del calcolo numerico è trovare algoritmi efficienti per risolvere un dato problema, riducendo l'errore dovuto alle approssimazioni e il tempo dovuto alle operazioni. Per iniziare, bisogna studiare come il calcolatore memorizza i numeri e svolge le operazioni di base.

Definizione 1.2. L'insieme dei numeri floating point, ovvero i numeri memorizzati nel calcolatore, è caratterizzato da una quaterna $F(\beta, t, L, U)$, dove β è la base rispetto alla quale sono memorizzati i numeri, t è la lunghezza della mantissa, ovvero il numero di cifre significative, e L e U sono, rispettivamente, il minimo e il massimo esponente della base. Tutti i numeri hanno dunque la forma $(\pm 0.\propto_1 \propto_2 \ldots \propto_t)_\beta * \beta^e, L \leq e \leq U$.

Il calcolatore usa il sistema $F(2,53,-1021,+1024)$.

Scegliendo opportunamente la base, anche i numeri irrazionali rispetto alla base decimale possono avere una rappresentazione finita.

Teorema 1.3. Un numero razionale scritto come frazione ridotta ai minimi termini $\frac{p}{q}$ ha una rappresentazione finita in base β se e solo se i fattori primi del denominatore q dividono β.

Dimostrazione

Sia q della forma $q = m^a n^b$, con m e n fattori primi di β. Allora $\frac{p}{q} = \frac{p}{m^a n^b} = \frac{p(m^{t-a} n^{t-b})}{(mn)^t}$; dunque il denominatore ha rappresentazione finita perché $mn \mid \beta$.

Notazione. Da qui in avanti, x indicherà la quantità esatta e xa la quantità approssimata.

Notazione. La sigla WLOG significa "without loss of generality" e si usa quando un'ipotesi aggiuntiva non inficia sulla validità di un'affermazione.

Definizione 1.4. L'errore assoluto è la quantità $|x - xa|$, l'errore relativo è la quantità $\frac{|x-xa|}{|x|}$.

Definizione 1.5. Un segmento è l'intervallo tra due potenze della base successive. In uno stesso segmento, i numeri sono equispaziati da una distanza detta spacing e ogni segmento contiene lo stesso quantitativo di numeri. Lo spacing tra la potenza p e la potenza $p + 1$ è β^{p+1-t}.

Definizione 1.6. L'underflow è un fenomeno che si verifica quando il numero che voglio rappresentare è più piccolo della minima potenza L. Viceversa, l'overflow è quanto va oltre la massima potenza U.

Se un numero non sta nell'insieme F, allora avviene il fenomeno di arrotondamento per permetterne la rappresentazione.

Definizione 1.7. La funzione $fl: R \to F$ associa a ogni numero reale x il numero floating point più vicino xa. Nel caso di equidistanza tra due floating point si usa il rounding to even (RTE), ovvero si sceglie il numero che ha per ultima cifra di mantissa un numero pari.

Operazioni nel calcolatore

Studiamo ora la stabilità delle operazioni sulla base dell'errore relativo.

Teorema 1.8. L'errore relativo non dipende dal numero x da rappresentare.

Dimostrazione

WLOG prendiamo x > 0 e consideriamo la sua rappresentazione in base β $(0.\propto_1 \propto_2 \ldots \propto_t)_\beta * \beta^e$, notiamo da subito che $x < \beta^e$ e la prima cifra di mantissa non può essere nulla, dunque $x = (0.\propto_1 \propto_2 \ldots \propto_t)_\beta * \beta^e \geq (0.100\ldots)_\beta * \beta^e = \beta^{e-1}$. Usando la formula dello spacing con p = e – 1;

$|x - fl(x)| \leq \frac{spacing}{2} = \frac{\beta^{e-t}}{2}$. Sapendo che $x \geq \beta^{e-1} => \frac{1}{x} \leq \beta^{1-e}$ e dunque $\frac{|x-fl(x)|}{|x|} \leq \frac{\beta^{1-t}}{2}$.

Definizione 1.9. La quantità $u = \frac{\beta^{1-t}}{2}$ è detta roundoff unit ed è l'errore massimo che commetto durante la rappresentazione.

Abbiamo ottenuto che $\frac{fl(x)-x}{x} = \varepsilon_x,\ |\varepsilon_x| \leq u => fl(x) = x(1+\varepsilon_x)$. Studiamo ora le operazioni 'elementari' e il loro errore relativo. Il prodotto di due errori è trascurabile e verrà usata questa approssimazione.

Somma: $\frac{|x+y-[x(1+\varepsilon_x)+y(1+\varepsilon_y)](1+\varepsilon_s)|}{|x+y|} = \frac{|x\varepsilon_x+y\varepsilon_y+(x+y)\varepsilon_s+x\varepsilon_x\varepsilon_s+y\varepsilon_y\varepsilon_s|}{|x+y|} \approx$
$\frac{|(x+y)\varepsilon_s+x\varepsilon_x+y\varepsilon_y|}{|x+y|} \leq |\varepsilon_s| + \frac{|x|}{|x+y|} * |\varepsilon_x| + \frac{|y|}{|x+y|}|\varepsilon_y| \leq u(1 + \frac{|x|}{|x+y|} + \frac{|y|}{|x+y|})$.
Dunque, la somma è instabile se x e y hanno lo stesso ordine di grandezza e sono di segno opposto oppure se hanno entrambi un ordine di grandezza 'piccolo'. La somma di numeri grandi è stabile, mentre la sottrazione e la somma di numeri piccoli è instabile.

Prodotto (e quoziente): $\frac{|xy-[x(1+\varepsilon_x)y(1+\varepsilon_y)](1+\varepsilon_p)|}{|x+y|} \leq |1-(1+u)^3| \approx 3u$
Dunque, il prodotto e il quoziente sono molto stabili.

Nel processore sono implementate tutte le funzioni elementari, quindi hanno lo stesso costo computazionale delle altre operazioni.

2. ALGORITMO DI GAUSS E DECOMPOSIZIONE PA = LU

Sistemi lineari e scelta del pivot

Notazione. Da questo punto in poi, il simbolo A' indicherà la trasposta di A.

Definizione 2.1. Il metodo di Gauss consente di risolvere un sistema lineare di equazioni trasformandolo in un sistema triangolare equivalente mediante l'uso di tre tipi di operazioni 'elementari': lo scambio di due righe, la moltiplicazione di una riga per uno scalare e la somma di una riga con il multiplo di un'altra.

Definizione 2.2. Il pivot è il primo elemento non nullo della riga.

L'algoritmo di Gauss è molto efficiente ed è relativamente semplice da implementare, l'unico problema è quando l'elemento al passaggio k-esimo a_{kk} è nullo. È necessario implementare un metodo che scambi la riga k-esima con una riga opportuna il cui pivot sta sulla k-esima colonna. La scelta del pivot è un passaggio fondamentale, in quanto può cambiare drasticamente l'efficienza e la stabilità dell'algoritmo. Distinguiamo quattro tipi di pivoting a scopo didattico:

- **Pivot algebrico**: scelgo la prima riga che trovo con coefficiente non nullo (quella più naturale per una persona).
- **Pivot parziale**: scelgo la riga con il coefficiente più grande in modulo.
- **Pivot totale**: scelgo su tutta la matrice la riga e la colonna con il coefficiente più grande in modulo.
- **Antipivot**: scelgo la riga con il coefficiente non nullo più piccolo in modulo.

L'antipivot è la scelta peggiore ed empiricamente produce l'errore più grande, mentre la correttezza del pivot algebrico dipende fortemente dalla matrice. L'analisi degli altri due verrà rimandata al capitolo 4, basti sapere per ora che nella gran parte dei casi è più conveniente il pivot parziale.

Decomposizione PA = LU

L'algoritmo di Gauss può essere interpretato come decomposizione della matrice dei coefficienti in delle matrici più semplici: una matrice P ortogonale di permutazione e due matrici L e U, rispettivamente triangolare inferiore e superiore.

Teorema 2.3. Una matrice A quadrata non singolare può essere riscritta come $A = P'LU$, dove le matrici P,L,U sono della forma descritta in precedenza.

Dimostrazione

La dimostrazione si basa sul trovare delle matrici che ricoprano il ruolo delle operazioni nell'algoritmo di Gauss.
Lo scambio di righe è ottenuto dalla moltiplicazione a sinistra per matrici P_{ij}, matrici identità con la i-esima e la j-esima riga scambiata. Notiamo che la moltiplicazione a destra produce lo stesso effetto ma sulle colonne.
Prendiamo ora in analisi le matrici M_{ij}, matrici identità tali che $m_{ij} = -\frac{a_{ij}}{a_{jj}}$. La

moltiplicazione a sinistra per la matrice A somma alla i-esima riga di A la j-esima riga di A scalata di un fattore m_{ij}. Per la scelta di m_{ij}, va a cancellare l'elemento j-esimo della i-esima riga e a modificare i restanti. Se facciamo il prodotto di tutte le M_{ij} per un j fissato, otteniamo la matrice M_i che è la matrice identità con gli m_{ij} trasportati dalle matrici del prodotto. Inoltre, l'inversa della matrice M_i presenta i moltiplicatori cambiati di segno.
Se non ci fossero permutazioni, il prodotto di tutte queste matrici, M, per la matrice A produrrebbero proprio una matrice triangolare superiore e, moltiplicando da entrambe le parti per l'inversa L, otteniamo la tesi.

La presenza di eventuali permutazioni porta ad una forma $M_n(P_n\left(\dots\left(M_2\left(P_2(M_1(P_1A))\right)\right)\right)$.

Intercaliamo tra ogni M_i e P_i il prodotto $P_{i+1}P_{i+1}$, operazione che posso fare perché è la matrice identità. Osserviamo che $P_{i+1}M_iP_{i+1}$ ha come effetto lo scambio secondo la regola determinata dalla matrice di permutazione dei soli moltiplicatori. Alla fine, dunque, otterrò il prodotto $MPA = U$ e invertendole ottengo la tesi.

Se volessi implementare il pivot totale, dovrei tenere in conto il prodotto a destra per delle matrici di permutazione Q, ottenendo lo stesso risultato con simili ragionamenti.

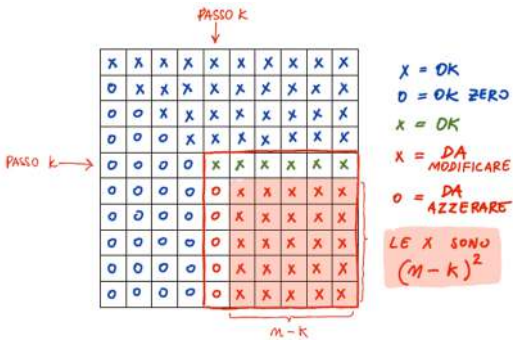
Applicazioni

Calcolo del determinante. Sfrutto che $\det(P) = (-1)^p, \det(L) = 1, \det(U) = \prod_{i=1}^{n} u_{ii}$, dove p è il numero di scambi, e applico il teorema di Binet.

Risoluzione di sistemi lineari. $Ax = b \Rightarrow P'LUx = b \Rightarrow LUx = Pb$. Dunque, devo risolvere i sistemi lineari $Ly = Pb\ e\ Ux = y$.

Inverso di una matrice. Detta X l'inversa di A, $AX = A\left[x^{(1)}, \dots, x^{(n)}\right] = I_n = [e^{(1)}, \dots, e^{(n)}]$, ovvero devo risolvere n sistemi lineari.

Complessità di Gauss



Consideriamo la matrice A al passo k. Devo calcolare $n - k$ moltiplicatori e modificare $(n - k)^2$ con una somma e un prodotto per ciascuno. Dunque, $\#op(k) = (n - k) + 2(n - k)^2$ e

$$\#op = \sum_{k=1}^{n-1} \#op(k) = \sum_{k=1}^{n-1} n - k + 2\sum_{k=1}^{n-1} (n-k)^2 = \sum_{k=1}^{n-1} k + \sum_{k=1}^{n-1} k^2$$
$$= \frac{n(n-1)}{2} + \frac{2}{6} n(n-1)[2(n-1)+1] \sim \frac{2}{3} n^2$$

3. Norme di matrici

Prodotti scalari e norme

Definizione 3.1. Un prodotto scalare su V è una funzione $<*>: V^2 \to R$ simmetrica, bilineare e positiva.

Definizione 3.2. Una norma su V è una funzione $||*|| : V \to R$ scalabile, positiva e che soddisfa la disuguaglianza triangolare.

Da ogni prodotto scalare è sempre possibile definire una norma come $\left|\left|v\right|\right| = \sqrt{< v, v >}$, mentre per l'inverso è necessario aggiungere una condizione ulteriore.

Teorema 3.3. Sia $||*||$ una norma su uno spazio vettoriale V. Allora esiste un prodotto scalare che definisce questa norma se e solo se la norma verifica la regola del parallelogramma

$$2\left|\left|u\right|\right|^2 + 2\left|\left|v\right|\right|^2 = \left|\left|u + v\right|\right|^2 + \left|\left|u - v\right|\right|^2$$

Norme su R^n e norme di matrici

Le norme di vettori più comuni sono le p-norme, definite come $\left|\left|x\right|\right|_p = \left(\sum_{i=1}^n x_i^p\right)^{\frac{1}{p}}$. Le norme usate più comunemente sono:

- **Norma euclidea** (o norma-2).
- $\left|\left|x\right|\right|_1 = \sum_{i=1}^n |x_i|$.
- $\left|\left|x\right|\right|_\infty = \max_{i \in \{1,\dots,n\}} |x_i|$.

Per una p-norma si deve dimostrare che vale la disuguaglianza di Minkowski:

$$\left(\sum_{i=1}^n |x_i + y_i|^p\right)^{\frac{1}{p}} \leq \left(\sum_{i=1}^n |x_i|^p\right)^{\frac{1}{p}} + \left(\sum_{i=1}^n |y_i|^p\right)^{\frac{1}{p}}$$

Definizione 3.4. Due norme si dicono equivalenti se esistono due costanti c e C positive tali che $c\left|\left|x\right|\right|_1 \leq \left|\left|x\right|\right|_2 \leq C\left|\left|x\right|\right|_1$

Definizione 3.5. Sia $A \epsilon Mat_n(R)$ e si consideri la matrice A come operatore lineare. Si definisce la norma naturale della matrice A come $\left|\left|A\right|\right|_p = \sup_{x \neq 0} \frac{\left|\left|Ax\right|\right|_p}{\left|\left|x\right|\right|_p}$.

Per le norme naturali, valgono le seguenti proprietà:

- $\left|\left|Ax\right|\right|_p \leq \left|\left|A\right|\right|_p \left|\left|x\right|\right|_p$
- $\left|\left|AB\right|\right|_p \leq \left|\left|A\right|\right|_p \left|\left|B\right|\right|_p$
- $\left|\left|I_n\right|\right|_p = 1$

Altre norme, non naturali (che dunque non rispettano le proprietà di prima!), sono le seguenti:

$$\left|\left|A\right|\right|_F = \left(\sum_{i,j=1}^{n} a_{ij}^2\right)^{\frac{1}{2}}$$ **(Norma di Frobenius)**

$$\left|\left|A\right|\right|_{MAX} = \max_{i,j\in\{1,\dots,n\}} |a_{ij}|$$ **(Norma del massimo)**

Definizione 3.6. Il raggio spettrale di una matrice $A\epsilon Mat_n(R)$ è il massimo autovalore in modulo associato alla matrice A.
Seppure non sia una norma, il raggio spettrale è scalabile e positivo. Inoltre

Un interessante risultato che lo lega alle norme di matrici è che $\left|\left|A\right|\right|_2 = \sqrt{\rho(A' * A)}$, se A è simmetrica si ha $\left|\left|A\right|\right|_2 = \sqrt{\rho(A^2)} = \sqrt{[\rho(A)]^2} = \rho(A)$.

Le norme naturali per p = 1 e p = ∞ possono essere calcolate semplicemente in modo esplicito.

$$\left|\left|A\right|\right|_1 = \max_{j\epsilon\{1,\dots,n\}} \sum_{i=1}^{n} |a_{ij}|$$

$$\left|\left|A\right|\right|_\infty = \max_{i\epsilon\{1,\dots,n\}} \sum_{j=1}^{n} |a_{ij}|$$

Teorema 3.7. Se una matrice A ha tutti gli autovalori reali, allora $\rho(A) \leq \left|\left|B\right|\right|_p$ per ogni scelta di p.

Dimostrazione

$$\left|\left|A\right|\right|_p = \sup_{x \neq 0} \frac{\left|\left|Ax\right|\right|_p}{\left|\left|x\right|\right|_p} \geq \frac{\left|\left|\lambda_{max} v_\lambda\right|\right|_p}{\left|\left|v_\lambda\right|\right|_p} \geq |\lambda_{max}| = \rho(A)$$

4. Stabilità dell'algoritmo di Gauss

Fattori dell'errore

Definizione 4.1. Il growth factor è un fattore legato alla scelta del pivot e è definito come

$$\gamma_n = \frac{\max_{i,j,k} |a_{ij}^{(k)}|}{\max_{i,j} |a_{ij}|}$$

Definizione 4.2. Il numero di condizionamento di una matrice A è $cond_p(A) = \left||A|\right|_p \left||A^{-1}|\right|_p$.

Notiamo che $cond_p(A) = \left||A|\right|_p \left||A^{-1}|\right|_p \geq \left||AA^{-1}|\right|_p = 1.$

Vale inoltre, per matrici simmetriche, che $cond_2(A) = \frac{\rho(A)}{\rho(A^{-1})}$, ovvero il rapporto tra il modulo dell'autovalore massimo e minimo.

Analisi della stabilità

Per analizzare l'errore nell'algoritmo di Gauss facciamo uso della tecnica di "Backwards Error Analysis", ovvero lavoriamo in R al posto di F nell'ipotesi di avere una perturbazione dei dati, in questo caso o del vettore dei termini noti o della matrice dei coefficienti.

Teorema 4.3. L'errore relativo della soluzione di un sistema lineare, dovuto a una perturbazione del termine noto, è controllato come $\frac{\left||x-x_a|\right|_p}{\left||x|\right|_p} \leq cond_p(A) \frac{\left||\delta b|\right|_p}{\left||b|\right|_p}$.

Dimostrazione

Siano x e xa rispettivamente le soluzioni di $(1)\ Ax = b$ e $(2)\ Ax = b + \delta b$.

Lavorando con le norme su (1) otteniamo $\left||b|\right|_p = \left||Ax|\right|_p \leq \left||A|\right|_p \left||x|\right|_p \Rightarrow \frac{1}{\left||x|\right|_p} \leq \frac{\left||A|\right|_p}{\left||b|\right|_p}$.

Consideriamo ora (2) $Ax_a = b + \delta b \Rightarrow x_a = A^{-1}b + A^{-1}\delta b$, ma so che $A^{-1}b = x$, dunque $x_a = x + A^{-1}\delta b \Rightarrow x_a - x = A^{-1}\delta b \Rightarrow$

$\left||x - x_a|\right|_p = \left||A^{-1}\delta b|\right|_p \leq \left||A^{-1}|\right|_p \left||\delta b|\right|_p$. Moltiplichiamo le due condizioni e otteniamo $\frac{\left||x-x_a|\right|_p}{\left||x|\right|_p} \leq \frac{\left||A|\right|_p \left||A^{-1}|\right|_p}{\left||b|\right|_p} \left||\delta b|\right|_p = cond_p(A) \frac{\left||\delta b|\right|_p}{\left||b|\right|_p}$.

Ometto la dimostrazione del caso della perturbazione della matrice dei coefficienti in quanto del tutto analoga.

Può essere dimostrato che $\frac{\left||E|\right|_p}{\left||A|\right|_p}, \frac{\left||\delta b|\right|_p}{\left||b|\right|_p} \leq \varphi(n)\gamma_n u$, dove $\varphi(n)$ è il numero di operazioni.

Per quanto concerne il growth factor, può essere dimostrato che $\gamma_n \leq 2^{n-1}$ per il pivot parziale e

$\gamma_n \leq n$ per il pivot totale. Seppure in prima analisi possa sembrare che il pivot parziale non sia molto stabile, in verità nella maggior parte dei casi si ha che $\gamma_n \sim \sqrt{n}$ per il pivot parziale e

quel limite superiore è raggiunto solo in casi patologici; come quello dato dalla matrice generata dalla funzione $gfpp(n)$, che è la matrice I_n con la sostituzione $a_{in} = 2^{i-1}$.

5. DECOMPOSIZIONE DI CHOLESKY

Matrici simmetriche e segnatura

Definizione 5.1. Una matrice A si dice simmetrica se $A = A'$.

Definizione 5.2. Una matrice si dice definita positiva se $< Ax, x > \geq 0$ e $< Ax, x > = 0 <=> x = 0$.

Le matrici simmetriche definite positive hanno alcune proprietà particolarmente utili:

- **A è invertibile.** Infatti, essere definita positiva garantisce che ker(A) = {0}.
- $\boldsymbol{a_{ii} > 0}$ $\forall i \in \{1, \dots, n\}$. Infatti, il prodotto scalare con i vettori della base canonica deve essere positivo.

Inoltre, data una matrice simmetrica, è possibile stabilire se è definita positiva grazie ai seguenti risultati.

Teorema 5.3. Una matrice A simmetrica è definita positiva se e solo se tutti i minori di Nord-Ovest sono positivi.

Teorema 5.4. Una matrice A simmetrica è definita positiva se e solo se tutti i suoi autovalori sono strettamente positivi.

Decomposizione di Cholesky

Teorema 5.5. Sia A una matrice simmetrica e definita positiva. Allora esiste una matrice R triangolare superiore, unica a meno di segni sulla diagonale, tale che $A = R'R$.

Dimostrazione

La dimostrazione è costruttiva, dunque presenta il procedimento, facilmente integrabile su MATLAB, per costruire la matrice R.

Riscrivo la matrice A a blocchi come $A = \begin{bmatrix} \propto & a' \\ a & A_* \end{bmatrix}$ e suppongo di avere $R = \begin{bmatrix} \rho & r' \\ 0 & R_* \end{bmatrix}$; dove *a* e *r* sono vettori di R^{n-1}, $\propto$ e ρ sono numeri reali e A_* e R_* sono sotto matrici ottenute togliendo la prima riga e la prima colonna. Svolgiamo i calcoli $R'R$ ed eguagliamo blocco a blocco con la matrice A.

$$R'R = \begin{bmatrix} \rho^2 & \rho r' \\ \rho r & rr' + R'_* R_* \end{bmatrix} = \begin{bmatrix} \propto & a' \\ a & A_* \end{bmatrix} = A$$

Dalla prima equazione otteniamo $\rho = \pm\sqrt{\alpha}$, per convenzione prendiamo il segno più ma è arbitrario. Dalla seconda (o terza) equazione otteniamo $r = \frac{1}{\rho} a = \frac{1}{\sqrt{\alpha}} a$. Infine, dall'ultima equazione otteniamo $R'_* R_* = A_* - \frac{1}{\propto} aa'$. Se mostro che $R'_* R_*$ è ancora simmetrica e definita positiva, posso ripetere il processo induttivamente e ottengo la tesi.

Simmetrica. $(R'_* R_*)' = \left(A_* - \frac{1}{\propto} aa'\right)' = A'_* - \frac{1}{\propto} aa' = A_* - \frac{1}{\propto} aa'$, in quanto A_* è simmetrica perché sottomatrice principale di una matrice simmetrica.

Definita positiva. Sia $y \in R^{n-1}$ un vettore non nullo e considero

$(1) < R'_* R_* y, y > = y' A_* y - \frac{1}{\propto}(y'a)^2.$

Sia ora k uno scalare e costruisco il vettore $\begin{pmatrix} k \\ y \end{pmatrix}$ e usiamolo per fare il prodotto scalare con A.

$(k\ y')A\begin{pmatrix} k \\ y \end{pmatrix} = (k\ y')\begin{bmatrix} \propto k & a'y \\ ka & A_* y \end{bmatrix} = \propto k^2 + 2k(y'a) + y' A_* y > 0\ \forall k \epsilon R$, in quanto A è definita positiva. Dunque, il discriminante deve essere negativo

$(y'a)^2 - \propto (y' A_* y) < 0 => y' A_* y - \frac{1}{\propto}(y'a)^2$. Tornando a (1), deduciamo che il prodotto scalare è positivo e dunque la matrice è definita positiva.

Sistemi lineari con Cholesky

Supponendo di aver decomposto una matrice A simmetrica definita positiva con l'algoritmo di Cholesky A = R'R, risolvere il sistema $Ax = b$ è equivalente a risolvere $R'Rx = b$; ovvero prima risolvo $R'y = b$ e poi $Rx = y$.

6. METODI ITERATIVI PER SISTEMI LINEARI

Introduzione ai metodi stazionari

Definizione 6.1. Una matrice A si dice sparsa se i suoi elementi non nulli sono molto minori a quelli nulli.

Per le matrici sparse, i metodi visti finora presentano il fenomeno del fill-in, ovvero il numero di elementi non nulli aumenta drasticamente e di conseguenza lo spazio occupato in memoria. L'introduzione dei metodi iterativi permette di evitare questo fenomeno e di ottenere comunque una soluzione, corretta entro una certa tolleranza.

Definizione 6.2. I metodi diretti sono tali per cui la soluzione viene calcolata in un numero finito di passi. Viceversa, i metodi iterativi generano una successione di vettori che tende alla soluzione all'infinito.

Definizione 6.3. Un metodo iterativo è detto stazionario se la successione delle soluzioni ha la forma $x^{(k+1)} = Bx^{(k)} + d$, dove B è detta la matrice di iterazione del metodo e sia B che d rimangono costanti durante le iterazioni.

Teorema 6.4. Un metodo iterativo stazionario $x^{(k+1)} = Bx^{(k)} + d$ converge se e solo se $\rho(B) < 1$.

Dimostrazione

Se il metodo converge, segue che esiste un x_* punto fisso per la successione. Ma allora

$$x^{(k+1)} - x_* = Bx^{(k)} + d - Bx - d = B\left(x^{(k)} - x_*\right) = B^2\left(x^{(k-1)} - x_*\right) = \cdots$$
$$= B^{k+1}(x^{(0)} - x_*)$$

Vogliamo che l'ultimo termine tenda a zero per ogni scelta di $x^{(0)}$, dunque deve essere $B^{k+1} \to 0$. Si può dimostrare la tesi anche senza questa ipotesi, quindi WLOG supponiamo che B sia diagonalizzabile $B = CDC^{-1} => B^2 = CDC^{-1}CDC^{-1} = CD^2C^{-1} => B^{k+1} = CD^{k+1}C^{-1}$ e la matrice D tende alla matrice nulla (e quindi la sua norma è nulla indipendentemente dalla norma) se e solo se ogni elemento sulla diagonale è minore di 1; dunque, $\rho(B) < 1$.

Metodo di Jacobi

Tra i metodi qui presentati, il metodo di Jacobi è il più semplice. L'idea è, sotto l'ipotesi che la diagonale della matrice sia non nulla, di ricavare dalla i-esima riga $\sum_{j=1}^{n} a_{ij}x_j = b_i$ il termine

$x_i = \frac{1}{a_{ii}}(b_i - \sum_{\substack{j=1 \\ j\neq i}}^{n} a_{ij}x_j)$ e dunque la successione è $x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{\substack{j=1 \\ j\neq i}}^{n} a_{ij}x_j{}^{(k)}\right)$.

Scomponendo A = L + D + U, in forma matriciale è equivalente a $x^{(k+1)} = D^{-1}[b - (L+U)x^{(k)}]$. Per Jacobi, otteniamo dunque $B_J = -D^{-1}(L+U), d_J = D^{-1}b$.

Convergenza di Jacobi

Vale un interessante condizione sufficiente ma non necessaria per la convergenza di questo metodo, che ha in comune con i successivi metodi di questo capitolo.

Teorema 6.5. Sia A strettamente diagonale dominante, per righe o per colonne. Allora il metodo di Jacobi converge per ogni scelta del dato iniziale.

Dimostrazione

Per (6.4), per convergere deve essere $\rho(B) < 1$ ma sappiamo per (3.7) che $\rho(A) < \left|\left|B\right|\right|_p$ per ogni scelta di p; dunque, consideriamo p = ∞ e imponiamo sia minore di 1.

$$B_J = \begin{cases} -\frac{a_{ij}}{aii}, & altrimenti \\ 0, & i = j \end{cases}.$$

$$\left|\left|B_J\right|\right|_\infty = \max_{i\epsilon\{1,\dots,n\}} \sum_{\substack{j=1 \\ j\neq i}}^{n} \left|\frac{a_{ij}}{a_{ii}}\right| = \max_{i\epsilon\{1,\dots,n\}} \frac{1}{|a_{ii}|} \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}| < 1 <=> \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}| < |a_{ii}|$$

Metodo di Gauss-Seidel

Partendo dall'idea del metodo di Jacobi, ora prendiamo in considerazione anche il fatto che abbiamo già calcolato le componenti precedenti alla i-esima nelle precedenti iterazioni, dunque

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)} \right)$$

In forma matriciale, diventa $x^{(k+1)} = D^{-1}\left[b - Lx^{(k+1)} - Ux^{(k)}\right] =>$
$x^{(k+1)} = (D + L)^{-1}(b - Ux^{(k)})$.

Dunque, $B_{GS} = -(D + L)^{-1}U, d_{GS} = (D + L)^{-1}b$.

Convergenza di Gauss-Seidel e confronto con Jacobi

Oltre al risultato di (6.5), vale anche la seguente condizioni per matrici particolari.

Teorema 6.6. Sia A simmetrica e definita positiva. Allora il metodo di Gauss-Seidel converge per ogni scelta del dato iniziale.

Nonostante siano molto simili, la loro convergenza non è sempre simultanea. Ad esempio, si considerino le due matrici $\begin{bmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \\ 1 & 2 & -3 \end{bmatrix}$ e $\begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 1 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & 1 \end{bmatrix}$. La prima converge solo con Jacobi, mentre la seconda solo con Gauss-Seidel. Dal (6.4), possiamo dedurre che minore è il raggio

di convergenza, più veloce sarà la convergenza. Vale questo risultato che lega i due metodi, ma prima è necessario dare una nuova definizione.

Definizione 6.7. Una matrice quadrata che è nulla al di fuori degli elementi sulla diagonale e immediatamente sopra e sotto la diagonale si dice tridiagonale.

Teorema 6.8. Sia A una matrice tridiagonale e consideriamo i metodi di Jacobi e Gauss-Seidel. Allora

$$\rho(B_{GS}) = \rho\left(B_J\right)^2$$

Di conseguenza, per matrici tridiagonali, i due metodi convergono o divergono simultaneamente e, se convergono, allora Gauss-Seidel è più rapido.

Metodo Successive Over Relaxation

Il metodo SOR è una variante di Gauss-Seidel che mira ad introdurre un parametro di 'rilassamento' ω per diminuire il raggio spettrale. Il metodo segue questa successione:

$$x_i^{(k+1)} = \frac{\omega}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)}\right) + (1-\omega)\mathrm{x}_\mathrm{i}^{(k)}$$

In forma di metodo stazionario, si ha $B_{SOR} = (D + \omega\mathrm{L})^{-1}[(1-\omega)\mathrm{D} - \omega\mathrm{U}]$ e $d_{SOR} = \omega(\mathrm{D} + \omega\mathrm{L})^{-1}b.$

Teorema 6.9 (di Kahan). Se nel metodo SOR uso un parametro ω ≤ 0 o ω ≥ 2, allora il metodo diverge.

Dimostrazione

$$\det(B_{SOR}) = \frac{\det[(1-\ \omega)\mathrm{D} - \omega\mathrm{U}]}{\det\ (D + \omega\mathrm{L})} = \frac{\det[(1-\omega)\mathrm{D}]}{\det(D)} = (1-\omega)^{\mathrm{n}}$$

Dato che il determinante è il prodotto degli autovalori, se $|1-\omega|^{\mathrm{n}} \geq 1 <=>\ \omega \leq 0$ o $\omega \geq 2$, allora c'è almeno un autovalore maggiore o uguale ad 1 e dunque il metodo diverge.

Teorema 6.10 (di Ostrowski-Reich). Se A è una matrice simmetrica e definita positiva, allora il metodo SOR converge per ogni valore del parametro ω.

Criterio di arresto per metodi iterativi

Abbiamo stabilito che i metodi iterativi convergono all'infinito, quindi dobbiamo assegnare una tolleranza e fermarci quando l'errore relativo è inferiore a essa. Tuttavia, non conosciamo la soluzione esatta, dunque non possiamo calcolare l'errore relativo. Ci sono due principali criteri per capire quando arrestarsi: l'incremento tra due iterate e il residuo.

Definizione 6.11. Il residuo nei metodi iterativi è la quantità, dipendente dall'iterata,

$$r^{(k)} = Ax^{(k)} - b$$

Incremento tra due iterate. $x^{(k+1)} - x_* = B\left(x^{(k)} - x_*\right) =>$

$$\left|\left|x^{(k+1)}-x_*\right|\right|_p \le \left||B|\right|_p \left|\left|\left(x^{(k)}-x_*\right)\right|\right|_p = \left||B|\right|_p \left|\left|x^{(k)}-x^{(k+1)}+x^{(k+1)}-x_*\right|\right|_p$$

$$\le \left||B|\right|_p \left(\left|\left|x^{(k+1)}-x^{(k)}\right|\right|_p + \left|\left|x^{(k+1)}-x_*\right|\right|_p\right) =>$$

$$=> \left|\left|x^{(k+1)}-x^{(k)}\right|\right|_p \ge \frac{1-\left||B|\right|_p}{\left||B|\right|_p}\left|\left|x^{(k+1)}-x_*\right|\right|_p => \left|\left|x^{(k+1)}-x_*\right|\right|_p$$

$$\le \frac{\left||B|\right|_p}{1-\left||B|\right|_p}\left|\left|x^{(k+1)}-x^{(k)}\right|\right|_p$$

Questo procedimento usa il fatto che $0 < \left||B|\right|_p < 1$ durante le divisioni.

Residuo. $Ax^{(k)} = b + r^{(k)}$, quindi è come se avessimo un sistema perturbato dal residuo e usiamo (4.3).

$\frac{\left||x_*-x^{(k)}|\right|_p}{\left||x_*|\right|_p} \le cond_p(A)\frac{\left||r^{(k)}|\right|_p}{\left||b|\right|_p} = cond_p(A)\frac{\left||Ax^{(k)}-b|\right|_p}{\left||b|\right|_p}$, dunque, basta porre

$$\frac{\left||Ax^{(k)}-b|\right|_p}{\left||b|\right|_p} \le \frac{TOL}{cond_p(A)}.$$

7. AUTOVALORI

Localizzare gli autovalori

I metodi che analizzeremo in questo capitolo per trovare gli autovalori sono di tipo iterativo; dunque, è utile avere una stima di un valore iniziale per far partire il metodo.

Teorema 7.1 (Cerchi di Gershgorin). Sia A una matrice quadrata e x un autovettore di A. Detto $x_{imax} = \max_{i\in\{1,..,n\}} |x_i|$, allora posso costruire un cerchio che contiene l'autovalore associato, con centro in $a_{imaximax}$ e raggio $\sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{imaxj}|$.

Dimostrazione

Considero $Ax = \lambda x$ e considero la i_{max}-esima riga

$$\lambda x_{imax} = \sum_{j=1}^{n} a_{imaxj}x_j \Leftrightarrow |\lambda - a_{imaximax}||x_{imax}| = \left|\sum_{\substack{j=1 \\ j\neq i_{max}}}^{n} a_{imaxj}x_j\right| \leq \sum_{\substack{j=1 \\ j\neq imax}}^{n} |a_{imaxj}||x_j| \Rightarrow$$

$$\Rightarrow |\lambda - a_{imaximax}| \leq \sum_{\substack{j=1 \\ j\neq imax}}^{n} |a_{imaxj}|\frac{|x_j|}{|x_{imax}|} \leq \sum_{\substack{j=1 \\ j\neq imax}}^{n} |a_{imaxj}|$$

Teorema 7.1.2. Sia A una matrice quadrata, costruisco n cerchi con centro in a_{ii} e raggio $\sum_{\substack{j=1 \\ J\neq i}}^{n} |a_{ij}|$. Se λ è un autovalore, allora λ appartiene all'unione dei cerchi; cerchi isolati contengono un unico autovalore. Se m cerchi si intersecano, la loro unione ne contiene m.

Un altro modo di approcciare il problema della localizzazione è quello di calcolare il polinomio caratteristico della matrice $p_A(\lambda) = \det(\lambda I_n - A)$. Nonostante il problema di cercare gli autovalori come zeri del polinomio caratteristico sia instabile e inefficiente, è possibile rappresentare il polinomio usando MATLAB per poter stimare gli zeri mediante il grafico.

Metodo delle potenze e varianti

Il metodo delle potenze è un metodo iterativo che permette di calcolare l'autovalore di modulo massimo di una matrice. Il metodo consiste nel prendere un vettore $q^{(0)}$ che abbia almeno una componente non nulla rispetto all'autovettore corrispondente e si itera il processo $z^{(k)} = Aq^{(k-1)}$, normalizzando il risultato per evitare l'overflow $q^{(k)} = \frac{z^{(k)}}{\left||z^{(k)}|\right|_2}$.

L'aritmetica floating point, con un sufficiente numero di iterazioni, garantirà che ci abbia componente non nulla rispetto all'autovettore grazie all'approssimazione. Inoltre, useremo

l'ipotesi che l'autovalore massimo in modulo sia unico. In merito a ciò, riporto di seguito un risultato interessante.

Definizione 7.2. Il quoziente di Rayleigh è il rapporto $\mu = \frac{<Av,v>}{<v,v>}$. Se v è l'autovettore corrispondente all'autovalore di modulo massimo (minimo), allora il quoziente restituisce quell'autovalore.

Teorema 7.3 (di Perron-Frobenius). Una matrice quadrata con coefficienti strettamente positivi ammette un unico autovalore di modulo massimo.

Teorema 7.4. Sia A una matrice quadrata, della quale supponiamo abbia un unico autovalore λ massimo in modulo. Sia inoltre $q^{(0)}$ un vettore con una componente non nulla rispetto all'autovettore x corrispondente a λ. Allora, il metodo delle potenze converge.

Dimostrazione

$$q^{(k)} = \frac{z^{(k)}}{\left||z^{(k)}|\right|_2} = \frac{Aq^{(k-1)}}{||Aq^{(k-1)}||_2} = \frac{A\left(\frac{z^{(k-1)}}{\left||z^{(k-1)}|\right|_2}\right)}{\left\|A\left(\frac{z^{(k-1)}}{\left||z^{(k-1)}|\right|_2}\right)\right\|_2} = \frac{Az^{(k-1)}}{\left||Az^{(k-1)}|\right|_2}$$

$$= \frac{A^2q^{(k-2)}}{\left||A^2q^{(k-2)}|\right|_2} = \cdots = (1)\ \frac{A^kq^{(0)}}{||A^kq^{(0)}||_2}$$

So che $(2)\ q^{(0)} = \alpha_1 x + \sum_{i=2}^{n} \alpha_i x_i$, con x_i autovettori, e per ipotesi $\alpha_1 \neq 0$.
Inoltre, $(3)\ Ax_i = \lambda_i x_i => A^k x_i = \lambda_i^k x_i$.
Usiamo (2) e (3) per calcolare $A^k q^{(0)} = \alpha_1 \lambda^k x + \sum_{i=2}^{n} \alpha_i \lambda_i^k x_i =$
$= \alpha_1 \lambda^k \left(x + \sum_{i=2}^{n} \frac{\alpha_i}{\alpha_1} \left(\frac{\lambda_i}{\lambda}\right)^k x_i\right)$ e indichiamo con $y^{(k)} = \sum_{i=2}^{n} \frac{\alpha_i}{\alpha_1} \left(\frac{\lambda_i}{\lambda}\right)^k x_i$ e, essendo λ massimo in modulo, $y^{(k)} \to 0$. Usiamo questa informazione in (1) $q^{(k)} = \frac{A^kq^{(0)}}{\left||A^kq^{(0)}|\right|_2} =$

$= \frac{\alpha_1\lambda^k(x+y^{(k)})}{\left||\alpha_1\lambda^k(x+y^{(k)})|\right|_2} = signum(\alpha_1\lambda^k)\frac{x+y^{(k)}}{\left||x+y^{(k)}|\right|_2}$, quindi osserviamo che $q^k \to x$.
Calcoliamo il quoziente di Rayleigh, con la semplificazione che $< q^{(k)}, q^{(k)} > = 1$. Dunque,

$$\mu_k = < Aq^{(k)}, q^{(k)} > =$$

$$= < signum(\alpha_1\lambda^k)\frac{Ax + Ay^{(k)}}{\left||x + y^{(k)}|\right|_2}, signum(\alpha_1\lambda^k)\frac{x + y^{(k)}}{\left||x + y^{(k)}|\right|_2} > =$$

$$= \frac{signum(\alpha_1\lambda^k)^2}{\left||x + y^{(k)}|\right|_2^2} < \lambda x + Ay^{(k)}, x + y^{(k)} > =$$

$$= \frac{\lambda \left||x|\right|_2^2}{\left||x + y^{(k)}|\right|_2^2} + \frac{\lambda < x, y^{(k)} > + < Ay^{(k)}, x > + < Ay^{(k)}, y^{(k)} >}{\left||x + y^{(k)}|\right|_2^2} \to \lambda$$

Teorema 7.5. Se λ è l'autovalore di modulo minimo di una matrice A, allora $\frac{1}{\lambda}$ è l'autovalore di modulo massimo di A^{-1}.

Il metodo delle potenze inverse è una variazione del metodo delle potenze, che permette di trovare l'autovalore minimo in modulo. Si basa su (7.5), quindi consiste nell'applicare il metodo delle potenze a A^{-1}.

Il metodo delle potenze inverse con shift è un'altra variazione che permette di trovare l'autovettore in modulo più vicino a un valore h scelto dall'utente. Voglio trovare l'autovalore più piccolo di $A - hI_n$, ovvero applico il metodo delle potenze a $(A - hI_n)^{-1}$.

Dipendenza degli autovalori dalle perturbazioni della matrice

Vogliamo ora cimentarci nello studio del condizionamento del problema della ricerca degli autovalori, usando la BEA come per i sistemi lineari.

Teorema 7.6 (di Bauer-Fike). Sia A una matrice diagonalizzabile $A = XDX^{-1}$, sia E una perturbazione di A e μ un autovalore di $A + E$. Allora $\min_{i\epsilon\{1,\dots,n\}} |\lambda_i - \mu| \leq cond_p(X)\left||E|\right|_p$.

Dimostrazione

Supponiamo che μ non sia un autovalore di A, altrimenti è banale. Sappiamo che $A + E - \mu I_n$ è singolare, quindi $X^{-1}(A + E - \mu I_n)X = D + X^{-1}EX - \mu I_n$ è ancora singolare; dunque, esiste un vettore x non nullo tale per cui

$$0 = [(D - \mu I_n) + X^{-1}EX]x = (D - \mu I_n)x + X^{-1}EXx$$

So che $D - \mu I_n$ è invertibile, dunque $(D - \mu I_n)^{-1}X^{-1}EXx = -x$. Prendo le p-norme di entrambi i membri.

$$\left||x|\right|_p \leq \left||(D - \mu I_n)^{-1}|\right|_p \left||X^{-1}|\right|_p \left||E|\right|_p \left||X|\right|_p \left||x|\right|_p \Rightarrow 1 \leq cond_p(X)\left||E|\right|_p \left||(D - \mu I_n)^{-1}|\right|_p$$

$$\Rightarrow \frac{1}{\left||(D-\mu I_n)^{-1}|\right|_p} \leq cond_p(X)\left||E|\right|_p.$$

Sapendo che $\left||(D - \mu I_n)^{-1}|\right|_p = \frac{1}{\min_{i\epsilon\{1,\dots,n\}}|\lambda_i - \mu|}$, in quanto la p-norma di una matrice diagonale è il massimo elemento in modulo, concludo con la tesi.

Velocità di convergenza

Ricordando la dimostrazione della convergenza del metodo, notiamo che la velocità dipende da quanto rapidamente $y^{(k)}$ tende a 0, dunque più sono distanziati gli autovalori da quello massimo in modulo, più rapidamente il metodo converge.

Per matrici simmetriche, si può dimostrare che il metodo converge più rapidamente.

Infine, si può dimostrare che, se l'autovalore massimo in modulo non è unico, il metodo converge comunque ma più lentamente.

Criterio di arresto per la ricerca degli autovalori

Mantenendo immutato il criterio dell'incremento tra due iterate, analizziamo il criterio del residuo in questo caso; sotto l'ipotesi che la matrice sia diagonalizzabile.

Definizione 7.7. Il residuo per gli autovalori è la quantità, dipendente dall'iterata, $r^{(k)} = Aq^{(k)} - \lambda^{(k)}q^{(k)}$.

Residuo. $r^{(k)} = XDX^{-1}q^{(k)} - \lambda^{(k)}q^{(k)} = X\left(D - \lambda^{(k)}I_n\right)X^{-1}q^{(k)}$. Supponendo che $\lambda^{(k)}$ non sia un autovalore di A, $q^{(k)} = X^{-1}\left(D - \lambda^{(k)}I_n\right)^{-1}Xr^{(k)}$ e prendiamo le norme da entrambi i membri. $\left||q^{(k)}|\right|_p \leq cond_p(X)\left|\left|\left(D - \lambda^{(k)}I_n\right)^{-1}\right|\right|_p \left||r^{(k)}|\right|_p = \frac{cond_p(X)\left||r^{(k)}|\right|_p}{\min_{i\epsilon\{1,\dots,n\}}|\lambda^{(k)} - \lambda_i|}$

$$=> \min_{i\epsilon\{1,\dots,n\}}\left|\lambda^{(k)} - \lambda_i\right| \leq \frac{cond_p(X)\left||Aq^{(k)} - \lambda^{(k)}q^{(k)}|\right|_p}{\left||q^{(k)}|\right|_p}$$

8. ZERI DI FUNZIONE

Zeri di polinomi

Lo studio degli zeri di funzione è un argomento circoscritto (per funzioni di una variabile), in quanto esiste un metodo molto efficiente per risolvere il problema che è il metodo di Brent, usato da gran parte dei programmi. Per iniziare ad interfacciarci al problema, consideriamo il caso più semplice dello studio degli zeri di polinomi.

Definizione 8.1. La companion matrix di un polinomio p_n è una matrice quadrata $C(p_n)$, il cui polinomio caratteristico coincide con p_n.

Detto $p_n = [a_0, \dots, a_{n-1}, 1]$, polinomio monico di grado n rappresentato in forma vettoriale;

una possibile scelta per la companion matrix è $C(p_n) = \begin{bmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \ddots & \vdots & \vdots \\ \vdots & \ddots & \ddots & 0 & -a_{n-2} \\ 0 & \cdots & 0 & 1 & -a_{n-1} \end{bmatrix}$

Teorema 8.2. La matrice definita come sopra è una companion matrix.

Dimostrazione

Dimostriamolo per induzione sul grado di p_n.

P(3): $\begin{bmatrix} 0 & 0 & -a_0 \\ 1 & 0 & -a_1 \\ 0 & 1 & -a_2 \end{bmatrix} p_C(\lambda) = \det\big(\lambda I_3 - C(p_3)\big) = \lambda[\lambda(\lambda + a_2) + a_1] + a_0(0 + 1) =$

$$= a_0 + a_1\lambda + a_2\lambda^2 + \lambda^3.$$

P(n): Sviluppo la prima riga con Laplace e ottengo

$p_C(\lambda) = \lambda \det\big(\lambda I_{n-1} - C(p_{n-1})\big) + a_0(-1)^{n-1} \det(-I_{n-1})$, con $C(p_{n-1})$ che va da a_1 ad a_{n-1}. Applico l'ipotesi induttiva e ottengo

$$\lambda(a_1 + a_2\lambda + \cdots + a_{n-1}\lambda^{n-2} + \lambda^{n-1}) + a_0(-1)^{n-1}(-1)^{n-1} =$$
$$= a_0 + a_1\lambda + \cdots + a_{n-1}\lambda^{n-1} + \lambda^n = p_n(\lambda)$$

Con questo nuovo concetto, possiamo ricondurre lo studio degli zeri di un polinomio allo studio degli autovalori di una matrice, che sappiamo essere un problema ben condizionato.

Metodo di bisezione

Definizione 8.3. Dati una funzione f e un intervallo $[a, b]$, si dice che $[a, b]$ è una bracket per f se $f(a)f(b) < 0$.

Considero una funzione continua a valori reali su un intervallo $[a, b]$, bracket per f. Per il teorema di esistenza degli zeri, so che nell'intervallo $[a, b]$ esiste almeno uno zero di f.

L'idea è quindi di dimezzare l'ampiezza dell'intervallo con un metodo iterativo, andando a creare una nuova bracket con il punto medio e uno dei due precedenti estremi.

Criterio di arresto per la bisezione

Considerando che l'ampiezza dell'intervallo dimezza a ogni iterazione, si ha che

$$L_0 = b - a, L_1 = \frac{L_0}{2}, L_2 = \frac{L_1}{2} = \frac{L_0}{4}, \dots, L_i = \frac{L_0}{2^i} = \frac{b-a}{2^i}$$

Voglio che la grandezza sia minore della tolleranza, dunque $\frac{b-a}{2^{i+1}} < TOL =>$

$$i > \log_2\left(\frac{b-a}{TOL}\right) - 1$$

Concludiamo dunque, con un cambio di base, che ogni 10 iterazioni guadagniamo 3 cifre decimali.

Osserviamo anche che, nonostante la convergenza sia di tipo lineare, essa è garantita indipendentemente dalla grandezza della bracket.

Metodo di Newton

Il metodo di Newton si basa sull'idea di approssimare la funzione con la sua retta tangente, individuare l'intersezione della retta con l'asse x e con questo nuovo punto iterare il metodo.

Come idea, ha il potenziale di convergere molto rapidamente, ma la convergenza non è garantita. Inoltre, il metodo richiede di conoscere l'espressione esplicita della derivata della funzione. La successione del metodo è

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

Convergenza di Newton

Vediamo due risultati: il primo dà una condizione sufficiente per la convergenza, mentre il secondo dà informazioni sulla velocità di convergenza.

Teorema 8.4. Sia f una funzione definita su un intervallo I, di classe $C^2(I)$ e sia $x_p \in I$ tale che $f(x_p) = 0$ e $f'(x_p) \neq 0$. Allora esiste un intorno I_δ di x_p tale per cui in ogni punto la successione $\{x_k\}$ è ben definita (derivata sempre non nulla) e converge a x_p.

Dimostrazione

Definisco la funzione di iterazione $\varphi(x) = x - \frac{f(x)}{f'(x)}$ e ne calcolo la derivata

$\varphi'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2} = \frac{f(x)f''(x)}{[f'(x)]^2}$ e noto che $\varphi'(x_p) = 0$ e che φ' e continua, dunque

$$\forall \varepsilon < 1 \; \exists \delta | \varphi'(x) < \varepsilon \; \forall x \epsilon \; [x_p - \delta, x_p + \delta]$$

Consideriamo ora l'errore al passo $k+1$ è $e_{k+1} = x_p - x_{k+1} = \varphi(x_p) - \varphi(x_k)$. Dato che la funzione è derivabile, applico Lagrange e ottengo $e_{k+1} = \varphi'(\vartheta_k)e_k$, ma sappiamo

che ϑ_k sta in I_δ, quindi $e_{k+1} < \varepsilon e_k = \varepsilon\varphi'(\vartheta_{k-1})e_{k-1} < \varepsilon^2 e_{k-1} < \cdots < \varepsilon^{k+1}e_0$, che per $k \to \infty$ tende a 0, dunque la successione è ben definita e tende a x_p.

Teorema 8.5. Sia f una funzione definita su un intervallo I, di classe $C^3(I)$ e sia $x_p \in I$ tale che $f(x_p) = 0$ e $f'(x_p) \neq 0$. Allora $\lim_{k\to\infty} \frac{e_{k+1}}{e_k^2} = \frac{\varphi''(x_p)}{2}$.

Dimostrazione

Scrivo lo sviluppo di Taylor arrestato al secondo ordine

$$\varphi(x_k) = \varphi\left(x_p + (x_k - x_p)\right) = \varphi(x_p) + (x_k - x_p)\varphi'(x_p) + \frac{\varphi''(\vartheta_k)}{2}(x_k - x_p)^2$$

$$x_{k+1} = x_p + \frac{e_k^2}{2}\varphi''(\vartheta_k) \Rightarrow e_{k+1} = e_k^2\frac{\varphi''(\vartheta_k)}{2} \Rightarrow \lim_{k\to\infty}\frac{e_{k+1}}{e_k^2} = \frac{\varphi''(x_p)}{2}$$

Dunque, quando il metodo converge, converge quadraticamente ed è dunque più efficiente della bisezione.

Metodo delle secanti

Il metodo delle secanti è una variante del metodo di Newton volto a sopperire l'impossibilità di calcolare la derivata esplicitamente per alcune funzioni.

Al posto di approssimare la funzione con la retta tangente, l'idea è di approssimarla con una secante; quindi, servono due punti (e non più uno) per far partire l'algoritmo. Sostituendo nella formula di Newton la derivata con la secante, otteniamo questa formula

$$x_{k+1} = x_k - f(x_k)\frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}$$

Metodo di Brent

Il metodo di Brent è un metodo iterativo che mette insieme il metodo delle secanti e quello di bisezione (MATLAB mette anche l'interpolazione quadratica inversa), in modo da convergere nel migliore dei casi come le secanti, nel peggiore un po' peggio rispetto alla bisezione, ma è garantita la convergenza.

L'idea dietro all'algoritmo è di calcolare ogni volta entrambe le iterate e di selezionare come nuovo punto quello che determina l'intervallo più piccolo. Gli 'ingredienti' usati dal metodo a ogni passaggio sono tre punti a, b, e c; tali che $|f(b)| \leq |f(c)|$ e {b,c} forma una bracket. L'algoritmo procede iterando questi passaggi:

0) Consideriamo gli incrementi in modo che $m = b + dm, s = b + ds, d = b + dd$.
1) Controllo che la bracket sia più piccola della tolleranza, se lo è ho finito.
2) Applico il metodo delle secanti con {a,b} per calcolare l'incremento $ds = -f(b)\frac{b-a}{f(b)-f(a)}$, accertandomi che $f(b) \neq f(a)$. Se lo sono, prendo direttamente bisezione.

3) Applico il metodo di bisezione con {b,c} per calcolare l'incremento $dm = \frac{c-b}{2}$.
4) Se $|ds| \leq |dm|\ e\ signum(ds) = signum(dm)$, significa che con le secanti ho reso più piccolo l'intervallo rispetto a $b + dm$. In quel caso, pongo $dd = ds$, altrimenti pongo $dd = dm$.
5) Verifico se $abs(dd) < TOL$, in tal caso lo modifico per non essere troppo piccolo $dd = TOL * \frac{signum(dd)}{2}$.
6) Calcolo d e imposto i nuovi a, b e c: $na = b$ e $nb = d$. Per nc, devo scegliere tra c e b in modo che formi una bracket con nb.
7) Imposto $a = na, b = nb, c = nc$ e controllo che $|f(b)| \leq |f(c)|$, se non lo sono li scambio.

9. INTERPOLAZIONE POLINOMIALE

Importanza dell'interpolazione

Molto spesso ci troviamo a studiare funzioni che o sono molto complesse o sono addirittura semplici set di dati; quindi, il processo diventa complicato e si rischia di incorrere in errori. L'idea dell'interpolazione è di ricondurre in qualche modo lo studio di funzione allo studio di funzioni più semplici, quali sono i polinomi.

Definizione 9.1. Sia $\{x_i, y_i\}$ un set di dati e sia f una funzione continua. Diremo che f è una funzione interpolante per il set se per ogni punto del set vale che $f(x_i) = y_i$.

Definizione 9.2. Sia $C^0([a,b])$ l'insieme delle funzioni continue sull'intervallo [a,b] e definisco la norma dell'estremo superiore come $||f||_\infty = \max_{x\in[a,b]} |f(x)|$. L'insieme definito poc'anzi dotato della norma dell'estremo superiore è uno spazio di Banach.

Teorema 9.3 (di Stone-Weierstrass). Sia $f: [a,b] \to R$ una funzione continua. Allora $\forall \varepsilon > 0\ \exists p(x) \in R[x]$ tale che $||f-p||_\infty < \varepsilon$.

Un esempio sono i polinomi di Bernstein, che convergono uniformemente per ogni funzione continua ma lo fanno lentamente. Consideriamoli nell'intervallo $[0,1]$.

Definizione 9.4. Detto n un numero naturale, gli $n+1$ polinomi elementari di Bernstein sono $B_{k,n}(x) = \binom{n}{k} x^k (1-x)^{n-k}, k \in \{0, \dots, n\}$. Sia ora $f: [0,1] \to R$ una funzione continua, allora il suo polinomio di Bernstein è $B_n(f)(x) = \sum_{k=0}^{n} f\left(\frac{k}{x}\right) B_{k,n}(x)$.

Possiamo raffinare il precedente risultato con il seguente teorema, ma prima diamo un'altra definizione.

Definizione 9.5. Dato un insieme $\{x_0, \dots, x_n\}$, si definisce la matrice di Vandermonde la matrice quadrata di ordine $n+1$ tale che $V = \begin{bmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{bmatrix}$.

Teorema 9.6. Se tutte le ascisse dell'insieme $\{x_0, \dots, x_n\}$ sono distinte, allora la matrice di Vandermonde non è singolare.

Dimostrazione

Il determinante è mutilineare, dunque tolgo ad ogni colonna x_0 volte la precedente. In questo modo, la prima riga è il primo versore della base canonica e lo sviluppo con la Laplace. Iterando il processo ottengo che $\det(V) = \prod_{i<j}(x_j - x_i),\ \ j \in \{1, \dots, n\}$.

Teorema 9.7 (esistenza e unicità della best approximation). Sia $f: [a, b] \to R$ una funzione continua. Allora per ogni numero naturale n esiste un unico polinomio p_n^* di grado minore o uguale di n tale che $\left||f - p_n^*|\right|_\infty \leq \left||f - p_n|\right|, \forall p_n \in R_n[x]$.

Dimostrazione (1)

Considero l'applicazione $T: R_n[x] \to R^{n+1}$, che associa a un polinomio il vettore della valutazione in $\{x_0, \dots, x_n\}$. È una mappa lineare tra spazi finiti, se mostro che è iniettiva allora è un isomorfismo.

Sappiamo che, se il polinomio si annulla in $\{x_1, \dots, x_n\}$, allora è divisibile per questi e dunque è della forma $p_n(x) = C(x - x_1) \dots (x - x_n)$. Per annullarsi anche in x_0, deve essere $C = 0$, ovvero l'unico polinomio che si annulla in tutti i punti di grado minore o uguale a n è il polinomio nullo.

Dimostrazione (2)

Sia $\{x_i, y_i\}$ il set di dati da interpolare e considero il polinomio $p_n(x) = \sum_{i=0}^{n} a_i x^i$. Deve essere
$p_n(x_i) = y_i$ quindi devo risolvere $n + 1$ equazioni lineari nei coefficienti del polinomio, equivalente al sistema $V(\{x_i\})a = (y_i)$. Dunque, se i punti sono distinti, ammette un'unica soluzione per (9.6).

Polinomi di Lagrange

Uno dei modi più efficienti per risolvere il problema dell'interpolazione è l'uso dei polinomi di Lagrange.

Definizione 9.8. Sia $\{x_0, \dots, x_n\}$ un insieme di nodi, allora si definiscono gli $n + 1$ polinomi elementari di Lagrange come gli unici polinomi di grado n tali che $l_i(x_j) = \delta_{ij}$.

Sappiamo che $l_i(x) = C \prod_{\substack{j=0 \\ j \neq i}}^{n} (x - x_j)$ e $l_i(x_i) = 1$, dunque $C = \frac{1}{\prod_{\substack{j=0 \\ j \neq i}}^{n} (x_i - x_j)}$ e

$$l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^{n} \frac{x - x_j}{x_i - x_j}$$

Definizione 9.9. Dato un set di dati $\{x_i, y_i\}$, definisco il polinomio d'interpolazione come

$$p_n(x) = \sum_{i=0}^{n} y_i l_i(x)$$

Inoltre, questo polinomio è unico. Infatti, se $q_n(x)$ fosse un altro polinomio che risolve lo stesso problema di interpolazione, allora la loro differenza sarebbe un polinomio di grado minore o uguale a n che si annulla in $n + 1$ punti distinti, dunque è il polinomio nullo.

Notiamo anche che $\sum_{i=0}^{n} l_i(x) \equiv 1$, in quanto $\sum_{i=0}^{n} l_i(x_j) = 1$ per ogni nodo e l'unico polinomio che vale 1 in $n+1$ nodi è il polinomio costante 1.

Confronto tra base canonica e base dei polinomi elementari

Abbiamo dunque raggiunto, usando due modi diversi, lo stesso risultato. Ci chiediamo ora qual è la migliore scelta.

Per quanto riguarda la base canonica, devo risolvere un sistema lineare in $O(n^3)$ operazioni per ottenere il polinomio e poi devo tenere conto della valutazione. Esiste un algoritmo che permette di calcolare la valutazione in $O(n)$, detto algoritmo di Horner.
L'idea è di riscrivere il polinomio come
$p(x) = a_0 + x\left(a_1 + x\left(a_2 + \cdots + x(a_{n-1} + xa_n)\right)\right)$ e valutarlo usando un ciclo for.

Per quanto riguarda la rappresentazione di Lagrange, l'algoritmo per determinare il polinomio è più stabile ma la valutazione prevede il costo di n polinomi elementari di Lagrange, dunque $O(n^2)$.

Tuttavia, possiamo modificare la rappresentazione di Lagrange in modo da avere lo stesso costo di Horner.

Rappresentazione baricentrica di Lagrange

Definiamo $\lambda_i = \frac{1}{\prod_{\substack{j=0 \\ j\neq i}}^{n}(x_i - x_j)}$ in modo che $l_i(x) = \lambda_i \prod_{\substack{j=0 \\ j\neq i}}^{n}(x - x_j)$ e

$w_{n+1}(x) = \prod_{j=0}^{n}(x - x_j)$

$\Rightarrow \prod_{\substack{j=0 \\ j\neq i}}^{n}(x - x_j) = \frac{w_{n+1}(x)}{x - x_i}$. A questo punto, $p_n(x) = w_{n+1}(x)\sum_{i=0}^{n}\frac{\lambda_i}{x - x_i}y_i$. Sapendo che $\sum_{i=0}^{n} l_i(x) \equiv 1$, abbiamo $1 = w_{n+1}(x)\sum_{i=0}^{n}\frac{\lambda_i}{x - x_i} \Rightarrow w_{n+1}(x) = \frac{1}{\sum_{i=0}^{n}\frac{\lambda_i}{x - x_i}}$.

La rappresentazione diventa $p_n(x) = \frac{\sum_{i=0}^{n}\frac{\lambda_i}{x - x_i}y_i}{\sum_{i=0}^{n}\frac{\lambda_i}{x - x_i}}$, valida se non valuto in un nodo.

Scelta dei nodi

La scelta dei nodi è un momento cardinale nella risoluzione del problema di interpolazione, poiché determina una sostanziale differenza nella stabilità. Definiamo tre tipi di nodi (gli ultimi due saranno definiti nell'intervallo [-1,1]):

- **Nodi equispaziati.** Detto $h = \frac{b-a}{n}$, definisco gli n+1 nodi come $x_i = a + ih$, $i \in \{0, \dots, n\}$

- **Nodi di Chebychev del secondo tipo.** Al posto di dividere l'intervallo in segmenti equispaziati, divido l'angolo in parti uguali secondo la legge $x_i = \cos\left(\frac{i\pi}{n}\right)$, $i \in \{0, \dots, n\}$.
- **Nodi di Chebychev del primo tipo.** Sono simili a quelli del secondo tipo ma non comprendono gli estremi dell'intervallo. Seguono la legge $x_i = \cos\left(\frac{(2i+1)\pi}{2(n+1)}\right)$, $i \in \{0, \dots, n\}$.

Nel caso dei nodi di Chebychev del secondo tipo (in un qualunque intervallo), i coefficienti λ_i hanno la forma $\lambda_i = (-1)^i$, con il primo e l'ultimo divisi per 2.

Nel caso dei nodi di Chebychev del primo tipo (in un qualunque intervallo), i coefficienti λ_i hanno la forma $\lambda_i = \sin\left(\frac{(2\mathrm{i}+1)\mathrm{pi}}{2\mathrm{n}+2}\right)(-1)^{\mathrm{i}}$ (forse).

Vediamo ora un risultato sul condizionamento dipendentemente dai nodi.

Definizione 9.10. La costante di Lebesgue è la norma della somma dei moduli dei polinomi elementari di Lagrange $\Lambda = \left|\left|\sum_{i=0}^{n}|l_i(x)|\right|\right|_\infty$.

Teorema 9.11. Siano $\{x, y\} \to p(x)$ un set di dati e $\{x, y + \delta y\} \to p^*(x)$ una sua perturbazione, ciascuno con il suo polinomio interpolatorio. Allora $\frac{||p-p^*||_\infty}{||p||_\infty} \leq \Lambda \frac{||\delta y||_\infty}{||y||_\infty}$.

Dimostrazione

Iniziamo scrivendo entrambi i polinomi.

$$p(x) = \sum_{i=0}^{n} y_i l_i(x), p^*(x) = \sum_{i=0}^{n} y_i l_i(x) + \delta y_i l_i(x)$$

$$|p - p^*| = \left|\sum_{i=0}^{n} \delta y_i l_i(x)\right| \leq \sum_{i=0}^{n} |\delta y_i||l_i(x)| \leq \left|\left|\delta y\right|\right|_\infty \sum_{i=0}^{n}|l_i(x)|$$

$$\left|\left|p - p^*\right|\right|_\infty \leq \left|\left|\delta y\right|\right|_\infty \Lambda => \frac{\left|\left|p - p^*\right|\right|_\infty}{\left|\left|p\right|\right|_\infty} \leq \Lambda \frac{||\delta y||_\infty}{\left|\left|y\right|\right|_\infty},$$

$$in\ quanto\ \left|\left|p\right|\right|_\infty \geq \max_i |p(x_i)| = \left|\left|y\right|\right|_\infty$$

Si può dimostrare che la costante di Lebesgue in $[-1,1]$ è $\Lambda \sim \frac{2^{n+1}}{e\, n \log(n)}$, per i nodi equispaziati, e $\Lambda \sim \frac{2}{\pi}\log(n+1)$, per i nodi di Chebychev del secondo tipo.

Interpolazione di funzioni

Per concludere questo capitolo, trattiamo i risultati principali sull'interpolazione di funzioni.

Teorema 9.12. Sia $f \in C^{n+1}([a, b])$, siano $\{x_0, \dots, x_n\}$ punti distinti di [a,b] e sia p il polinomio interpolante di f usando quei punti come nodi. Allora

$$e(x) = f(x) - p(x) = \frac{f^{n+1}(\theta_x)}{(n+1)!} w_{n+1}(x)$$

Dimostrazione

Considero un x diverso dai nodi e definisco la funzione $G_x(y) = e(y) - \frac{w_{n+1}(y)}{w_{n+1}(x)} e(x)$. Noto che G_x si annulla negli $n+1$ nodi e in x; dunque, per il teorema di Rolle esistono $n+1$ punti in cui la sua derivata prima si annulla. Iteriamo il processo induttivamente fino a ottenere che esiste un unico punto θ_x in cui $G_x^{(n+1)}$ si annulla.

Consideriamo le derivata successive di G_x e notiamo che $w_{n+1}(y)$ è un polinomio monico di grado $n+1$, dunque la sua derivata $(n+1)$ −esima sarà proprio $(n+1)!$, mentre per la derivata di e(y) sappiamo che p ha grado minore di n+1, quindi $e^{(n+1)}(y) = f^{(n+1)}(y)$.

Uniamo le informazioni e otteniamo che $0 = G_x^{(n+1)}(\theta_x) = f^{(n+1)}(\theta_x) - \frac{(n+1)!}{w_{n+1}(x)} e(x)$

$$=> e(x) = \frac{f^{n+1}(\theta_x)}{(n+1)!} w_{n+1}(x)$$

Se passiamo alla norma, capiamo che l'errore dipende dalla scelta dei nodi in quanto è controllato da $\left|\left|w_{n+1}(x)\right|\right|_\infty$

Teorema 9.12.1. Se $f \in C^\infty([a,b])$ e le sue derivate sono tutte limitate, allora la successione dei polinomi interpolanti di f converge per ogni scelta dei nodi.

Fenomeno di Runge. Se proviamo a interpolare nell'intervallo $[-5,5]$ la funzione $f(x) = \frac{1}{1+x^2}$, notiamo che per i nodi di Chebychev si avrà una convergenza rapida, mentre i nodi equispaziati presentano delle grandi oscillazioni agli estremi dell'intervallo.

Teorema 9.13 (di Faber). Data una qualunque successione di nodi in un intervallo chiuso $[a,b]$ esiste sempre una funzione $f(x)$ che genera una sequenza di polinomi di interpolazione che non convergono ad f nella norma del massimo.

Teorema 9.14. Sia f una funzione Lipschitziana sull'intervallo $[a,b]$. Allora la successione dei polinomi di interpolazione di f basata sui nodi di Chebychev converge a f nella norma del massimo.

---

10. FUNZIONI SPLINE

Spline

Quando abbiamo dei nodi che non possiamo cambiare, usare le tecniche di interpolazioni precedenti possano non dare risultati efficaci. Per questo, bisogna introdurre nuove tecniche per ovviare a questo problema.

Definizione 10.1. Sia $\{x_1, \dots, x_n\}$ un insieme di nodi ordinati in ordine crescente. Si definisce spline di ordine k una funzione che in ciascun sottointervallo $[x_i, x_{i+1}]$ è un polinomio di grado minore o uguale a k e tale per cui nei nodi i tratti si raccordano fino alla $(k-1)$ −esima derivata.

Chiediamoci ora da quanti parametri liberi è determinata una spline. Se ho una spline di ordine k, allora ho $(N-1)$ polinomi di grado al massimo k, dunque $(N-1)(k+1)$ parametri liberi. Chiedere che si raccordino fino all'ordine $k-1$ implica chiedere che siano continue e che si raccordino (da sinistra e da destra tranne il primo e l'ultimo) fino alla $(k-1)$ −esima derivata, dunque $(\mathrm{N}-2)(\mathrm{k}-1+1) = \mathrm{k}(\mathrm{N}-2)$.

Dunque, una spline di ordine k è definita a meno di $N+k-1$ parametri, che permettono di imporre il passaggio per N punti avanzando $k-1$ parametri liberi.

11. MINIMI QUADRATI E FATTORIZZAZIONE QR

Sistemi sovradeterminati

Definizione 11.1. Un sistema lineare il cui numero di equazioni è maggiore del numero di incognite è detto sovradeterminato.

Spesso ci troviamo a voler interpolare $n+1$ punti con un polinomio di grado $d < n$, ma questo problema non presenta sempre una soluzione, in quanto il sistema corrispondente è sovradeterminato, con matrice dei coefficienti una matrice di Vandermonde generalizzata $V \in M_{n,d+1}(R)$.

Non avendo sempre soluzione, possiamo traslare il problema a

$$minimizzare \sum_{i=0}^{n} |p_d(x_i) - y_i|^2 => minimizzare \left||Va - y|\right|_2^2$$
$$=> minimizzare \left||Va - y|\right|_2$$

Approcceremo questo problema seguendo due strade diverse, per poi osservare lo stesso risultato.

Approccio analitico

Considero la funzione $F: R^n \to R \mid F(x_1, \dots, x_n) = \sum_{i=1}^{d+1}\left(\sum_{j=1}^{n} v_{ij}x_j - b_i\right)^2$ e risolvo il problema di minimizzare questa funzione. Per farlo, ricaviamo il gradiente e l'Hessiana. Chiamiamo $m = d+1$ per comodità.

$$\frac{\partial F}{\partial x_k} = 2\left[\sum_{i=1}^{m}\left(\sum_{j=1}^{n} v_{ij}x_j - b_i\right)v_{ik}\right] = 2\left[\sum_{j=1}^{n}\left(\sum_{i=1}^{m} v_{ik}v_{ij}\right)x_j - \sum_{i=1}^{m} v_{ik}b_i\right]$$

$$(1)\ \sum_{i=1}^{m} v_{ik}v_{ij} = \sum_{i=1}^{m} v'_{ki}v_{ij} = (V'V)_{kj}$$

$$(2)\ \sum_{i=1}^{m} v_{ik}b_i = \sum_{i=1}^{m} v'_{ki}b_i = (V'b)_k$$

$$\frac{\partial F}{\partial x_k} = 2\left[\sum_{j=1}^{n}(V'V)_{kj}x_j - (V'b)_k\right]$$

Concludiamo che $\nabla F = 2(V'Vx - V'b)$. Il gradiente deve annullarsi, dunque $V'Vx = V'b$.

Definizione 11.2. Le equazioni $V'Vx = V'b$ sono dette equazioni normali.

Ora dobbiamo verificare che l'hessiana sia definita positiva.

$$\frac{\partial^2 F}{\partial x_k \partial x_l} = 2\sum_{i=1}^{m}(V'V)_{kj}\delta_{jl} = 2(V'V)_{kl}$$

$$H_F = 2V'V$$

$$< H_F x, x > = < V'Vx, x > = < Vx, Vx > = \left|\left|Vx\right|\right|_2^2 = 0 <=> Vx = 0$$

La richiesta che dobbiamo fare è che V sia un monomorfismo come applicazione lineare, e questo avviene se le colonne di V sono linearmente indipendenti.

Questa condizione, applicata al problema dei minimi quadrati, è verificata perché la sottomatrice di ordine m è una matrice di Vandermonde, che quindi ha determinante non nullo. Segue che l'intera matrice ha rango m.

Approccio geometrico

Dal punto di vista geometrico, le colonne di V generano un sottospazio lineare. La soluzione a^* deve essere tale da minimizzare la distanza tra Va^* e y, quindi Va^* deve essere la proiezione ortogonale di y sul sottospazio. Dunque, il vettore congiungente Va^* e y deve essere ortogonale al sottospazio

$< Va^* - y, Va > = 0 \ <=> < V'(Va^* - y), x > = 0 \ \forall a \in R^n$, ovvero

$$V'(Va^* - y) = 0 <=> V'Va^* = V'y.$$

Inciso: proiezione ortogonale

Con le equazioni normali, posso avere un'espressione esplicita della proiezione ortogonale di un vettore su un sottospazio lineare. Prendiamo $A = V, b = y, x^* = a^*$ e abbiamo che

$$\Pi_A b = Ax^* = A(A'A)^{-1}A'b$$

Noto che è idempotente, simmetrico e il vettore risultante appartiene effettivamente al sottospazio, dunque è una proiezione ortogonale.

Decomposizione QR

Risolvere le equazioni normali con la decomposizione di Cholesky è instabile, in quanto la matrice $V'V$ è tendenzialmente mal condizionata, quindi si usa un'altra decomposizione.

Teorema 11.3. Una matrice $A \in M_{m,n}(R)$ con colonne linearmente indipendenti può essere decomposta nel prodotto di una matrice Q e una matrice R: la matrice Q ha le stesse dimensioni di A e le sue colonne sono ortonormali, mentre la matrice R è quadrata triangolare superiore di ordine n. Tale decomposizione è unica a meno di segni.

Dimostrazione

La dimostrazione si basa sulla decomposizione di Cholesky, ma non viene usata per i motivi nominati prima. Visto che A'A è simmetrica definita positiva, posso decomporla come $A'A = R'R$. Prendo $Q = AR^{-1}$, devo mostrare che è ortonormale.

$$Q'Q = (AR^{-1})'AR^{-1} = (R^{-1})'A'AR^{-1} = (R^{-1})'R'RR\hat{}-1 = I$$

Nella pratica, la costruzione viene effettuata applicando l'algoritmo di Gram-Schmidt alle colonne di V. Quindi, costruisco la matrice Q in modo che

$q_*^{(i)} = a^{(i)} - \sum_{j=1}^{i-1} < a^{(i)}, q^{(j)} >* q^{(j)}$ (1), $q^{(i)} = \frac{q_*^{(i)}}{\left\| q_*^{(i)} \right\|_2}$. Facciamo il prodotto scalare dei due:

$$< q_*^{(i)}, q^{(i)} >=< a^{(i)}, q^{(i)} > - \sum_{j=1}^{i-1} < a^{(i)}, q^{(j)} >*< q^{(j)}, q^{(i)} > \; =< a^{(i)}, q^{(i)} > (2)$$

Sapendo che $q_*^{(i)} = \left\| q_*^{(i)} \right\|_2 \; q^{(i)} =< q_*^{(i)}, q^{(i)} >* q^{(i)}$, usando (2)

$$q_*^{(i)} =< a^{(i)}, q^{(i)} >* q^{(i)}.$$

Mettendola in (1), $< a^{(i)}, q^{(i)} >* q^{(i)} = a^{(i)} - \sum_{j=1}^{i-1} < a^{(i)}, q^{(j)} >* q^{(j)} \; =>$

$$a^{(i)} = \sum_{j=1}^{i} < a^{(i)}, q^{(j)} >* q^{(j)}$$

In forma matriciale, è proprio $A \; = \; QR$, dove $R = \begin{cases} 0, \; i > j \\ < a^{(j)}, q^{(i)} >, \; altrimenti \end{cases}$.

Applicazioni

Oltre che per la risoluzione di sistemi lineari, la decomposizione QR può essere usata per calcolare gli autovalori di una matrice. Costruisco la successione in questo modo:

1) Calcolo la decomposizione $A_k = Q_k R_k$
2) Pongo $A_{k+1} = R_k Q_k$

Le matrici della successione sono simili alla matrice iniziale $A_{k+1} = R_k Q_k = Q_k^{-1} A_k Q_k$ e quindi hanno gli stessi autovalori. Inoltre, la successione tende a una matrice triangolare superiore e gli elementi sulla diagonale tendono agli autovalori.

12. FORMULE DI QUADRATURA

Approssimare integrali definiti

Definizione 12.1. Le formule di quadratura sono metodi di approssimazione per integrali definiti.

I metodi che andremo ad analizzare saranno sotto l'ipotesi che la funzione sia regolare in un compatto di R. L'idea fondamentale è che, se riesco ad approssimare la funzione integranda con una funzione facilmente integrabile, allora posso stimare l'integrale con quello della funzione approssimante. Infatti

$$\left|\int_a^b f(x)\,dx - \int_a^b f_A(x)\,dx\right| = \left|\int_a^b f(x) - f_A(x)dx\right| \leq \int_a^b |f(x) - f_A(x)|\,dx \leq (b-a)\varepsilon$$

Formule di tipo interpolatorio

Definizione 12.2. Una formula di quadratura di tipo interpolatorio di grado n si basa sul calcolo dell'integrale del polinomio d'interpolazione di grado n definito da $n+1$ nodi nell'intervallo $[a,b]$.

Usando i polinomi di Lagrange,

$$p(x) = \sum_{i=0}^{n} f(x_i)l_i(x) => \int_a^b p(x)\,dx = \sum_{i=0}^{n} f(x_i)\int_a^b l_i(x)\,dx$$

Definizione 12.3. I numeri $\int_a^b l_i(x)\,dx$ prendono il nome di pesi della formula di quadratura.

Formula del trapezio

La formula del trapezio è la formula di quadratura di tipo interpolatorio di grado 1. Calcoliamo la formula esplicita per l'integrale, notando che i polinomi elementari formano triangoli:

$$\int_a^b f(x)\,dx \approx f(a)\int_a^b l_a(x)\,dx + f(b)\int_a^b l_b(x)\,dx = \frac{b-a}{2}[f(a)+f(b)]$$

Lemma 12.4. Siano $F, G\colon [a,b] \to R$ regolari e sia G a segno costante. Allora

$$\exists \xi \in [a,b] \mid \int_a^b F(x)G(x)dx = F(\xi)\int_a^b G(x)\,dx$$

Dimostrazione

$$\min F \leq F \leq \max F => \min F\,G(x) \leq F(x)G(x) \leq \max F\,G(x)$$

$$\min F \int_a^b G(x)dx \leq \int_a^b F(x)G(x)dx \leq \max F \int_a^b G(x)dx => \min F \leq \frac{\int_a^b F(x)G(x)dx}{\int_a^b G(x)dx} \leq \max F$$

$$\exists \xi \in [a,b] \mid \int_a^b F(x)G(x)dx = F(\xi)\int_a^b G(x)\,dx$$

Per il teorema del valore intermedio.

Stimiamo ora l'errore usando (9.12)

$$errore = \int_a^b f(x)dx - \int_a^b p_1(x)dx = -\int_a^b \frac{f''(\eta_x)}{2}(x-a)(b-x)dx =$$
$$= -f''(\xi)\int_a^b \frac{(x-a)(b-x)}{2}dx = -\frac{(b-a)^3}{12}f''(\xi)$$

Formula di Simpson

La formula di Simpson è la formula di quadratura di tipo interpolatorio di grado 2. Usando i polinomi di Lagrange, abbiamo $p_2(x) = f(a)l_a(x) + f\left(\frac{a+b}{2}\right)l_{\frac{a+b}{2}}(x) + f(b)l_b(x)$. Per quanto riguarda i pesi, con un calcolo diretto abbiamo

$$\int_a^b l_a(x)\,dx = \frac{b-a}{6} = \int_a^b l_b(x)\,dx\,, \int_a^b l_{\frac{a+b}{2}}(x)\,dx = \frac{2(b-a)}{3}$$

Dunque, $\int_a^b f(x)\,dx \approx (b-a)\left[\frac{f(a)}{6} + \frac{4}{6}f\left(\frac{(a+b)}{2}\right) + \frac{f(b)}{6}\right]$.

Non lo dimostreremo, ma l'errore per la formula di Simpson è

$$errore = -\frac{(b-a)^5}{2880}f^{(iv)}(\xi)$$

Formule di tipo interpolatorio composite

Definizione 12.5. Le formule di tipo interpolatorio composite sono il prodotto dell'applicazione di formule di tipo interpolatorio semplici su dei sottointervalli in cui è diviso l'intervallo.

Consideriamo la formula del trapezio. Conosciamo la sua formula e dobbiamo iterarla per N volte con un campionamento di tipo equispaziato con distanza h.

$$\int_{x_{i-1}}^{x_i} f(x)dx \approx \frac{h}{2}[f(x_i) + f(x_{i-1})] => \int_a^b f(x)dx \approx \frac{h}{2}\sum_{i=0}^{N} f(x_{i-1}) + f(x_i) =$$
$$\int_a^b f(x)dx \approx \frac{h}{2}\left[f(a) + 2\sum_{i=1}^{N-1} f(x_i) + f(b)\right]$$

Per il calcolo dell'errore, sappiamo da prima che

$$errore_i = -\frac{h^3}{12}f''(\xi_i) => errore = -\frac{(b-a)^2 h}{12N}\sum_{i=1}^{N} f''(\xi_i) = -\frac{b-a}{12}h^2 f''(\xi)$$

Per quanto riguarda la formula di Simpson composita, riporto solo i risultati

$$\int_a^b f(x)dx \approx \frac{h}{6}\left[\sum_{i=0}^{N} f(x_i) + f(x_{i+1}) + 4f\left(\frac{x_i + x_{i+1}}{2}\right)\right]$$

$$errore = -\frac{b-a}{2880}h^4 f^{(iv)}(\xi)$$

Formule di quadratura di Newton-Cotes e grado di precisione

Le formule di quadratura di Newton-Cotes di ordine sono formule di tipo interpolatorio che utilizzano $n+1$ punti equidistanti, estremi dell'intervallo inclusi.

Definizione 12.6. Il grado di precisione di una formula di quadratura è il massimo grado dei polinomi per cui è esatta.

Nella formula dei trapezi l'errore è controllato da una derivata seconda; dunque, è esatto fino ai polinomi di primo grado. Similmente, la formula di Simpson ha una derivata quarta, dunque ha grado di precisione 3.

Trasformazioni affini di nodi

Supponiamo di avere una formula di quadratura su un intervallo $[a^*, b^*]$ e di voler trovare i nodi e i pesi corrispondenti su un intervallo $[a, b]$. Costruiamo una mappa affine che trasforma il primo intervallo nel secondo $T(x^*) = \alpha x + \beta$, con $T(a^*) = a,\ T(b^*) = b$. Facendo le due valutazioni otteniamo che $\propto = \frac{h}{h^*}\ e\ \beta = \frac{b^*a - ba^*}{b^* - a^*}$. Nell'integrale, facciamo un cambio di variabile e otteniamo

$$\int_a^b f(x)dx = \int_{a*}^{b^*} f\big(T(x^*)\big)T'(x^*)dx^* = \frac{h}{h^*}\int_{a*}^{b^*} f\big(T(x^*)\big)dx^* =$$

$$= \sum_{i=0}^{N} f\big(T(x_i^*)\big)\left[\frac{h}{h^*}w_i^*\right]$$

Metodi di quadratura adattivi

Seppure i risultati sugli errori dei metodi ci permettano di dare una stima su come siano controllati, non sono utili nella pratica a ottenere un errore entro una certa tolleranza.

I metodi adattivi si basano sui metodi compositi con la differenza è che l'ampiezza degli intervalli varia (procedimento fatto dal programma) per ottenere una precisione al di sotto della tolleranza.

Inizio approssimando con i trapezi semplici l'integrale. Se non ho già la precisione ricercata, divido a metà gli intervalli e applico i trapezi composti. Mettiamoci nel segmento $[x_{i-1}, x_i]$ e chiamiamo $T_i\ e\ T_i^2$ rispettivamente i trapezi applicati al segmento e i trapezi composti di ordine 2 applicati al segmento. Vogliamo che l'errore sia minore della tolleranza, ma notiamo $errore = \left|\sum_{i=1}^{N_k} I_i - T_i^2\right| \leq \sum_{i=1}^{N_k}\left|I_i - T_i^2\right|$, quindi basta porre $\left|I_i - T_i^2\right| \leq \frac{h_i}{b-a}TOL$, in quanto la somma degli h_i è $b-a$.

Non conoscendo il valore reale dell'integrale, dobbiamo verificare l'ipotesi in un altro modo. Dallo studio dell'errore sappiamo che

$I_i - T_i^2 = -\frac{h_i}{12}\left(\frac{h_i}{2}\right)^2 f''(\xi_i) = -\frac{h_i^3}{48}f''(\xi_i)$ e che $I_i - T_i = -\frac{h_i^3}{12}f''(\eta_i)$.

Facendo l'ipotesi che $f''(\xi_i) \approx f''(\eta_i)$, che nella pratica non ho modo di verificare e non è soddisfatta ma funziona comunque, posso dire che

$$4\left(I_i - T_i^2\right) = I_i - T_i \Rightarrow I_i - T_i^2 = \frac{T_i^2 - T_i}{3}$$

Quindi abbiamo modo di impostare il nostro criterio di arresto usando le due formule dei trapezi.

Cambiando i trapezi con Simpson, si ottiene un risultato simile con $I_i - S_i^2 = \frac{S_i^2 - S_i}{15}$.